



浙江大學
ZHEJIANG UNIVERSITY

因果推理

2.1 因果发现

因果发现：从数据中寻找因果关系

在日常生活中，我们经常追问"为什么"：为什么吃药后病好了？为什么经济政策调整后通胀下降了？这类问题的核心是**因果关系**。

在机器学习和统计学中，大多数方法只能告诉我们变量之间的"相关性"（**correlation**），却无法直接告诉我们"因果性"（**causation**）。因果发现（**Causal Discovery**）要解决的核心问题就是：仅凭观测数据，能否自动学习出变量之间的因果结构？

因果推断 vs 因果发现

因果推断假设因果图（即变量之间的因果关系图）已经知道了，目标是估计某个具体的因果效应（比如"吃药对康复的影响有多大"）。而因果发现则更基础——它是要把因果图本身从数据中学出来。

因果发现方法的三大流派

目前主流的因果发现方法可以分为三大类，各有特点：

方法类别	核心思想	代表算法
基于约束	通过条件独立性检验推断因果结构	PC算法、FCI算法
基于评分	为每种可能的图打分，选最优图	GES、BIC评分搜索
基于函数模型	假设因果关系满足特定函数形式	LiNGAM、ANM

基于约束方法的核心思想

- 基于约束的方法建立在一个非常巧妙的洞察之上：

因果结构（图的形状）和统计性质（数据中的条件独立性）之间存在精确的对应关系。这个对应关系由两个条件保证。

两个关键假设

- **Markov条件 (因果图 $\rightarrow$ 独立性)**

如果在因果图中，变量X和变量Y被一组变量Z在图上"d-分离"了，那么在数据中，X和Y在给定Z的条件下一定是统计独立的。

- **忠实性条件 (独立性 $\rightarrow$ 因果图)**

反过来，如果在数据中发现X和Y在给定Z的条件下是统计独立的，那么在因果图中，X和Y一定被Z d-分离了。也就是说，数据中观察到的独立性不是"巧合"，而是图结构决定的。

- 这两个条件合在一起，就建立了一座桥梁：**条件独立 $\Leftrightarrow$ d-分离**。有了这座桥，我们就可以通过对数据进行统计检验（检验条件独立性），来推断因果图的结构。

条件独立性检验

- 条件独立性检验是基于约束方法的基本"工具"。常用的检验方法包括：
- 对于连续数据，可以使用偏相关检验（基于Fisher-z变换），通过检查偏相关系数是否为零来判断两个变量在给定其他变量后是否独立；
- 对于离散数据，可以使用卡方检验（G-test或chi-square test），通过检查条件频率表是否满足独立性来判断；
- 对于非线性关系，可以使用核方法（如HSIC检验）或基于互信息的方法，这些方法不要求变量之间是线性关系，适用范围更广。

PC算法

- PC算法由Peter Spirtes和Clark Glymour于1991年提出（"PC"取两人名字首字母），是最经典的基于约束的因果发现算法。
- 它的核心策略非常直观：先从一个完全连接的图出发，通过不断"删边"得到骨架，再通过分离集信息确定边的方向。
- 整个算法分为两个主要阶段。

第一阶段：骨架学习 (Skeleton Learning)

- 目标是确定哪些变量之间有边（暂时不考虑方向），通过逐步删除"不该存在"的边来实现。
- **步骤0：初始化——从完全图开始**
- 假设我们有4个变量 $\{X1, X2, X3, X4\}$ 。算法一开始非常"大方"，假设所有变量之间都有边。4个变量两两配对一共有 $C(4,2)=6$ 条边，所以初始图是一个完全无向图，每个变量都和其他所有变量相连。
- 为什么从完全图开始？因为我们还不知道哪些边该删，所以采用"宁多勿少"的策略——先假设都有关系，然后逐步排除。

-
- **步骤1：无条件独立检验（条件集大小 $|S|=0$ ）**
 - 第一轮检验最简单：对每一对相邻的变量直接做独立性检验，不用控制任何其他变量。也就是直接问："X和Y之间有没有关联？"如果检验结果显示X1和X4是边际独立的 ($X1 \perp X4$)，那就删除X1和X4之间的边，并记录分离集 $Sep(X1, X4) = \{\}$ （空集，表示不需要条件在任何变量上就能分离它们）。

-
- **步骤2：条件集大小 $|S|=1$**
 - 第二轮检验稍微复杂一些：对于仍然相连的每对变量，从它们各自的邻居中选出一个变量作为"条件"，然后检验在这个条件下，这对变量是否独立。
 - 举例来说，如果 X_2 和 X_4 还相连， X_3 是它们的共同邻居，那就检验：在给定 X_3 的条件下， X_2 和 X_4 是否独立？如果是 $(X_2 \perp X_4 \mid X_3)$ ，就删除 X_2 - X_4 这条边，并记录 $\text{Sep}(X_2, X_4) = \{X_3\}$ 。

为什么要逐步增大条件集？

条件集从空集开始逐渐增大的策略有两个好处。首先，小条件集的检验统计效力更强（需要的样本更少），所以先做简单的检验可以尽早删掉明显不该有的边。其次，删边后图变得更稀疏，后续需要检验的条件集组合就更少，大大降低了计算量。这是一种"先易后难"的高效策略。

- **步骤3及以后：逐步增大条件集**

- 继续增大条件集大小到 $|S|=2, 3, \dots$ ，重复同样的过程。每一轮对于仍然相邻的节点对，从它们的邻居中选取相应大小的子集进行条件独立检验。

- **终止条件**

- 当对于每一对仍然相邻的节点，其邻居数量都不够组成当前大小的条件集时，第一阶段结束。此时得到的无向图就是因果图的骨架（skeleton）——它告诉我们哪些变量之间有直接的因果联系，但还不知道方向。

第二阶段：边的定向 (Edge Orientation)

- 有了骨架之后，下一步是确定每条边的方向——也就是判断"谁导致了谁"。这个阶段分两步完成。
- **步骤A：识别V-结构 (Collider Detection)**
- 这是定向过程中最关键的一步。V-结构（也叫对撞结构）是一种形如 $X \rightarrow Z \leftarrow Y$ 的模式，其中X和Y都指向Z，且X和Y之间没有直接的边。
- 识别V-结构的方法是：在骨架中找到所有" $X - Z - Y$ "这样的三元组（其中X和Y不直接相连），然后检查第一阶段记录的分离集 $\text{Sep}(X, Y)$ 。如果Z不在 $\text{Sep}(X, Y)$ 中，那就说明Z是对撞节点，将其定向为 $X \rightarrow Z \leftarrow Y$ 。

为什么Z不在分离集中就意味着V-结构？

这背后有一个精妙的图论性质。

如果Z是对撞节点 ($X \rightarrow Z \leftarrow Y$)，那么条件在Z上反而会“打开”X和Y之间的信息通路（而不是阻断），所以Z不可能出现在使X和Y独立的分离集中。这就像两条河流汇入同一个湖泊——如果你只观察湖泊的水位（条件在Z上），反而能推断出两条河流的关系。（加法）

反之，如果Z是链式结构 ($X \rightarrow Z \rightarrow Y$)，那么条件在Z上就能阻断X和Y的联系，Z就会出现在分离集中。

- **步骤B：应用定向规则**

- V-结构只能定向一部分边。对于剩下的无向边，PC算法使用三条定向规则来尽可能多地确定方向，同时避免产生矛盾（新的V-结构或有向环）。
- **规则1——避免新V-结构：**如果已经知道 $X \rightarrow Z$ ，且Z和Y之间有无向边，而X和Y不相邻，那么必须定向为 $Z \rightarrow Y$ 。因为如果反过来定向为 $Z \leftarrow Y$ ，就会形成 $X \rightarrow Z \leftarrow Y$ ，这就产生了一个新的V-结构，与之前的检验结果矛盾。
- **规则2——避免有向环：**如果已经存在从X到Y的有向路径 ($X \rightarrow \dots \rightarrow Y$)，同时X和Y之间还有一条无向边，那么必须定向为 $X \rightarrow Y$ 。否则如果定向为 $Y \rightarrow X$ ，就会形成一个有向环（因果关系循环了），这在因果图中是不允许的。
- **规则3——利用不相邻性约束：**如果存在两条无向路径 $X - Z - Y$ 和 $X - W - Y$ ，且Z和W不相邻，通过d-分离的约束可以进一步推断方向。这条规则较为技术性，核心思想仍然是利用图结构的一致性约束。
- 反复应用这三条规则，直到没有新的边可以被定向为止。最终得到的图其中有些边是有向的（方向确定），有些边可能仍然是无向的（方向无法从数据中确定）。

例子

- 下面通过一个具体例子来走一遍PC算法的完整流程。假设有四个变量 $\{A, B, C, D\}$ ，真实的因果图为：

$$A \rightarrow B \leftarrow C \rightarrow D$$

- 也就是说：A和C都是B的原因（B是对撞节点），C同时也是D的原因。

$A \rightarrow B \leftarrow C \rightarrow D$

第一阶段：骨架学习

- 初始完全图有6条边：A-B, A-C, A-D, B-C, B-D, C-D。

第一轮：|S|=0（无条件独立检验）

- 逐对检验所有变量的边际独立性。从真实因果图可以推出：A和C之间没有直接因果路径，且A和C之间的唯一路径是 $A \rightarrow B \leftarrow C$ （这是对撞结构），在无条件下这条路径是被"阻断"的（对撞节点B没有被条件化），所以 $A \perp C$ 。同理 $A \perp D$ 。
- 删除 A-C 和 A-D 两条边，记录 $\text{Sep}(A,C)=\{\}$, $\text{Sep}(A,D)=\{\}$ 。
- 此时剩余4条边：A-B, B-C, B-D, C-D。

第二轮：|S|=1（条件集大小为1）

- 检查B和D的条件独立性。B的邻居有{A, C, D}，D的邻居有{B, C}。选择C作为条件变量，检验 $B \perp D \mid C$ 。在真实图中，B和D之间的唯一路径是 $B \leftarrow C \rightarrow D$ ，给定C后这条路径被阻断，所以 $B \perp D \mid C$ 成立。
- 删除 B-D，记录 $\text{Sep}(B,D)=\{C\}$ 。
- **最终骨架：** A - B - C - D（一条链式结构）。

叉式结构

- C是B和D的共同原因，这就是典型的叉式结构。
- 举个例子：假设C代表"今天下大雨"，B代表"路面积水"，D代表"航班延误"。下大雨既会导致路面积水，也会导致航班延误，所以你观察数据会发现路面积水和航班延误经常一起出现——它们是相关的。
- 但这两件事之间并没有直接的因果关系，它们的关联完全是因为共同原因"下大雨"。一旦你知道了今天是否下大雨（条件在C上），路面积水就不再给你关于航班是否延误的额外信息了。知道下雨了，航班大概率延误，不管你是否另外知道路面有没有积水。
- 所以 $B \perp D | C$ ：给定C（是否下雨）后，B（路面积水）和D（航班延误）就独立了，共同原因被"锁住"之后，两个结果之间的关联消失。

$$A \rightarrow B \leftarrow C \rightarrow D$$

- **第二阶段：定向**
- **识别V-结构（最终骨架：A - B - C - D（一条链式结构））**
- 三元组 A - B - C：A和C不相邻，检查 $\text{Sep}(A, C) = \{\}$ 。B是否在 $\{\}$ 中？不在！所以B是对撞节点，定向为 $A \rightarrow B \leftarrow C$ 。
- 三元组 B - C - D：B和D不相邻，检查 $\text{Sep}(B, D) = \{C\}$ 。C是否在 $\{C\}$ 中？在！所以这不是V-结构，暂不定向。

$$A \rightarrow B \leftarrow C \rightarrow D$$

- **应用定向规则** ($A \rightarrow B \leftarrow C \rightarrow D$)
- 目前已知 $A \rightarrow B \leftarrow C$, $C-D$ 还是无向边, B 和 D 不相邻。尝试用三条定向规则来确定 $C-D$ 的方向: 规则1要求“已有 $X \rightarrow Z \text{ --- } Y$, 且 X 和 Y 不相邻”才能定向。这里虽然有 $A \rightarrow B$ 且 B 和 D 不相邻, 但 B 和 D 之间没有边, 规则1无法作用。如果把 $C-D$ 定向为 $D \rightarrow C$, 形成 $B \leftarrow C \leftarrow D$, 这是链式结构, 不产生新V-结构, 也不形成有向环, 因此规则1、2、3都无法排除这个方向。反过来定向为 $C \rightarrow D$ 也同样合理。
- 这意味着 $C-D$ 这条边的方向仅凭观测数据是无法确定的。 $A \rightarrow B \leftarrow C \rightarrow D$ 和 $A \rightarrow B \leftarrow C \leftarrow D$ 编码了完全相同的条件独立关系, 它们属于同一个马尔可夫等价类。PC算法的正确输出是CPDAG: $A \rightarrow B \leftarrow C \text{ --- } D$, 其中 $C-D$ 保持无向, 表示“两个方向都与数据兼容”。
- **PC算法输出:** $A \rightarrow B \leftarrow C \text{ --- } D$ ——正确识别了V-结构, $C-D$ 方向留待额外信息确定

主要局限性

- **局限1——马尔可夫等价类：**PC算法只能识别到"马尔可夫等价类"（MEC），即具有相同骨架和相同V-结构的所有DAG的集合。在等价类中，有些边的方向是无法仅从观测数据中确定的。最终结果用CPDAG表示，其中未定向的边代表"两种方向都与数据兼容"。
- **局限2——对检验错误敏感：**算法的每一步删边决策都依赖于条件独立性检验的结果。如果某一步检验出错（在有限样本中这很常见），错误会"传播"到后续步骤，影响最终结果。后来的改进版本PC-stable算法通过并行化删边决策，减少了对检验顺序的依赖。
- **局限3——忠实性假设可能被违反：**在某些特殊情况下，不同因果路径的效应可能恰好"抵消"，导致虽然存在因果关系但数据中显示独立。例如X通过两条路径影响Y，一条正效应一条负效应，如果恰好大小相等，就会看到X和Y独立。
- **局限4——无法处理隐藏混杂：**标准PC算法假设所有相关变量都被观测到了。如果存在未观测的混杂变量（同时影响两个观测变量的隐藏原因），算法可能给出错误的结果。FCI算法是PC算法的扩展，通过引入双向边（ $\leftrightarrow$ ）来表示潜在混杂的存在。

PC算法的变体与扩展

算法变体	改进点	适用场景
PC-stable	并行删边，消除顺序依赖	标准场景（推荐默认使用）
FCI	允许隐藏混杂变量	不确定是否有未观测变量时
RFCI	FCI的快速近似版本	高维数据+潜在混杂
PC with majority/conservative	多数/保守投票确定V-结构	需要更稳健的V-结构判断时

2.2 因果推断

2.2.1 随机试验


什么是因果？ 一个实用的定义

定义： T 导致了 Y 当且仅当

保持其他所有变量不变的情况下，
改变 T 发现 Y 也发生了变化。

因果效应： T在改变一个单位时， Y的变化量。

两个关键条件: 保持其他所有变量不变， 改变T



因果效应估计

- 干预变量: $T = 1$ 或 $T = 0$
- 潜在结果变量: $Y(T = 1)$ 和 $Y(T = 0)$
- 个体因果效应 (Individual Treatment Effect, ITE) :

$$ITE(i) = Y_i(T_i = 1) - Y_i(T_i = 0)$$

- 平均因果效应 (Average Treatment Effect, ATE) :

$$ATE = E[Y(T = 1) - Y(T = 0)]$$

- 反事实问题: $Y(T = 1)$ 或 $Y(T = 0)$




两个关键条件: 保持其他所有变量不变, 改变T

理想方案：存在平行世界

- 假设存在平行世界（真实世界和平行世界）
- 在真实世界和平行世界上，所有的变量都是一样的，但干预变量 T 不一样




$Y(T = 1)$




$Y(T = 0)$

理想方案：存在平行世界

- 假设存在平行世界（真实世界和平行世界）
- 在真实世界和平行世界上，所有的变量都是一样的，但干预变量 T 不一样




金标准---随机实验



随机选取两批人群，一个人群施加干预（吃药），另一个人群不施加干预（不吃药）。

通过观察两个人群的康复效果以计算该药的因果效应。

随机实验的定义



随机试验是指在**相同条件下**对随机现象进行观察、记录或实验的过程，它的单次结果不可预知，但通过大量重复可以发现稳定的统计规律

金标准--随机实验

随机实验是核心科学研究方法

- 核心价值：通过系统控制变量与随机分配干预，为评估措施的真实效果提供强有力工具。
- 广泛应用：覆盖药物疗效评估、公共政策制定、新技术推广等多个领域。
- 历史发展：雏形始于 20 世纪初的农业科学，后随统计学发展，成为医学、社会科学、工程学和商业的标准研究方法。

随机实验的特点

在概率论中，随机实验通常具有以下几个典型特点：

- (1) **可重复性**：随机实验可以在相同条件下多次重复进行，保证实验结果在多次试验中的可比性。
- (2) **结果多样性**：每次实验可能出现多种不同结果，但可以事先确定所有可能的结果集合。
- (3) **不可预知性**：在每次实验开始之前，无法提前确定具体会发生的结果，但通过分析结果分布，可以获得总体规律性认识。

随机实验的设计

随机对照实验的设计需要考虑多个关键因素：


- (1) **样本选择**：样本选择需与研究目标相关，并能代表总体人群，以确保实验结果具有外推性。
- (2) **随机化设计**：随机化是随机实验的核心，包括完全随机、随机区组和分层随机化等多种方法，研究者需根据具体情境选择。
- (3) **对照组设计**：对照组的设计至关重要，其核心目的是提供参照以对比处理组的结果，且其选择和设置必须科学，以保证与处理组的可比性。

使用随机实验进行因果推断

随机实验通过**随机分配平衡干扰因素**，有效避免选择偏倚，是可靠评估干预措施因果效应、进行因果推断的核心科研方法。

当对照组和实验组中人群特征相同时，通过设计随机实验可以得到**无偏**的RCT数据。

利用RCT数据的无偏性，可以直接对组间直接取平均计算ATE。



随机实验的现实场景


医药领域：药物临床试验

在新药研发阶段，通过随机对照试验（RCT）将患者随机分为实验组（接受新药治疗）和对照组（接受安慰剂或现有标准药物治疗），以客观评估新药的疗效和安全性，这是药物获批上市的“金标准”。

互联网：推荐算法 A/B 测试

例子：视频平台或电商网站在优化推荐系统时，会将用户随机分配到不同的算法版本（如 A 版和 B 版），通过比较不同版本的用户点击率、停留时长、转化率等指标，来确定哪个算法版本的效果更优。

随机实验的局限性



- 随机实验的缺点：
 - 耗钱，耗时，耗力
 - 很多时候可能存在伦理问题

随机实验的局限性

- 1. **成本高，样本有限**：一项评估新型罕见病药物疗效的随机实验，由于患者数量极少，难以招募足够样本，导致实验结果可能无法推广到更广泛的患者群体。
- 2. **伦理问题**：研究高糖饮食对健康的长期影响时，无法通过随机实验让一组健康人群长期摄入高糖饮食作为干预，这违背了医学伦理。
- 3. **耗费时间长**：评估某种生活方式（如规律运动）对预防老年痴呆症的效果，由于该疾病潜伏期长、发病率相对较低，开展大规模、长期的随机对照实验在时间和资源上都不现实。

金标准---随机实验



- 随机实验

- 耗钱，耗
- 很多时候

如果没有随机试验数据，我们该如何评
估因果效应？
历史数据/观测学习

伦理问题


基于观测数据进行因果推断

- 因果推断中的反事实问题：

$$ATE = E[Y(T = 1) - Y(T = 0)]$$



- 能否通过计算 $T=1$ 和 $T=0$ 两个群体的均值，并相减来计算平均因果效应ATE？
 - 能，如果数据来自于随机实验（因为随机化保证了两组的混杂变量 X 分布一致）
 - 不能，如果是观测数据/历史数据（两组的混杂变量 X 可能分布不同）
- 两个关键条件：
 - 保持其他所有变量不变
 - 改变 T



基于观测数据进行因果推断

- 因果推断中的反事实问题：


$$ATE = E[Y(T = 1) - Y(T = 0)]$$



- 能否通过计算T=1和T=0两个群体的均值，并相减来计算平均因果效应ATE？
 - 能，如果数据来自于随机实验（X是一样的）
 - 不能，如果是观测数据/历史数据（X可能不一样）

平衡混杂变量的分布（T=1 / T=0）

一旦混杂变量的分布被平衡了，观测数据就近似于随机实验数据，从而可以进行无偏的因果推断




总结

在因果推断计算无偏因果效应时，往往需要无偏数据支持。

由于反事实的缺失，最好的方法是设计随机实验来获得无偏数据。但是由于成本、伦理、时间等约束，真正能够得到的无偏数据少之又少。

因此需要在观测数据下进行因果推断。因此如何平衡实验组和对照组直接的协变量特征成为因果推断中一个重要的课题。




2.2.2 经典因果推断方法


因果推断的经典方法

- **匹配法**
- **基于倾向得分的方法**
 - 倾向得分匹配法
 - 倾向得分逆加权法 (Inverse of Propensity Weighting, IPW)
 - 双稳健算法

匹配法












$T = 0$




$T = 1$

匹配法



匹配法




匹配法

- 通过约束混杂变量X相似或一样，来匹配T=1和T=0的样本：

$$Distance(X_i, X_j) \leq \epsilon$$


- 匹配的样本对能够保证T=1和T=0两组样本的混杂变量近似或一样。
- 平均因果效应可以通过计算T=1和T=0两组样本结果变量平均值的差值来计算。
- 参数 ϵ 越小，因果评估的偏差越小，但是方差大。



匹配法

- 精准匹配法:

$$Distance(X_i, X_j) = \begin{cases} 0, & X_i = X_j \\ \infty, & X_i \neq X_j \end{cases}$$



- 匹配法可用于混杂变量维度较低的场景

$$Distance(X_i, X_j) \leq \epsilon$$

- 但是当混杂变量是高维时，我们无法找到混杂变量完全一样的样本，匹配法就失效了

因果推断的经典方法

- 匹配法
- 基于倾向得分的方法
 - 倾向得分匹配法
 - 倾向得分逆加权法 (Inverse of Propensity Weighting, IPW)
 - 双稳健算法

基于倾向得分的方法


- 倾向得分 $e(X)$ 定义为样本接受干预 ($T=1$) 的概率:

$$e(X) = P(T = 1|X)$$

- 理论上, Donald Rubin证明了倾向得分足以总结混杂变量的信息, 用于保证因果推断的无偏性。
- 但是, 倾向得分无法被观测到, 需要进行评估

倾向得分匹配法

- 评估倾向得分: $\hat{e}(X) = P(T = 1|X)$
 - **监督学习**: 基于样本的观测变量/混杂变量X来预测其干预变量T。
 - 二分类问题, 逻辑斯蒂回归或深度神经网络
- 通过约束样本倾向得分相似或一样来匹配T=1和 T=0的样本:
$$Distance(X_i, X_j) = |\hat{e}(X_i) - \hat{e}(X_j)|$$
- 混杂变量高维的挑战:
 - 从匹配阶段转移到了倾向得分评估阶段




$$Distance(X_i, X_j) \leq \epsilon$$

因果推断的经典方法

- 匹配法
- 基于倾向得分的方法
 - 倾向得分匹配法
 - 倾向得分逆加权法 (Inverse of Propensity Weighting, IPW)
 - 双稳健算法

倾向得分逆加权法



倾向得分逆加权法

- 为什么利用倾向得分的逆对样本加权有用？
 - 倾向得分导致了混杂变量X在T=1和T=0两组样本之间的分布不一致

$$e(X) = P(T = 1|X)$$

样本	$e(X)$	$1 - e(X)$	样本数量	T=1组 样本数量	T=0组 样本数量
A	0.7	0.3	10	7	3
B	0.6	0.4	50	30	20
C	0.2	0.8	40	8	32

分布不一致

样本数量	T=1组 样本数量	T=0组 样本数量
A	10	10
B	50	50
C	40	40

混杂变量的分布一致了！

样本通过倾向得分的逆来加权：

$$w_i = \frac{T_i}{e_i} + \frac{1 - T_i}{1 - e_i}$$

倾向得分逆加权法

- 如果评估的倾向得分等于真实的倾向得分 $\hat{e}(X) = e(X)$, 那么 IPW 方法是无偏的 (unbiased)

$$ATE_{IPW} = \frac{1}{n} \sum_{i=1}^n \frac{T_i Y_i}{\hat{e}(X_i)} - \frac{1}{n} \sum_{i=1}^n \frac{(1 - T_i) Y_i}{1 - \hat{e}(X_i)} = E(Y_1 - Y_0)$$

- IPW 方法被广泛应用于各种实际场景中 (经济学、社会学等)
- 但 IPW 方法对因果评估的无偏性依赖于倾向得分模型的准确性
- 且当倾向得分 e 接近于 0 或 1 时, 因果评估的方差会很大

因果推断的经典方法

- 匹配法
- 基于倾向得分的方法
 - 倾向得分匹配法
 - 倾向得分逆加权法 (Inverse of Propensity Weighting, IPW)
 - 双稳健算法

结果变量回归 (Outcome Regression)

核心思想

最直接的想法：既然我们想知道处理效应，那就**直接建模"结果 Y 与协变量 X 之间的关系"**，分别对处理组和对照组各拟合一个模型，然后比较差异。

结果变量回归 (Outcome Regression)

具体步骤

第一步：分别建模

用处理组数据 ($T = 1$ 的样本) 拟合：

$$m_1(X) = E(Y \mid T = 1, X)$$

用对照组数据 ($T = 0$ 的样本) 拟合：

$$m_0(X) = E(Y \mid T = 0, X)$$

比如最简单的情况，用线性回归：

$$m_1(X) = \beta_0^{(1)} + \beta_1^{(1)} X_1 + \beta_2^{(1)} X_2 + \dots$$

$$m_0(X) = \beta_0^{(0)} + \beta_1^{(0)} X_1 + \beta_2^{(0)} X_2 + \dots$$

第二步：对每个个体预测两个"反事实"结果

对数据中的每个人 i ，不管他实际是否接受了处理，都用两个模型分别预测：

- $\hat{m}_1(X_i)$ ：如果他接受处理，预期结果是多少
- $\hat{m}_0(X_i)$ ：如果他不接受处理，预期结果是多少

第三步：求平均处理效应

$$\widehat{ATE} = \frac{1}{n} \sum_{i=1}^n [\hat{m}_1(X_i) - \hat{m}_0(X_i)]$$

对所有人的个体处理效应取平均，就得到了 ATE 的估计。

双稳健算法

- 平均因果效应的定义: $ATE = E[Y(T = 1) - Y(T = 0)]$
- 简单的结果变量回归方法:
 $m_1 = E(Y|T = 1, X)$ 以及 $m_0 = E(Y|T = 0, X)$
 - 如果结果变量回归模型是正确的, 那么因果效应评估是无偏的
- 倾向得分逆加权方法:
 - 如果倾向得分回归模型是正确的, 那么因果效应评估是无偏的
- 双稳健算法: 将两者结合起来

双稳健算法

$$m_0 = E(Y|T = 0, X)$$

$$m_1 = E(Y|T = 1, X)$$

- 双稳健算法：

$$\begin{aligned}ATE_{DR} &= \frac{1}{n} \sum_{i=1}^n \left[\frac{T_i Y_i}{\hat{e}(X_i)} - \frac{\{T_i - \hat{e}(X_i)\}}{\hat{e}(X_i)} \hat{m}_1(X_i) \right] \\ &\quad - \frac{1}{n} \sum_{i=1}^n \left[\frac{(1 - T_i) Y_i}{1 - \hat{e}(X_i)} + \frac{\{T_i - \hat{e}(X_i)\}}{1 - \hat{e}(X_i)} \hat{m}_0(X_i) \right]\end{aligned}$$

- 如果结果变量回归模型或者倾向得分回归模型是正确的，那么因果效应评估是无偏的
- 这种属性称之为双稳健


2.2.3 复杂环境下因果推断

-
- 复杂数据偏差
 - 复杂干预变量
 - 高维混杂变量

复杂数据偏差


复杂偏差下因果推断

2021诺贝尔经济学奖：
基于工具变量的因果推断




可解释
稳定/鲁棒
可决策

混淆偏差



虚假关联: T is
correlated with Y
ignoring X

选择偏差



虚假相关: T is
correlated with Y
given S

混淆偏差下因果推断

在自然实验中甄别混淆变量：知其然、且知其所以然

2021年度诺贝尔经济学奖一半奖项授予加州大学伯克利分校戴维·卡德（David Card），以表彰“他对劳动经济学的实证研究性的贡献”；另一半授予麻省理工学院的乔舒亚·安格里斯特（Joshua D. Angrist）和斯坦福大学的吉多·因本斯（Guido W. Imbens），以表彰“他们在因果关系分析方面的方法论贡献”。

“一个人的出生季节或月份”是一个神奇的**工具变量（Instrumental Variable）**，与其他（混淆）因素区分开，干净识别出了“多读一年书对未来收入造成的影响”。



III, Niklas Elmehed © Nobel Prize Outreach.
David Card
Prize share: 1/2




III, Niklas Elmehed © Nobel Prize Outreach.
Joshua D. Angrist
Prize share: 1/4



III, Niklas Elmehed © Nobel Prize Outreach.
Guido W. Imbens
Prize share: 1/4

The association between education and income


There is a clear correlation between years of education and income. But does this mean there is also causation?



读书是否有用？

The association between education and income

There is a clear correlation between years of education and income. But does this mean there is also causation?




The figure uses data from Angrist and Krueger (1991). People with 12 years of education have incomes that are 12 per cent higher than those of people with 11 years of education. People with 16 years of education have 65 per cent higher incomes than people with 11 years of education.

高中毕业


大学毕业

©Johan Jarnestad/The Royal Swedish Academy of Sciences

- 高中毕业 v.s. 高中肄业：12%
- 大学毕业 v.s. 高中毕业：53%
- 高出来的收入是否是“因为”多读了几年书？




评估教育对收入的影响




- 混杂变量 X : 能力
- 干预变量 $T=1/0$: 是否高中毕业
- 结果变量 Y : 收入
- 分析读书与收入之间的因果效应
 - 控制 X (混杂变量) 的分布
 - 方法: 匹配法, 基于倾向得分的方法等
 - 假设: 所有的混杂变量都能被观测

评估教育对收入的影响



- 混杂变量 X : 能力
- 干预变量 $T=1/0$: 是否高中毕业
- 结果变量 Y : 收入
- 分析读书与收入之间的因果效应
 - 控制 X (混杂变量) 的分布
 - 方法: 匹配法, 基于倾向得分的方法等
 - 假设: 所有的混杂变量都能被观测
- 实际应用中: 很多混杂变量无法观测
 - 如家庭情况 (U) 无法被测量


评估教育对收入的影响---工具变量



- 工具变量 (Z) 的条件
- 相关性: $P(T|Z) \neq P(T)$
- 排他性: $P(Y|Z, T, U) \neq P(Y|T, U)$
- 无混杂性: $Z \perp U$

- 分析**读书**与**收入**之间的因果效应
- **生日**可以作为**工具变量**
 - ✓生日影响读书
 - ✓生日不影响能力和家庭情况
 - ✓生日不直接影响收入



评估教育对收入的影响---工具变量



- Z : 生日, 春季出生/冬季出生
- T : 是否高中毕业
- Y : 收入
- U : 能力, 家庭情况等

两阶段回归 { 第一阶段: 用 Z 去回归 T $\hat{T} = \hat{g}(Z)$
第二阶段: 用 $\hat{T}$ 去回归 Y $\hat{Y} = \hat{f}(\hat{T})$

$$\begin{aligned} Z &\sim \mathcal{N}(0,1) \\ U &\sim \mathcal{N}(0,1) \\ T &= Z + U \\ Y &= f(T) + U \end{aligned}$$



• Data $P(T, Y)$



— f

— $\hat{f}^{NN}$

— $\hat{f}^{IV}$

局限于线性假设
需要提前定义工具变量

非线性工具变量回归



非线性工具变量回归 (DeepIV, KernelIV et.al)



第一阶段：用 Z 和 X 去回归 T $\hat{T} = \hat{g}(Z, X)$

第二阶段：用 $\hat{T}$ 和 X 去回归 Y $\hat{Y} = \hat{f}(\hat{T}, X)$

第一阶段回归会给第二阶段回归
引入混杂偏差 (X)

混杂变量平衡 + 工具变量回归

混杂平衡的工具变量回归 (CB-IV)



CB-IV (Confounder Balanced IV regression):

第一阶段（干预回归）：用 Z 和 X 去回归 T $\hat{T} = \hat{g}(Z, X)$

混杂平衡： 学习混杂平衡的表征 $\phi(X)$ ，使其满足 $\hat{T} \perp \phi(X)$

第二阶段（结果回归）：用 $\hat{T}$ 和 $\phi(X)$ 去回归 Y $\hat{Y} = \hat{f}(\hat{T}, \phi(X))$

实验分析和结果

Table 2: The bias (mean $\pm$ std) of ATE estimation on real-world data (Data- m_Z - m_X - m_U)

工具变量回归算法


混杂变量平衡方法

混杂平衡+工具变量回归

Within-Sample				
Method	IHDP-2-6-0	IHDP-2-4-2	Twins-5-8-0	Twins-5-5-3
DeepIV-LOG	2.8736 $\pm$ 0.0577	2.6227 $\pm$ 0.0651	0.0135 $\pm$ 0.0215	0.0237 $\pm$ 0.0111
DeepIV-GMM	3.7760 $\pm$ 0.0316	3.7396 $\pm$ 0.0402	0.0194 $\pm$ 0.0047	0.0221 $\pm$ 0.0041
OneSIV	1.7249 $\pm$ 0.3752	1.7411 $\pm$ 0.3422	0.0083 $\pm$ 0.0191	0.0080 $\pm$ 0.0167
DFIV	3.5543 $\pm$ 0.0891	3.6218 $\pm$ 0.1038	0.0268 $\pm$ 0.0005	0.0265 $\pm$ 0.0003
DFL	3.2018 $\pm$ 0.0496	3.1991 $\pm$ 0.0374	0.0624 $\pm$ 0.0586	0.0847 $\pm$ 0.0049
DirectRep	0.0675 $\pm$ 0.0562	0.4600 $\pm$ 0.0711	0.0167 $\pm$ 0.0171	0.0193 $\pm$ 0.0251
CFR	0.0854 $\pm$ 0.0579	0.4826 $\pm$ 0.0642	0.0115 $\pm$ 0.0167	0.0223 $\pm$ 0.0176
DRCFR	0.0553 $\pm$ 0.0644	0.4336 $\pm$ 0.0692	0.0114 $\pm$ 0.0221	0.0118 $\pm$ 0.0174
CB-IV	0.0117 $\pm$ 0.3882	0.1601 $\pm$ 0.2499	0.0067 $\pm$ 0.0271	0.0014 $\pm$ 0.0249
Out-of-Sample				
Method	IHDP-2-6-0	IHDP-2-4-2	Twins-5-8-0	Twins-5-5-3
DeepIV-LOG	2.8760 $\pm$ 0.0553	2.6226 $\pm$ 0.0692	0.0140 $\pm$ 0.0208	0.0238 $\pm$ 0.0111
DeepIV-GMM	3.7768 $\pm$ 0.0350	3.7388 $\pm$ 0.0416	0.0193 $\pm$ 0.0047	0.0221 $\pm$ 0.0040
OneSIV	1.7287 $\pm$ 0.3725	1.7351 $\pm$ 0.3430	0.0082 $\pm$ 0.0191	0.0081 $\pm$ 0.0168
DFIV	3.5538 $\pm$ 0.0904	3.6225 $\pm$ 0.1061	0.0268 $\pm$ 0.0005	0.0265 $\pm$ 0.0003
DFL	3.2038 $\pm$ 0.0496	3.1994 $\pm$ 0.0376	0.0624 $\pm$ 0.0584	0.0846 $\pm$ 0.0046
DirectRep	0.0608 $\pm$ 0.0817	0.4571 $\pm$ 0.0759	0.0162 $\pm$ 0.0175	0.0194 $\pm$ 0.0253
CFR	0.0785 $\pm$ 0.0810	0.4804 $\pm$ 0.0687	0.0110 $\pm$ 0.0163	0.0225 $\pm$ 0.0180
DRCFR	0.0450 $\pm$ 0.0953	0.4321 $\pm$ 0.0673	0.0113 $\pm$ 0.0219	0.0118 $\pm$ 0.0174
CB-IV	0.0150 $\pm$ 0.3927	0.1578 $\pm$ 0.2540	0.0065 $\pm$ 0.0270	0.0015 $\pm$ 0.0247

需要提前定义
工具变量

工具变量自动生成 (AutoIV)



工具变量 (Z) 的条件

相关性: $P(T|Z) \neq P(T)$

排他性: $P(Y|Z, T, U) \neq P(Y|T, U)$

无混杂性: $Z \perp U$

互信息约束
解耦表征学习

但是排他性可能不满足

工具变量自动生成 (AutoIV)




Figure 2: Response function prediction in low-dimensional scenarios.

综述：因果推理和机器学习中的工具变量方法

Instrumental Variables in Causal Inference and Machine Learning: A Survey

Anpeng Wu, Kun Kuang, Ruoxuan Xiong, Fei Wu, *Senior Member, IEEE*

Abstract—Causal inference is the process of using assumptions, study designs, and estimation strategies to draw conclusions about the causal relationships between variables based on data. This allows researchers to better understand the underlying mechanisms at work in complex systems and make more informed decisions. In many settings, we may not fully observe all the confounders that affect both the treatment and outcome variables, complicating the estimation of causal effects. To address this problem, a growing literature in both causal inference and machine learning proposes to use Instrumental Variables (IV). This paper serves as the first effort to systematically and comprehensively introduce and discuss the IV methods and their applications in both causal inference and machine learning. First, we provide the formal definition of IVs and discuss the identification problem of IV regression methods under different assumptions. Second, we categorize the existing work on IV methods into three streams according to the focus on the proposed methods, including two-stage least squares with IVs, control function with IVs, and evaluation of IVs. For each stream, we present both the classical causal inference methods, and recent developments in the machine learning literature. Then, we introduce a variety of applications of IV methods in real-world scenarios and provide a summary of the available datasets and algorithms. Finally, we summarize the literature, discuss the open problems and suggest promising future research directions for IV methods and their applications. We also develop a toolkit of IVs methods reviewed in this survey at <https://github.com/causal-machine-learning-lab/mliv>.




Fig. 2: Outline of the Survey.

Anpeng Wu, Kun Kuang*, Ruoxuan Xiong, Fei Wu. Instrumental Variables in Causal Inference and Machine Learning: A Survey, ACM Computing Surveys, 2025.

综述：因果推理和机器学习中的工具变量方法

mliv

```
from mliv.dataset.demand import gen_data
from mliv.utils import CausalDataset
gen_data()
data = CausalDataset('./Data/Demand/0.5_1.0_0.0_10000/1/')

from mliv.inference import Vanilla2SLS
from mliv.inference import Poly2SLS
from mliv.inference import NN2SLS
from mliv.inference import OneSIV
from mliv.inference import KernelIV
from mliv.inference import DualIV
from mliv.inference import DFL
from mliv.inference import AGMM
from mliv.inference import DeepGMM
from mliv.inference import DFIV
from mliv.inference import DeepIV          # Tensorflow & keras

for mod in [OneSIV, KernelIV, DualIV, DFL, AGMM, DeepGMM, DFIV, Vanilla2SLS, Poly2SLS, NN2SLS]:
    model = mod()
    model.config['num'] = 100
    model.config['epochs'] = 10
    model.fit(data)

print(mod)
```

复杂偏差下因果推断


2000诺贝尔经济学奖：
面向选择偏差的因果推断

因果




可解释
稳定/鲁棒
可决策

混淆偏差



虚假关联: T is
correlated with Y
ignoring X

选择偏差





虚假相关: T is
correlated with Y
given S

选择偏差下因果推断

选择性样本的理论与方法

2000年诺贝尔经济学奖授予美国经济学家詹姆斯·赫克曼（James Heckman，生于1944年）和丹尼尔·麦克法登（Daniel McFadden，生于1937年），以表彰前者“发展了分析**选择性样本的理论和方法**”和后者“发展了分析离散选择的理论和方法”。


抽样问题是经济计量学中的基本问题。如果一个样本不能随机地代表其总体，则抽样偏差就可能发生。可获得的微观数据是选择性样本，而不是随机样本。例如，对工资数据进行统计分析时，如果选择工作或接受教育的个人具有某种研究者未观察到的特征，而这种特征在统计时未予以考虑，统计评估就可能产生偏差。



读书是否有用？

The association between education and income

There is a clear correlation between years of education and income. But does this mean there is also causation?



The figure uses data from Angrist and Krueger (1991). People with 12 years of education have incomes that are 12 per cent higher than those of people with 11 years of education. People with 16 years of education have 65 per cent higher incomes than people with 11 years of education.


高中毕业

大学毕业

© Johan Jarnestad/The Royal Swedish Academy of Sciences


- 高中毕业 v.s. 高中肄业：12%
- 大学毕业 v.s. 高中毕业：53%

- 高出来的收入是否是“因为”多读了几年书？




直接做随机对照实验

评估教育对收入的影响




- 分析**读书**与**收入**之间的因果效应
 - 随机对照实验：做实验、发问卷
 - 干预变量 $T=1/0$ ：是否高中毕业
 - 结果变量 Y ：收入
- 实际应用中，RCT也可能存在**选择偏差**
 - 如**高中毕业但收入低**的受访者，**不愿意**回答
 - 而**高中未毕业但收入高**的，**非常愿意**回答
 - 选择变量 S ，由 T 和 Y （甚至 X ）同时影响
 - $S=1$ ： X, T, Y
 - $S=0$ ： X, T

碰撞偏差 (Collider Bias)



- 问题：读书与收入之间的因果效应
 - 混杂变量 X ：能力
 - 干预变量 $T=1/0$ ：是否高中毕业
 - 结果变量 Y ：收入
 - 选择变量 S ：由 T, Y, X 同时影响
 - $S=1$ ： X, T, Y
 - $S=0$ ： X, T
- 挑战：
 - ✓ 分布偏移： $P(X, T, Y, S = 1) \neq P(X, T, Y)$
 - ✓ 不可识别：存在碰撞偏差，因果效应不可识别

影子变量 (Shadow Variable)



- 影子变量 (Z) 的条件
- $Z \perp\!\!\!\perp S | X, Y, T$
- $Z \not\perp\!\!\!\perp Y | X, T, S = 1$

- 给定影子变量 (Z) , 则 $f(Y|X, Z, T, S = 0)$ 可识别


$$f(Y|X, Z, T, S = 0) = \text{OR}(X, T, Y) \cdot f(Y|X, Z, T, S = 1) / E[\text{OR}(X, T, Y) | X, Z, T, S = 1]$$

- 其中 $\text{OR}(X, T, Y) := \frac{f(S=0|X, T, Y) \cdot f(S=1|X, T, Y=0)}{f(S=0|X, T, Y=0) \cdot f(S=1|X, T, Y)}$, 可通过以下过程计算

- $\text{OR}(X, T, Y) = \widetilde{\text{OR}}(X, T, Y) / \widetilde{\text{OR}}(X, T, Y = 0)$
- $E[\widetilde{\text{OR}}(X, T, Y) | X, Z, T, S = 1] = f(Z|X, T, S = 1) / f(Z|X, T, S = 0)$
- 当且仅当 Z 比 Y 有更大的 support set 时 $\widetilde{\text{OR}}(X, T, Y)$ 有唯一解

需要提前定义好
影子变量

Learning Shadow Variable Representation



- 影子变量 (Z) 的条件
- $Z \perp\!\!\!\perp S | X, Y, T$
- $Z \not\perp\!\!\!\perp Y | X, T, S = 1$
- 从混杂变量 X 中学习影子变量 Z 的表征, 约束其满足以下条件:
 - $Z \not\perp\!\!\!\perp Y | X, T, S = 1$: 只用观测变量即可显式约束
 - $Z \perp\!\!\!\perp S | X, Y, T$: Y 在 $S = 0$ 时缺失, 无法显式约束
- 假设 $Z \perp\!\!\!\perp S | X, Y, T$ 成立
 - 当且仅当 $E[S/Q(X, T, Y) | X, Z, T] = 1$ 不存在 $(0, 1]$ 之间的解时, 可拒绝该假设
 - 其中 $Q(X, T, Y)$ 是一个未知函数



学习影子变量表征

假设检验确保条件满足

基于影子变量的因果推断

ShadowCatcher & ShadowEstimator

- ShadowCatcher:
 - 表征学习阶段
 - 假设检验阶段
- ShadowEstimator
 - 估计 $OR(X, T, Y)$
 - 估计 $f(Y|X, Z, T, S = 0)$



实验分析和结果


ESTIMATOR	$\beta = 1$		$\beta = 3$		$\beta = 5$	
	SELECTED DATA	UNSELECTED DATA	SELECTED DATA	UNSELECTED DATA	SELECTED DATA	UNSELECTED DATA
HECKIT	0.323±0.065	0.330±0.046	0.340±0.055	0.352±0.042	0.349±0.069	0.413±0.048
DR	0.298±0.032	0.316±0.042	0.331±0.048	0.357±0.053	0.367±0.033	0.448±0.017
IPSW	0.328±0.048	0.348±0.049	0.328±0.031	0.353±0.034	0.465±0.011	0.545±0.014
BNN	0.290±0.011	0.306±0.012	0.329±0.048	0.354±0.033	0.359±0.011	0.439±0.015
TARNET	0.295±0.012	0.312±0.011	0.329±0.030	0.357±0.053	0.366±0.071	0.436±0.087
CFR	0.290±0.009	0.307±0.008	0.324±0.009	0.350±0.013	0.359±0.008	0.436±0.030
CFOREST	0.310±0.030	0.331±0.038	0.338±0.019	0.368±0.022	0.373±0.026	0.453±0.043
DR-CFR	0.284±0.038	0.307±0.040	0.340±0.055	0.355±0.064	0.366±0.051	0.435±0.060
TEDVAE	0.281±0.056	0.419±0.070	0.378±0.063	0.420±0.059	0.394±0.054	0.431±0.067
DER-CFR	0.291±0.010	0.309±0.014	0.323±0.015	0.348±0.017	0.358±0.011	0.439±0.013
DESCN	0.295±0.002	0.312±0.002	0.326±0.003	0.357±0.004	0.365±0.003	0.449±0.011
ES-CFR	0.289±0.003	0.305±0.004	0.331±0.003	0.359±0.003	0.369±0.003	0.448±0.005
OURS	0.227±0.001	0.229±0.001	0.249±0.013	0.255±0.021	0.299±0.008	0.300±0.008

ESTIMATOR	IHDP ($\sqrt{\text{PEHE}}$)		ACIC 2016 ($\sqrt{\text{PEHE}}$)		JOBS ($\hat{R}_{\text{Pol}}$)	
	WITHIN-SAMPLE	OUT-OF-SAMPLE	WITHIN-SAMPLE	OUT-OF-SAMPLE	WITHIN-SAMPLE	OUT-OF-SAMPLE
HECKIT	1.587±0.065	1.621±0.041	3.106±0.444	3.340±0.111	0.328±0.050	0.331±0.052
DR	1.355±0.123	1.572±0.205	2.346±0.129	2.653±0.222	0.316±0.007	0.317±0.036
IPSW	2.118±0.344	2.129±0.295	4.244±0.145	5.411±0.073	0.284±0.051	0.289±0.063
BNN	1.308±0.298	1.457±0.339	2.173±0.150	2.586±0.486	0.303±0.025	0.304±0.041
TARNET	1.240±0.158	1.416±0.154	2.275±0.756	2.805±0.766	0.315±0.012	0.316±0.050
CFR	1.283±0.186	1.401±0.238	2.107±0.297	2.361±0.587	0.313±0.018	0.314±0.072
CFOREST	1.702±0.292	1.948±0.429	4.137±0.295	4.605±0.137	0.326±0.012	0.326±0.059
DR-CFR	1.299±0.087	1.399±0.171	2.240±0.691	2.340±0.663	0.322±0.022	0.323±0.099
TEDVAE	4.246±0.394	4.347±0.563	3.501±0.708	4.468±0.813	0.296±0.046	0.300±0.031
DER-CFR	1.446±0.345	1.571±0.371	2.214±0.204	2.246±0.598	0.309±0.023	0.311±0.029
DESCN	1.193±0.057	1.665±0.246	2.185±0.150	2.306±0.236	0.331±0.010	0.331±0.051
ES-CFR	1.499±0.096	1.436±0.095	3.875±0.224	4.494±0.214	0.290±0.045	0.293±0.046
OURS	0.703±0.106	0.723±0.102	1.911±0.126	2.047±0.351	0.279±0.017	0.280±0.018

复杂偏差下因果推断


2021诺贝尔经济学奖：
基于工具变量的因果推断

2000诺贝尔经济学奖：
面向选择偏差的因果推断




可解释
稳定/鲁棒
可决策

混淆偏差



虚假关联: T is
correlated with Y
ignoring X


选择偏差




虚假相关: T is
correlated with Y
given S

同时存在混淆偏差和选择偏差，如何推断？


复杂偏差下因果推断




(a) Latent confounding. (b) Instrumental variable approach.



(a) Collider bias.



(b) Shadow variable approach.




- 如何同时解决两种偏差:
 - IV is all you need

2SSI: 两阶段Shadow Variable回归


• 第一阶段

- 用 $S=1$ 和 $S=0$ 的 X 和 Z 回归 T ，根据 T 和 $\hat{T}$ 求残差 R
- 用 $S=1$ 和 $S=0$ 的 X , T 和 Z 回归 S ，同时学习解耦表征 φ
 - 用一个表征网络学习 $\varphi = f(Z)$ 预测 S ，并约束其与 T 独立
 - 二值 T 时采用积分概率度量IPM，连续 T 时用互信息



• 第二阶段

- 引入 φ ，将 R 视为 φ 的条件下的Shadow Variable
 - R 在 X, T, Y 和 φ 的条件下与 S 独立，在 $X, T, S=1$ 和 φ 的条件下与 Y 相关




- 影子变量 (Z) 的条件
- $Z \perp\!\!\!\perp S | X, Y, T$
- $Z \not\perp\!\!\!\perp Y | X, T, S = 1$

实验结果

- 在合成数据集上的实验结果

ESTIMATOR	$\alpha = 5$		$\alpha = 10$		$\alpha = 15$		ESTIMATOR	$\beta = 5$		$\beta = 10$		$\beta = 15$	
	$S = 1$ DATA	$S = 0$ DATA	$S = 1$ DATA	$S = 0$ DATA	$S = 1$ DATA	$S = 0$ DATA		$S = 1$ DATA	$S = 0$ DATA	$S = 1$ DATA	$S = 0$ DATA	$S = 1$ DATA	$S = 0$ DATA
HECKIT	0.648±0.038	5.685±0.324	0.724±0.060	6.741±0.359	0.714±0.057	6.763±0.507	HECKIT	0.089±0.007	6.008±0.230	0.724±0.060	6.741±0.359	1.819±0.122	9.490±0.778
2SRI	0.998±0.070	6.076±0.262	1.052±0.097	6.673±0.219	1.016±0.063	6.799±0.363	2SRI	0.114±0.011	3.317±0.155	1.052±0.097	6.673±0.219	2.918±0.251	10.88±0.452
IPSW	1.075±0.082	12.72±1.070	1.063±0.093	12.39±0.656	1.056±0.085	12.45±0.442	IPSW	0.136±0.035	5.588±0.777	1.063±0.093	12.39±0.656	3.150±0.396	24.65±2.918
SHADOW	0.852±0.083	4.619±0.269	0.956±0.116	5.233±0.289	0.957±0.088	5.258±0.449	SHADOW	0.099±0.009	3.220±0.149	0.956±0.116	5.233±0.289	2.512±0.260	7.350±0.520
DEEPIV	0.630±0.048	12.06±0.832	0.633±0.051	12.46±0.424	0.641±0.053	12.57±1.007	DEEPIV	0.065±0.007	4.697±0.278	0.633±0.051	12.46±0.424	1.945±0.117	24.97±1.596
KERNEL IV	0.297±0.097	6.450±0.367	0.400±0.175	6.995±0.526	0.428±0.109	7.220±0.903	KERNEL IV	0.052±0.015	3.734±0.182	0.400±0.175	6.995±0.526	1.759±0.747	12.07±0.611
DEEPGMM	0.655±0.105	8.138±1.268	0.688±0.108	8.399±1.555	0.699±0.104	9.163±1.419	DEEPGMM	0.040±0.009	3.893±0.443	0.688±0.108	8.399±1.555	2.445±0.396	13.59±2.546
DFIV	0.572±0.090	12.72±0.686	0.580±0.106	12.97±1.667	0.620±0.052	13.60±1.181	DFIV	0.072±0.008	5.056±0.435	0.580±0.106	12.97±1.667	1.809±0.302	28.27±1.978
CB-IV	1.202±0.228	7.910±0.482	1.270±0.225	8.442±0.574	1.343±0.153	8.771±0.712	CB-IV	0.099±0.021	3.737±0.276	1.270±0.225	8.442±0.574	4.031±0.412	14.46±0.615
2SSI	0.147±0.020	1.320±0.335	0.154±0.016	1.278±0.155	0.155±0.024	1.275±0.227	2SSI	0.038±0.020	1.995±0.088	0.154±0.016	1.278±0.155	0.522±0.411	2.655±0.630

- 在真实数据集上的ATE估计结果



复杂偏差下因果推断与因果图学习





Figure 1: Underlying bias present in unknown causal relation.



Assumption 1. SUTVA.

Assumption 2. Unconfoundedness.



Assumption 3. Positive Assumption.

Assumption 4. Markov Assumption.

Assumption 5. Temporal Dependency.

Assumption 6. Invariant Causal Mechanism. At different timestamps, the causal relationship between variables does not change over time, and the parent node of a variable in the previous timestamp remains its parent node in the next timestamp.

复杂偏差下因果推断与因果图学习




基于前序时间变量 P_1, P_2, P_Y , P_T 为 T 和 Y 的条件工具变量

复杂偏差下因果推断


2021诺贝尔经济学奖：
基于工具变量的因果推断

2000诺贝尔经济学奖：
面向选择偏差的因果推断




可解释
稳定/鲁棒
可决策

混淆偏差



虚假关联: T is
correlated with Y
ignoring X

选择偏差



虚假相关: T is
correlated with Y
given S

同时存在混淆偏差和选择偏差，（条件）工具变量

复杂干预变量

复杂干预下因果推断

Causal Inference with Complex Treatments: A Survey

YINGRONG WANG, Zhejiang University, China

HAOXUAN LI, Peking University, China

MINQIN ZHU, Zhejiang University, China

ANPENG WU, Zhejiang University, China

RUOXUAN XIONG, Emory University, US

FEI WU, Zhejiang University, China

KUN KUANG, Zhejiang University, China




Fig. 1. An example of complex treatments.




Fig. 3. Outline of the survey.

复杂干预变量

可选药物	 ✓	    ✓	    ✓ ✓	 5~10g 注射 6. 28g
干预类型	二元	多值	多维	连续
所有可能	2	4	$2^4 = 16$	∞
干预变量	$T_i \in \mathcal{T}^{bin} = \{0,1\}$ 吃药或不吃药	$T_i \in \mathcal{T}^{mul} = \{1,2, \dots, m\}$ 多种药里选1种	$T_i \in \mathcal{T}^{bun} \subset \{0,1\}^m$ 多种药里组合用药	$T_i \in \mathcal{T}^{con} \subset \mathbb{R}$ 注射剂量
估计目标	$ATE = E[Y(T = \textcolor{blue}{t}) - Y(T = 0)]$ 干预组变为多种离散值			$ADRF = E[Y(T = t)]$ 剂量-响应曲线

方法扩展-倾向得分

- 倾向得分：倾向得分 $e(X)$ 定义为样本接受干预 ($T = 1$) 的概率



$$e(X) = P(T = 1|X)$$

二分类任务，一般采用逻辑斯蒂回归模型建模

- 广义倾向得分：

- 多值： $e(X) = P(T = t|X), \forall t \in \{1, 2, \dots, m\}$

多分类任务，采用多项逻辑回归/多分类神经网络

- 连续： $e(t, X) = f_{T|X}(t|x)$

条件概率密度函数，采用回归模型(整态假设)或核密度估计(非参方法)

- 多维： $e_t(X) = P(T_1 = t_1, T_2 = t_2, \dots, T_m = t_m | X)$

联合条件下的分配概率，采用表征学习网络/生成模型


方法扩展-混杂变量平衡

- 混杂变量平衡的核心：消除不同组之间的 X 分布差异
- 二元干预：
 - 样本加权 (熵平衡法、近似残差平衡法)： $T \perp wX$
 - 难以扩展到复杂干预变量的场景：
 - T 的取值过多，需要考虑多组平衡，尤其是连续干预
 - 干预空间变大，很多干预组下的样本非常稀疏
- 通常转为表征学习方法： $T \perp \phi(X)$
 - 特征解构：将混杂变量中的不同维度“区别对待”
 - 局部平滑：缓解了加权法中因样本稀疏导致的断层问题

极端权重

方法扩展-混杂变量平衡

- 混杂变量平衡的核心：消除不同组之间的 X 分布差异
- 二元干预：
 - 表征学习 (CounterFactual Regression, CFR) : $T \perp \phi(X)$




衡量两个分布间距离/差异性的常用度量

方法扩展-混杂变量平衡

- 混杂变量平衡的核心：消除不同组之间的 X 分布差异
- 复杂干预：
 - 多值干预：在 m 比较小的情况下，建立 m 个预测头
对于 m 个组，约束 C_m^2 组 IPM，进行两两间分布对齐
 - 多维/连续干预：在干预空间比较大的情况下，建立共享预测头
采用互信息等度量，直接约束 $T \perp \phi(X)$ 独立性
 - 连续干预：采用层级结构，将一个大的连续空间离散化为多个分段区间
先针对有限个数的分段区间进行分类预测
在每个区间内，针对性地学习一个回归模型预测结果

连续干预效应估计




- 二元干预
 - $T=0$ 或 $T=1$
 - $T \perp X$: 混杂因素平衡
- 多值干预
 - $T=0,1,2,\dots$
 - $T \perp X$: 混杂因素平衡
- 连续干预
 - 如何使 $T \perp X$?

连续干预效应估计

- 我们的目标: $T \perp X$
- 通过对干预变量进行随机置乱, 实现其与协变量的独立

命题 1. 在观测数据 $D_{obs} = \{T, X\}$ 中, 若将干预变量 T 在全部样本间随机置乱, 则当样本量 $n \rightarrow \infty$ 时, 置乱后的干预变量 T' 与协变量 X 相互独立。

PROPOSITION 1. *By randomly shuffle the value of the treatment variable T over all samples in observed data $\mathbf{D}_{obs} = \{T, \mathbf{X}\}$, the shuffled treatment T' would become independent with the covariates $\mathbf{X}$ if sample size $n \rightarrow \infty$.*



连续干预效应估计


- 我们的目标: $T \perp X$
- “校准” 分布的构造
 - 在 “校准” 分布 $\mathbf{D}_{cal} = \{T', \mathbf{X}\}$ 中, 有 $T' \perp X$
- “校准” 分布的逼近
 - 观测分布: $\mathbf{D}_{obs} = \{T, \mathbf{X}\}$
 - 学习样本权重以逼近 “校准” 分布

$$\mathbf{D}_{obs} = \{T, \mathbf{X}\} \xrightarrow{\text{样本权重 } W} \mathbf{D}_{cal} = \{T', \mathbf{X}\}$$


- 使得: $W T \perp W X$

来自 GAN 机制的启发

- 生成对抗网络 Generative Adversarial Networks (GAN)



- 生成对抗去混杂 Generative Adversarial De-confounding (GAD)




生成对抗去混杂 (GAD)

- “校准” 分布: $\mathbf{D}_{cal} = \{T', \mathbf{X}\}$
- 观测分布: $\mathbf{D}_{obs} = \{T, \mathbf{X}\}$
- 基于 GAD 的样本权重学习

$$\begin{aligned} L(\mathbf{w}, d) &= \mathbb{E}_{(t,x) \sim \mathbf{D}_{cal}} [l(d(t, x), \boxed{1})] \\ &\quad + \mathbb{E}_{(t,x) \sim \mathbf{D}_{obs}} [\boxed{w(t, x)} \cdot l(d(t, x), \boxed{0})], \\ s.t. \quad &\mathbb{E}_{(t,x) \sim \mathbf{D}_{obs}} [w(t, x)] = 1, \mathbf{w} \succeq 0, \end{aligned}$$

连续干预效应估计





Method	<i>TWINS</i>		
	$BIAS_{MTEF}$	$RMSE_{MTEF}$	$RMSE_{ADRF}$
OLS	0.208(0.079)	0.236(0.089)	0.686(0.350)
$IPW_{unstable}$	1.385(0.757)	1.532(0.890)	5.506(2.061)
IPW_{stable}	1.693(1.599)	1.878(1.849)	6.982(4.453)
ISMW	0.165(0.062)	0.181(0.069)	0.962(0.214)
CBGPS	0.187(0.137)	0.216(0.158)	0.683(0.380)
GAD	0.127(0.039)	0.144(0.046)	0.383(0.091)

连续且高维的干预变量

Method	Formulation
Treatment-Balanced Representation (Schwab et al. 2020)	$T \perp\!\!\!\perp \Phi(X)$
Balancing Representation (Nie et al. 2021)	$T \perp\!\!\!\perp X \mid \Phi(X)$
Prognostic Representation (Bica et al. 2020)	$Y(t) \perp\!\!\!\perp X \mid \Phi(X)$
Double Balancing Representation (ours)	$(T, Y) \perp\!\!\!\perp X \mid \Phi(X)$

Table 1: A comparison of the constraints employed in various representation learning methods.



Minqin Zhu, Kun Kuang .et al. Contrastive Balancing Representation Learning for Heterogeneous Dose-Response Curves Estimation, AAAI, 2024.

未来展望

- 待解决挑战：
 - 混杂变量的**异质性**：
 - 存在多个干预（多值/多维）时，不同干预对应不同的混杂变量
 - 大多数现有方法假设所有干预变量的混杂因素是统一的
 - 干预变量之间的**相互作用**（多维干预）：
 - 加性效应（ $1+1=2$ ）、协同效应（ $1+1>2$ ）、拮抗效应（ $1+1<2$ ）
 - 大多数现有方法暂未考虑干预变量之间的互相作用
 - 巨大干预空间下的数据**稀疏性**：
 - 数据只能覆盖所有可能干预中极小的一部分，可能违反overlap假设


高维混杂变量

高维协变量是真实数据常态

数据常见协变量维度高、来源杂的情况：

- 医疗电子病历：诊断、检查、用药等大量变量
- 互联网行为：点击、停留、画像特征维度爆炸
- 宏观经济与文本：指标众多 + 文本和词袋特征高维

因此，把所有变量全部放入模型训练并不安全




真混杂 $\subset$ 候选特征（未知）

高维变量

- 在满足 SUTVA、无混杂性和重叠性假设的条件下
- 在复杂环境中，我们可能会收集到高维变量，其中既包括混杂变量，也包括噪声变量
- 但并非所有观测到或收集到的变量都是混杂变量，纳入非混杂变量还可能引入新的偏差
- 如何为因果推断自动选择混杂变量？

用于反事实推断的分解表示学习



- 所有变量都可以被划分为三部分：**工具变量**、**混杂变量**和**调整变量**。
- 纳入**工具变量**会给因果推断带来偏差。
- 纳入**调整变量**有助于降低方差。

Kuang K, Cui P, Li B, et al. Treatment effect estimation with data-driven variable decomposition [C]. AAAI, 2017


Kuang K, Cui P, et al. Data-Driven Variable Decomposition for Treatment Effect Estimation, TKDE, 2020

Wu A, Yuan J, Kuang K, et al. Learning decomposed representations for treatment effect estimation[J]. TKDE, 2022.


用于反事实推断的分解表示学习

- 三个分解表示网络
 - $I(X)$, $C(X)$, $A(X)$
- 三个分解与平衡正则项
 - 混杂变量识别: $A(X) \perp T, I(X) \perp Y \mid T$
 - 混杂变量平衡: $w \cdot C(X) \perp T$
- 两个回归网络
 - $Y(T = 1)$, $Y(T = 0)$
- 用于分解的正交正则项


$$\mathcal{L}_O = \bar{I}_W^T \cdot \bar{C}_W + \bar{C}_W^T \cdot \bar{A}_W + \bar{A}_W^T \cdot \bar{I}_W$$



用于反事实推断的分解表示学习



(a) DR-CFR in Syn_16_16_16_3000



(b) DeR-CFR in Syn_16_16_16_3000

Wu A, Yuan J, Kuang K, et al. Learning decomposed representations for treatment effect estimation[J]. IEEE Transactions on Knowledge and Data Engineering, 2022.

用于反事实推断的分解表示学习

Table 1: The results on IHDP.

IHDP				
Mean +/- Std	Within-sample		Out-of-sample	
Methods	PEHE	ϵ_{ATE}	PEHE	ϵ_{ATE}
CFR-MMD	0.702 +/- 0.037	0.284 +/- 0.036	0.795 +/- 0.078	0.309 +/- 0.039
CFR-WASS	0.702 +/- 0.034	0.306 +/- 0.040	0.798 +/- 0.088	0.325 +/- 0.045
CFR-ISW	0.598 +/- 0.028	0.210 +/- 0.028	0.715 +/- 0.102	0.218 +/- 0.031
SITE	0.609 +/- 0.061	0.259 +/- 0.091	1.335 +/- 0.698	0.341 +/- 0.116
DR-CFR	0.657 +/- 0.028	0.240 +/- 0.032	0.789 +/- 0.091	0.261 +/- 0.036
DeR-CFR	0.444 +/- 0.020	0.130 +/- 0.020	0.529 +/- 0.068	0.147 +/- 0.022

Table 2: Ablation studies of DeR-CFR.

$\mathcal{L}_A$	$\mathcal{L}_I$	$\mathcal{L}_{C_B}$	$\mathcal{L}_O$	PEHE	
				Within-sample	Out-of-sample
✓	✓	✓	✓	0.444 +/- 0.020	0.529 +/- 0.068
✓	✓	✓		0.478 +/- 0.033	0.542 +/- 0.053
✓	✓		✓	0.482 +/- 0.039	0.565 +/- 0.075
✓		✓	✓	0.479 +/- 0.030	0.560 +/- 0.071
	✓	✓	✓	0.635 +/- 0.035	0.858 +/- 0.133

Wu A, Yuan J, Kuang K, et al. Learning decomposed representations for treatment effect estimation[J]. IEEE Transactions on Knowledge and Data Engineering, 2022.

用于反事实推断的分解表示学习

Table 1: The results on IHDP.

IHDP				
Mean +/- Std	Within-sample		Out-of-sample	
Methods	PEHE	ϵ_{ATE}	PEHE	ϵ_{ATE}
CFR-MMD	0.702 +/- 0.037	0.284 +/- 0.036	0.795 +/- 0.078	0.309 +/- 0.039
CFR-WASS	0.702 +/- 0.034	0.306 +/- 0.040	0.798 +/- 0.088	0.325 +/- 0.045
CFR-ISW	0.598 +/- 0.028	0.210 +/- 0.028	0.715 +/- 0.102	0.218 +/- 0.031
SITE	0.609 +/- 0.061	0.259 +/- 0.091	1.335 +/- 0.698	0.341 +/- 0.116
DR-CFR	0.657 +/- 0.028	0.240 +/- 0.032	0.789 +/- 0.091	0.261 +/- 0.036
DeR-CFR	0.635 +/- 0.035	0.240 +/- 0.032	0.789 +/- 0.091	0.261 +/- 0.036


Table 2: Ablation studies of DeR-CFR.

$\mathcal{L}_A$	$\mathcal{L}_I$	$\mathcal{L}_{C_B}$	$\mathcal{L}_O$	PEHE	
				Within-sample	Out-of-sample
✓	✓	✓	✓	0.444 +/- 0.020	0.529 +/- 0.068
✓	✓	✓		0.478 +/- 0.033	0.542 +/- 0.053
✓	✓		✓	0.482 +/- 0.039	0.565 +/- 0.075
✓		✓	✓	0.479 +/- 0.030	0.560 +/- 0.071
				0.635 +/- 0.035	0.858 +/- 0.133


面向干预前变量和结果前变量而设计。

对于干预后变量和结果后变量的情形，该如何处理？


调整特征选择



(a) Brute-force.



(b) Separation.



(c) Ours.

附加假设：不存在中介变量

理论结果：最优特征是混杂变量与结果相关的协变量

如何选择最优特征？

调整特征选择

- 半参数推断

- 定义：统计模型 M 由以下部分得到

- 目标参数 $\gamma(P)$: 有限维 (例如, ATE)

- 干扰参数: 无限维

- 渐近线性: $\sqrt{n}(T(n) - \gamma(P)) = \frac{1}{\sqrt{n}} \sum_{i=1}^n D_i(V) + o_p(1)$

- ✓ 影响函数: $D(V)$

- ✓ 估计量: $T(n)$ (例如, ATE 的估计量)

- 有效影响函数 $D^{eff}(V)$ 应达到克拉美-拉奥下界(CRLB)

- ATE 估计的有效影响函数:

- $D^{eff}(V) = \frac{I(T=1) - I(T=0)}{\pi^T(V)} (Y - m_V^T(Y)) + m_V^{T=1}(Y) - m_V^{T=0}(Y) - \gamma(P)$


- 其中, $\pi^T(V)$: 倾向得分, $m_V^T(Y)$: 回归模型

调整特征选择

- 渐近正态性:
 - ✓ $E[D^{eff}(V)] = 0$
 - ✓ $\sqrt{n}(\gamma(\hat{P}) - \gamma(P)) \xrightarrow{d} N(0, \text{Var}[D^{eff}(V)])$
- 我们的目标: 识别能够使渐近方差 $\text{Var}[D^{eff}(V)]$ 最小的调整变量集合 V
- V 的最优性: 当且仅当 $V = \{X, Z\}$ 时, $\text{Var}[D^{eff}(V)]$ 取得最小值
- 目标函数: $R^{OAF}(V) = \text{Var}[D^{eff}(V)]$
- 经验估计量: $\hat{R}^{OAF}(V) = \frac{1}{n} \sum_{i=1}^n \left(\frac{I(t_i=1) - I(t_i=0)}{\pi^{t_i}(v_i)} (y_i - \overline{m^{t_i}(v_i)}) \right)^2$

调整特征选择

- 如何选择最优特征 $V=\{X,Z\}$? 这是一个组合优化问题!
- 基于强化学习的优化方法:
 - 将变量选择建模为一个端到端可微过程
 - 使用掩码进行变量选择



调整特征选择

- 数据集：线性合成数据、非线性合成数据、IHDP、Twins
- 评价指标：
□ 特征选择准确率： $Acc = \frac{|\hat{M} - M_0|_1}{d}$ □ MAE 误差： $\epsilon_{ATE} = |ATE - \widehat{ATE}|$


			Settings		In_sample Prediction			Out_of_sample Prediction		
			Feature Dimension		20	40	80	20	40	80
Dataset	Fs_Acc	R_err	Statistical	Direct	4.69±0.62	7.09±0.68	8.92±0.76	5.23±0.41	6.28±1.41	9.28±1.32
S-20-l	95.0%	0.02		IPW	0.99±4.50	1.27±3.13	4.36±2.37	1.33±1.92	2.22±5.39	4.51±3.33
S-40-l	92.5%	0.04		AIPW	1.32±1.95	0.99±0.27	2.35±0.83	0.21±1.19	0.55±0.47	3.88±1.23
S-80-l	90.0%	0.11		TMLE	0.42±0.11	0.59±0.07	0.62±0.02	0.50±0.12	0.66±0.18	0.81±0.20
S-20-n	95.0%	0.06	Machine	DragonNet	0.19±0.19	0.20±0.14	0.57±0.38	0.99±0.16	0.84±0.70	0.87±1.02
S-40-n	95.0%	0.10		GANITE	0.80±0.01	0.87±0.01	0.99±0.01	0.99±0.01	1.08±0.01	1.10±0.01
S-80-n	90.0%	0.13		DNOUT	0.47±0.01	0.62±0.04	0.92±0.09	0.50±0.02	0.61±0.05	0.95±0.09
IHDP	92.0%	0.11		BART	0.92±0.20	2.03±0.27	2.89±0.98	0.92±0.20	2.25±0.16	2.98±1.10
Twins	94.7%	0.13	Decomposed	AIPW_L	0.59±0.10	0.66±0.05	0.89±0.10	0.54±0.29	0.74±0.13	0.96±0.22
				DVD	0.95±0.03	0.83±0.01	0.76±0.01	1.06±0.08	0.64±0.01	1.05±0.73
				DR-CFR	0.88±0.08	1.18±0.16	2.08±0.69	1.28±0.08	1.69±0.73	1.52±0.51
				TEDVAE	0.37±0.01	0.43±0.02	0.55±0.03	0.38±0.03	0.49±0.04	0.60±0.02
				NICE	1.08±0.32	1.24±0.60	1.81±0.22	1.10±0.37	1.23±0.41	1.93±0.35
			Ours	OAFP_L	0.03±0.13	0.12±0.10	0.23±0.13	0.24±0.22	0.20±0.13	0.32±0.34
				OAFP_N	0.01±0.10	0.09±0.07	0.13±0.11	0.15±0.09	0.16±0.07	0.14±0.08

高维因果推断的总体思路（因果 × 机器学习）

高维因果推断的挑战不是因果定义变了，而是混杂控制与推断在高维下推断不稳定。

因此需要把因果推断的识别与机器学习的高维建模能力结合起来。

- 因果推断负责明确目标参数（ATE/ATT/CATE）、识别假设（混杂控制、重叠等）与推断目标
- 机器学习负责在高维协变量下进行表示、选择、估计（例如控制集、模型的选择）



高维—— p 与 n 的关系

高维的核心是维度 p 与样本量 n 的相对大小

- $p \ll n$ （低维）：传统回归/倾向得分估计相对稳定
- $p \approx n$ （中高维）：估计方差大、对模型设定更敏感
- $p \gg n$ （高维）：无正则化不可识别或过拟合，推断尤其困难

强相关与共线性：变量成簇，信息冗余，系数不稳定

高度敏感：删/加少量变量，估计与权重可能明显变化

在高维设定下，参数估计与效应推断的稳定性显著下降。

高维混杂的三类处理思路

1. 变量选择 (Variable selection)

从高维候选集合中识别用于混杂控制的关键变量

代表方法: LASSO 与后双重选择 (post-double selection)

2. 协变量平衡与加权 (Covariate balancing / weighting)

构造权重或倾向得分, 使处理组与对照组在协变量上尽可能可比

代表方法: 协变量平衡倾向得分 (Covariate Balancing Propensity Score (CBPS)) 与熵平衡 (Entropy Balancing)

3. 正交化推断与双重机器学习 (Orthogonalization / Double Machine Learning)



允许用灵活模型估计倾向得分与结果模型, 同时保持推断有效

代表方法: 正交化估计与交叉拟合的双重机器学习框架 (DML)

变量选择风险：混杂与对撞结构

当 X 高维时，人工筛变量很常见，但在因果中容易系统性引入偏差：如漏控混杂，或控制了不该控的变量。

- 仅根据显著筛选：易漏控混杂
 - 混杂可能主要影响处理分配 T ，在 Y 回归里未必显著。
- 误控变量（bad controls）：控制 collider 或处理后变量会引入偏差
 - collider 打开非因果路径；处理后变量会截断效应路径或引入选择机制。



预测好与推断好

预测误差最小化 $\neq$ 因果效应推断好

- 目标不同：

- 预测：最小化 $E[(Y - \hat{Y})^2]$ 等总体误差

- 因果：估计特定目标量，如 ATE、CATE

- 高维下常用正则化或ML会引入偏差：

收缩（shrinkage）使 $\hat{m}(x) = E[Y | X]$ 、 $\hat{e}(x) = \Pr(T = 1 | X)$ 带系统性误差

- Plug-in风险：偏差会传导到效应估计中


直接把 $\hat{m}, \hat{e}$ 代入（plug-in）得到的处理效应，可能误差会传导到效应估计

因此需要正交化与双重稳健的框架（如 DML），在灵活建模下仍保证推断有效。

前沿进展研究

复杂环境下的因果推断


当研究对象超出独立个体、单次处理、单一人群的经典设定时，因果推断需要在效应定义、识别条件与估计方法上进行结构性扩展，典型包括：干扰或网络效应、纵向动态过程、连续时间事件过程、跨人群外推与可迁移性。



复杂环境 $\Rightarrow$ 效应目标重定义 + 识别与估计策略重构 + 额外结构假设

干扰与网络效应

- 在标准因果推断假设中（SUTVA），通常假定无干扰：个体 i 的潜在结果仅取决于其自身处理 A_i ，而不依赖其他个体的处理分配 A_{-i} 。当该假设不成立时，标准的个体处理效应定义与识别策略将不再适用。
- 许多场景存在溢出效应/相互影响（spillover）：
 - 传染病防控：他人接种/隔离会改变个体感染风险；
 - 教育与同伴效应：同伴激励/学习投入影响个体学习结果；
 - 社交网络广告：邻居曝光影响个体购买或传播；
 - 环境暴露：污染治理或资源分配的外部性影响周边个体。



干扰效应与机制分类

- 仅在存在干扰时，潜在结果写作 $Y_i(a_i, a_{-i})$ ，因此需要区分自身处理变化与他人处理分配变化，常用效应目标包括：
 - 直接效应：固定他人处理分配 a_{-i} ，比较 $Y_i(1, a_{-i})$ 与 $Y_i(0, a_{-i})$ ；
 - 间接/溢出效应：固定自身处理 a_i ，比较 $Y_i(a_i, a_{-i})$ 在不同 a_{-i} 下的差异；
 - 总效应：同时允许 a_i 与 a_{-i} 变化所产生的综合差异；
 - 总体效应：在给定分配机制或政策下，对总体结果的平均影响。
- 干扰的三类机制：
 - 直接干扰：他人处理直接进入 i 的结局机制；
 - 结局传播（contagion）：通过他人结局或状态的传播过程影响 i ；
 - 分配性干扰：处理改变资源、分组、匹配结构，从而间接影响结局。

复杂环境下因果推断

- 复杂数据偏差
- 复杂干预变量
- 高维混杂变量