



浙江大學
ZHEJIANG UNIVERSITY

因果赋能机器学习

3.1 因果稳定学习


因果赋能机器学习——稳定预测

- 预测模型的能和不能

有偏训练数据集



数据驱动
关联学习



重要特征


未知测试数据



为什么会失败？


- 数据的问题：

- 独立同分布假设（但实际应用中常常无法满足）
- 样本选择偏差导致数据分布发生偏移（训练数据和测试数据分布不一致）
- 小样本场景下，该问题更严重
- 但，我们无法控制测试数据的产生



为什么会失败？

- 模型的问题：
 - 关联驱动学习
 - 关联的三种来源：因果，混杂偏差，选择偏差（因果关联和虚假关联）
 - 想法：从复杂关联中甄别因果关联，因果约束实现稳定预测




稳定预测 (Stable Prediction)

- 稳定预测

$$Average_Error = \frac{1}{|\mathcal{E}|} \sum_{e \in \mathcal{E}} Error(D^e), \quad (1)$$


$$Stability_Error = \sqrt{\frac{1}{|\mathcal{E}|-1} \sum_{e \in \mathcal{E}} (Error(D^e) - Average_Error)^2}, \quad (2)$$



面向未知测试数据分布的稳定预测


预测模型为什么不稳定

- 预测 / 分类
 - X : 特征向量; $Y = \{0,1\}$
 - 环境: X 和 Y 的联合分布, 表示为 $P(XY)$
- 假设 $X = \{S, V\}$, 以及 $Y = f(S) + \varepsilon$
 - S : 因果特征集合 (如狗的眼睛, 耳朵等)
 - V : 非因果特征集合 (如草地等背景)
 - $P(Y|S)$ 是稳定不变的, 但 $P(Y|V)$ 会随着环境的变化而变化
- V 和 Y 并不独立 (由于样本选择偏差, 存在虚假相关)
 - 关联学习驱动的方法
 - 一些非因果特征 $v \subseteq V$ 会被学习成很重要的预测特征




因果如何实现稳定预测

- 结果变量产生机制：
 - $Y = f(S) + \varepsilon, X = \{S, V\}$
- 因果变量 S 和非因果变量 V 的区别：
 - S 对 Y 有因果效应,
 - 但, V 对 Y 没有因果效应。
- **想法:** 恢复 X 和 Y 之间的因果关联, 因为只有 S 和 Y 是因果关联的, 这样就可以使得 $V \perp Y$ 。




因果如何实现稳定预测

- 丢弃虚假关联，拥抱因果关联。



典型的关联分析框架



典型的因果推断框架

评估变量 **T** 和结果 **Y** 之间的**关联关系和效应**时，并没有考虑 **X** 和 **T** 之间的关系

评估变量 **T** 和结果 **Y** 之间的**因果关系和效应**时，需要平衡 **X** 的分布
(A/B 测试)

因果约束项及理论保证

- 因果约束项 (近似全局平衡法)

- 学习全局的样本权重 W , 使得变量集合 X 中的任意两个变量都相互独立

$$\sum_{j=1}^p \left\| \frac{X_{:, -j}^T \cdot (W \odot X_{:, j})}{W^T \cdot X_{:, j}} - \frac{X_{:, -j}^T \cdot (W \odot (1 - X_{:, j}))}{W^T \cdot (1 - X_{:, j})} \right\|_2^2, \quad (4)$$



0

PROPOSITION 3.3. If $0 < \hat{P}(X_i = x) < 1$ for all x , where $\hat{P}(X_i = x) = \frac{1}{n} \sum_i \mathbb{I}(X_i = x)$, *there exists a solution W^* satisfies equation (4) equals 0 and variables in X are independent after balancing by W^* .*

因果约束的逻辑斯蒂回归

- 全局平衡回归算法（GBR）

$$\begin{aligned} \min \quad & \sum_{i=1}^n W_i \cdot \log(1 + \exp((1 - 2Y_i) \cdot (X_i \beta))), \\ \text{s.t.} \quad & \sum_{j=1}^p \left\| \frac{X_{:,j}^T \cdot (W \odot X_{:,j})}{W^T \cdot X_{:,j}} - \frac{X_{:,j}^T \cdot (W \odot (1 - X_{:,j}))}{W^T \cdot (1 - X_{:,j})} \right\|_2^2 \leq \lambda_1, \quad W \geq 0, \\ & \|W\|_2^2 \leq \lambda_2, \quad \|\beta\|_2^2 \leq \lambda_3, \quad \|\beta\|_1 \leq \lambda_4, \quad (\sum_{k=1}^n W_k - 1)^2 \leq \lambda_5 \end{aligned} \quad (5)$$

样本加权的逻辑斯蒂损失函数


因果约束项

因果回归系数

- 因果回归系数：可解释且稳定
- 但，局限于线性模型

大数据时代的新挑战

- 数据变量维度高
 - 成千上百的变量
 - 降维
- 非线性
 - 预测变量与结果变量通常是非线性关系
 - 非线性方程拟合
- 深度自编码器



因果约束的深度学习网络

- 深度全局平衡算法 (DGBR)





Figure 2: The framework of our proposed DGBR model.

实验结果及分析

- 仿真实验数据设定：
- 不同的 r 表示不同的数据分布
 - 训练数据集： $r = 0.85$
 - 测试数据集： $r = \{0.1, \dots, 0.9\}$
- LR：逻辑斯蒂回归
- DLR：深度逻辑斯蒂回归
- DBR：全局平衡算法（我们）
- DGBR：深度全局平衡算法（我们）




(f) Trained on $n = 2000$, $p = 20$, $r = 0.85$

实验结果及分析

- 数据来源: *YFCC100M*
- 规模: 10个类别, 每个类别的数据约1000图片
- 数据构建: 针对每个类别 (如 “狗” 的图片), 结合背景构造5个背景标签 (如草地, 水, 车, 地板、雪地)




实验结果及分析




实验结果及分析




(a)



(b)



(c)



(d)




(e)




(f)



(g)




(h)



(i)



(j)



(k)



(l)



(m)



(n)



(o)



(p)

基于样本选择的稳定学习

• 因果约束项 (近似全局平衡法)

- 学习全局的样本权重 W , 使得变量集合 X 中的任意两个变量都相互独立

$$\sum_{j=1}^p \left\| \frac{X_{:, -j}^T \cdot (W \odot X_{:, j})}{W^T \cdot X_{:, j}} - \frac{X_{:, -j}^T \cdot (W \odot (1 - X_{:, j}))}{W^T \cdot (1 - X_{:, j})} \right\|_2^2, \quad (4)$$




Figure 1: A toy example to illustrate the main idea of each deconfounding method.

基于变量去相关的稳定学习

• 因果约束项 (近似全局平衡法)

- 学习全局的样本权重 W , 使得变量集合 X 中的任意两个变量都相互独立

$$\sum_{j=1}^p \left\| \frac{\mathbf{X}_{:, -j}^T \cdot (W \odot \mathbf{X}_{:, j})}{W^T \cdot \mathbf{X}_{:, j}} - \frac{\mathbf{X}_{:, -j}^T \cdot (W \odot (1 - \mathbf{X}_{:, j}))}{W^T \cdot (1 - \mathbf{X}_{:, j})} \right\|_2^2, \quad (4)$$


Variable Decorrelation by Sample Reweighting:

$$\min_W \sum_{j=1}^p \left\| \mathbb{E}[\mathbf{X}_{:, j}^T \Sigma_W \mathbf{X}_{:, -j}] - \mathbb{E}[\mathbf{X}_{:, j}^T W] \mathbb{E}[\mathbf{X}_{:, -j}^T W] \right\|_2^2$$

Decorrelated Weighted Regression:


$$\begin{aligned} & \min_{W, \beta} \sum_{i=1}^n W_i \cdot (Y_i - \mathbf{X}_i \beta)^2 \quad (12) \\ \text{s.t. } & \sum_{j=1}^p \left\| \mathbf{X}_{:, j}^T \Sigma_W \mathbf{X}_{:, -j} / n - \mathbf{X}_{:, j}^T W / n \cdot \mathbf{X}_{:, -j}^T W / n \right\|_2^2 < \lambda_2 \\ & |\beta|_1 < \lambda_1, \quad \frac{1}{n} \sum_{i=1}^n W_i^2 < \lambda_3, \\ & \left(\frac{1}{n} \sum_{i=1}^n W_i - 1 \right)^2 < \lambda_4, \quad W \succeq 0, \end{aligned}$$

Stable Prediction:




Results of Average Error and Stability Error


基于因果特征选择的稳定学习



Theorem 1. Given a causal variable C_0 , observed variables $\mathbf{X}$ and response variable Y , and assuming 1&2, then, for each causal variable $C_i \in \mathbf{C}$, we have $C_i \not\perp\!\!\!\perp C_0 \mid Y$; and for each isolated non-causal variable $I_k \in \mathbf{I}$, we have $I_k \perp\!\!\!\perp C_0 \mid Y$.



(a) Path between C_0 and I_k




(b) Path between C_0 and C_i


基于因果特征选择的稳定学习

Results of precision@k=0.6*p

Dimension	p=10	p=20	p=40	p=80
mRMR	0.500	0.583	0.586	0.598
RF	0.640	0.668	0.594	0.592
LASSO	0.693	0.706	0.622	0.601
PC-simple	0.663	0.636	0.598	0.616
CE	0.643	0.688	0.689	0.665
ICP	-	-	-	-
GBA	0.640	0.660	0.655	0.669
Our+BNCI	0.910	0.827	0.774	0.713
Our+RCIT	<u>0.900</u>	<u>0.820</u>	<u>0.767</u>	<u>0.703</u>



(a) RMSE across testing environments



(b) Average Error (green bar) & Stability Error (black line)

Results of Average Error and Stability Error

因果稳定学习

- 全局平衡回归算法 (GBR)

$$\begin{aligned} \min \quad & \sum_{i=1}^n W_i \cdot \log(1 + \exp((1 - 2Y_i) \cdot (X_i \beta))), \\ \text{s.t.} \quad & \sum_{j=1}^p \left\| \frac{X_{\cdot,-j}^T \cdot (W \odot X_{\cdot,j})}{W^T \cdot X_{\cdot,j}} - \frac{X_{\cdot,-j}^T \cdot (W \odot (1 - X_{\cdot,j}))}{W^T \cdot (1 - X_{\cdot,j})} \right\|_2^2 \leq \lambda_1, \quad W \geq 0, \\ & \|W\|_2^2 \leq \lambda_2, \quad \|\beta\|_2^2 \leq \lambda_3, \quad \|\beta\|_1 \leq \lambda_4, \quad (\sum_{k=1}^n W_k - 1)^2 \leq \lambda_5 \end{aligned} \quad (5)$$

样本文加权的逻辑斯蒂损失函数


因果约束项

因果回归系数

- 因果回归系数：可解释且稳定
- 但，局限于线性模型

How about with unobserved variables?

基于工具变量回归的因果可泛化学习



- Given data from different observed environments $e \in \mathcal{E}$:

$$(X^e, Y^e) \sim F^e, \quad e \in \mathcal{E}$$

- The task is to predict Y given X such that the prediction works well (is “robust”) for “all possible” (including unseen) environments


Domain Generation
Invariant Causal Prediction
Causal Transfer Learning

基于工具变量回归的因果可泛化学习

Data generating process (DGP) assumption for each domain m :

X^m : input features; Y^m : labels;



F^{ivt} : domain-invariant factor; F^m : domain-specific factor; e_x^m, e_y^m : error term.




基于工具变量回归的因果可泛化学习

Assumption 1. Data distributions of different domains satisfy the data generating process and causal graph, where only the factor F^{ivt} and relationship f are invariant across domains.

Theorem 1. For any two domains m and n , if $m \neq n$, then X^n is a valid instrumental variable of domain m .



工具变量



- 工具变量 (Z) 的条件
- 相关性: $P(T|Z) \neq P(T)$
- 排他性: $P(Y|Z, T, U) \neq P(Y|T, U)$
- 无混杂性: $Z \perp U$



两阶段回归 { 第一阶段: 用 Z 去回归 T $\hat{T} = \hat{g}(Z)$
第二阶段: 用 $\hat{T}$ 去回归 Y $\hat{Y} = \hat{f}(\hat{T})$

$$Z \sim \mathcal{N}(0,1)$$

$$U \sim \mathcal{N}(0,1)$$

$$T = Z + U$$

$$Y = f(T) + U$$



• Data $P(T, Y)$

• f
• $\hat{f}^{NN}$
• $\hat{f}^{IV}$

基于工具变量回归的因果可泛化学习

By taking expectation of Y^m conditional on X^n , we have:


$$\begin{aligned}\mathbb{E}[Y^m|X^n] &= \mathbb{E}[f(X^m)|X^n] + \mathbb{E}[F^m|X^n] + \mathbb{E}[e_y^m|X^n] \\ &= \int f(X^m) dP(X^m|X^n)\end{aligned}$$

First stage: estimate $P(X^m|X^n)$

Second stage: use the approximation of $P(X^m|X^n)$ and Y^m to learn invariant function $f(X^m)$



Remark: With IV regression, we only require the label information from one domain




基于工具变量回归的因果可泛化学习

Results on public domain generalization datasets.

RESULTS (%) FOR DOMAIN GENERALIZATION ON OFFICE-HOME DATASET.


Methods	Art	Clipart	Product	Real-World	Average
DeepAll [8]	52.15	45.86	70.86	73.15	60.51
JiGen [8]	53.04	47.51	71.47	72.79	61.20
DSON [44]	59.37	44.70	71.84	74.68	62.90
RSC [16]	58.42	47.90	71.63	74.54	63.12
DRIVE w/o IV	55.53 ± 0.21	45.92 ± 0.50	71.64 ± 0.35	74.49 ± 0.05	61.90 ± 0.20
DRIVE w/o pre	59.30 ± 0.06	47.65 ± 0.30	72.03 ± 0.57	75.55 ± 0.24	63.63 ± 0.11
DRIVE	60.40 ± 0.26	47.73 ± 0.28	72.63 ± 0.18	76.14 ± 0.10	64.23 ± 0.09

Results on biased datasets.



RESULTS (%) FOR DOMAIN GENERALIZATION ON PACS DATASET.

Methods	Art	Cartoon	Photo	Sketch	Average
DeepAll [8]	78.96	72.93	96.28	70.59	79.94
JiGen [8]	79.42	75.25	96.03	71.35	80.51
MASF [10]	80.29	77.17	94.99	71.69	81.04
DGER [61]	80.70	76.40	96.65	71.77	81.38
Epi-FCR [21]	82.1	77.0	93.9	73.0	81.5
MMLD [36]	81.28	77.16	96.09	72.29	81.83
EISNet [49]	81.89	76.44	95.93	74.33	82.15
L2A-OT [63]	83.3	78.2	96.2	73.6	82.8
DDAIG [62]	84.2	78.1	95.3	74.7	83.1
DRIVE w/o IV	79.40 ± 0.10	76.93 ± 0.09	95.75 ± 0.10	74.44 ± 0.07	81.63 ± 0.03
DRIVE w/o pre	81.95 ± 0.25	77.55 ± 0.31	96.64 ± 0.34	75.65 ± 0.10	82.95 ± 0.14
DRIVE	83.36 ± 0.70	78.76 ± 0.08	96.87 ± 0.18	78.68 ± 0.96	84.42 ± 0.11



Junkun Yuan, Xu Ma, Ruoxuan Xiong, Mingming Gong, Fei Wu, Lanfen Lin, Kun Kuang*. Instrumental Variable-Driven Domain Generalization with Unobserved Confounders, TKDD, 2023.

因果启发的可信机器学习（因果赋能机器学习）

发现了通过全局样本赋权实现因果关联挖掘的机制

PROPOSITION 3.3. If $0 < \hat{P}(X_i = x) < 1$ for all x , where $\hat{P}(X_i = x) = \frac{1}{n} \sum_i \mathbb{I}(X_i = x)$, *there exists a solution W^* satisfies equation (4) equals 0 and variables in $\mathbf{X}$ are independent after balancing by W^* .*

$$\sum_{j=1}^p \left\| \frac{X_{i,j}^T \cdot (W \odot X_{i,j})}{W^T \cdot X_{i,j}} - \frac{X_{i,j}^T \cdot (W \odot (1 - X_{i,j}))}{W^T \cdot (1 - X_{i,j})} \right\|_2^2$$

↓
0

存在一组样本权重，使得任意输入变量与其他变量之间相互独立

PROOF. Since $\|\cdot\| \geq 0$, Eq. (8) can be simplified to $\forall j, \forall k \neq j$

$$\lim_{n \rightarrow \infty} \left(\frac{\sum_i X_{i,k} \cdot 1 \cdot X_{i,j} \cdot 1 \cdot W_i}{\sum_i X_{i,k} \cdot 1 \cdot W_i} - \frac{\sum_i X_{i,k} \cdot 1 \cdot X_{i,j} \cdot 0 \cdot W_i}{\sum_i X_{i,k} \cdot 1 \cdot W_i} \right) = 0$$

with probability 1. For W^* , from Lemma 3.1, $0 < P(X_i = x) < 1$, $\forall x, \forall i, t = 1$ or 0 ,

$$\begin{aligned} \lim_{n \rightarrow \infty} \frac{1}{n} \sum_i X_{i,j} \cdot t \cdot W_i^* &= \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{x: x_j=t} \sum_i X_{i,j} \cdot x \cdot W_i^* \\ &= \lim_{n \rightarrow \infty} \sum_{x: x_j=t} \frac{1}{n} \sum_i X_{i,j} \cdot x \cdot \frac{1}{P(X_i=x)} \\ &= \lim_{n \rightarrow \infty} \sum_{x: x_j=t} P(X_i=x) \cdot \frac{1}{P(X_i=x)} = 2^{p-1} \end{aligned}$$

with probability 1 (Law of Large Number). Since features are binary,

$$\begin{aligned} \lim_{n \rightarrow \infty} \frac{1}{n} \sum_i X_{i,k} \cdot 1 \cdot X_{i,j} \cdot 1 \cdot W_i^* &= 2^{p-2} \\ \lim_{n \rightarrow \infty} \frac{1}{n} \sum_i X_{i,k} \cdot 1 \cdot X_{i,j} \cdot 0 \cdot W_i^* &= 2^{p-2} \end{aligned}$$

and therefore, we have following equation with probability 1:

$$\lim_{n \rightarrow \infty} \left(\frac{X_{i,k}^T \cdot (W^* \odot X_{i,j})}{W^{*T} \cdot X_{i,j}} - \frac{X_{i,k}^T \cdot (W^* \odot (1 - X_{i,j}))}{W^{*T} \cdot (1 - X_{i,j})} \right) = \frac{2^{p-2}}{2^{p-1}} - \frac{2^{p-2}}{2^{p-1}} = 0. \quad \square$$

有效提升机器学习模型的可解释性和稳定性

样本重采样因果恢复模型






Figure 1: A toy example to illustrate the main idea of each deconfounding method.

因果特征选择解耦模型




因果约束的深度学习模型




因果推理应用1

- **因果干预模型**赋能**多模态数据表征学习**，应用于电商短视频推荐
- 问题：多模态数据表征学习
- 挑战：数据偏差导致文本特征与视觉特征虚假相关
- 方法：因果去偏差指导表征学习




因果干预
(do算子)





$$P(\text{衬衫} | \text{乐器}) = 5.98\%$$

$$P(\text{衬衫} | \text{do}(\text{乐器})) = 3.10\%$$




因果推理应用2

- 因果反事实+视觉知识赋能机器学习可解释
- 问题：机器学习中模型可解释性，为什么图中场景是在“打篮球”
- 挑战：虚假相关、如何从像素级别解释到视觉概念级别解释
- 方法：视觉知识+因果反事实推理





因果推理应用3

- 因果反事实赋能智能司法，实现法律文本生成
- 问题：法律裁判文书中“本院认为”生成
- 挑战：数据偏差/虚假关联（胜率高的案件才会起诉）
- 方法：因果反事实推理赋能文本生成





因果推理应用4


- **因果特征选择**，实现**面向未知环境的稳定预测**
- 背景：传统方法是关联驱动，存在虚假关联
 - 训练图片中多数狗在草地上，草地与狗虚假相关
- 草地预测狗：不可解释，不稳定等
- 方法：区分因果特征和非因果特征



因果特征：狗眼睛、耳朵等
非因果特征：草地、背景等



(a) Path between C_0 and I_k



(b) Path between C_0 and C_i

Theorem 1. Given a causal variable C_0 , observed variables X and response variable Y , and assuming 1&2, then, for each causal variable $C_i \in \mathbf{C}$, we have $C_i \not\perp\!\!\!\perp C_0 \mid Y$; and for each isolated non-causal variable $I_k \in \mathbf{I}$, we have $I_k \perp\!\!\!\perp C_0 \mid Y$.

因果特征选择理论保证


Kuang K, Li B, et al. Stable Prediction via Leveraging Seed Variable[J]. TKDE, 2022.

Liu J, Shen Z, et al. Invariant Adversarial Learning for Distributional Robustness[C]. AAAI, 2021.

Kuang K, Xiong R, et al. Stable prediction with model misspecification and agnostic distribution shift[C]//AAAI, 2020.

因果推理应用5

- 因果反事实推理赋能多智能体强化学习信度分配
- 问题：多智能体强化学习中，如何计算每个智能体对团体的贡献？
- 方法：提出因果沙普利值，通过因果反事实推理计算智能体贡献
 - 当某个智能体不参与团队合作，团队收益的减少量作为其对团队的贡献



Map	Methods													
	VDN		QMIX		QTRAN		COMA		QPD		SQDDPG		OURS	
	$\tilde{m}$	avg	$\tilde{m}$	avg	$\tilde{m}$	avg	$\tilde{m}$	avg	$\tilde{m}$	avg	$\tilde{m}$	avg	$\tilde{m}$	avg
3m	100	100	100	100	100	100	95	96	99	99	64	65	99	99
8m	100	100	100	100	100	100	100	100	95	95	92	90	98	97
2s3z	100	100	100	100	92	91	45	45	99	98	60	55	100	100
1c3s5z	88	85	95	90	40	41	15	15	77	72	2	2	61	60
3s5z	80	69	80	67	12	13	5	3	79	80	1	1	92	90
3s5z_vs_3s6z	0	0	0	0	0	0	0	0	3	5	0	0	20	20

因果机器学习应用6

因果混淆机制赋能数据隐私保护









Figure 2: Introducing confounders in ImageNet25 by class-wise patches.





因果机器学习应用7




因果+多智能体强化学习




因果+元学习



因果机器学习应用8（因果图神经网络）



(a) Decorrelation in Causal View





(b) GNN-DVD Framework

Zhu D, Wang D, Kuang K*, et al. Graph Neural Network with Two Uplift Estimators for Label-Scarcity Individual Uplift Modeling, The WebConf, 2023.

Shaohua Fan, Xiao Wang, Chuan Shi, **Kun Kuang**, et.al. Debiased Graph Neural Networks with Agnostic Label Selection Bias. TNNLS 2022.

Zhengyu Cheng, Teng Xiao, Kun Kuang*. BA-GNN: On Learning Bias-Aware Graph Neural Network, ICDE, 2022.

因果启发的可信机器学习（因果赋能机器学习）



3.2 因果表征学习


目录 Overview

- 1、引言：深度学习与因果推断的鸿沟
- 2、IID环境下的因果表征学习
- 3、多分布环境下的因果表征学习
- 4、时序环境下的因果表征学习
- 5、因果抽象与多模态
- 6、总结与展望

引言：深度学习与因果推断的鸿沟

1.2 传统表征学习的局限性

- 传统的机器学习，特别是深度学习中的无监督学习，主要致力于“表征学习”（Representation Learning）。其目标是通过自编码器（Autoencoder, AE）或生成对抗网络（GAN）等架构，将高维数据 X 映射到一个低维的潜在空间 Z 。
- 传统的表征学习主要关注的是**数据重构能力**或**统计相关性**而非**因果机制**。这导致学习到的表征往往是“**纠缠**”的。




1.2 传统表征学习的局限性

- **案例：** 人脸数据中，如果大部分女性样本都化了妆，男性没有化妆，“性别”往往与“妆容”纠缠。
- **结果：** 当我们试图在潜在空间中干预“性别”时，“妆容”也会随之改变。
- **缺陷：** 缺乏可解释性，分布外 (OOD) 泛化能力差。

1.3 什么是因果表征学习 (CRL)?

- **基本想法**: 真实世界的观察变量往往不直接表征因果关系, 而是由背后的因果潜变量去构建因果关系
- **核心目标**: 从高维观测数据 X 中恢复低维潜在变量 Z
- **关键要求: 可识别性 (Identifiability)**
 - 学习到的表征 Z 应在某种变换下等价于真实的因果变量
 - 同时发现 Z 之间的因果结构 S
- **数学表达**
 - 生成过程: $X = g(S)$
 - 逆向求解: $S = g^{-1}(X)$



1.4 不同场景/假设下的因果表征学习

- **IID 环境 (独立同分布)**

- 最难场景，无辅助信息。
- 算法依赖：数据的非高斯性、秩亏、稀疏性。

- **多分布环境 (Multiple Distributions)**

- 引入环境/领域标签。
- 算法依赖：数据本身的分布变化 (Distribution Shift)。

- **时序环境 (Temporal)**

- 时间提供自然因果顺序。
- 算法依赖：非平稳性、动力学演化。


IID 条件下的因果表征学习

2. IID 条件下的因果表征学习

- 在独立同分布 (Independent and Identically Distributed, IID) 的数据环境中, 所有的样本都来自同一个联合分布 $P(X)$ 。
- 在这种设定下, 我们没有任何先验辅助信息, 因此必须对数据生成过程 (Data Generating Process) 施加结构性或参数性假设, 以实现潜在变量的可识别性。
- 主要的假设及其对应的方法如下:
 - **线性高斯情形**
 - Tetrad condition/Rank deficiency-based method
 - **线性非高斯情形**
 - GIN-based method
 - **非线性情形**
 - Sparsity假设

2.1 线性高斯模型与Tetrad条件（秩亏条件）

- 最简单的因果表征模型是**线性高斯潜变量模型**。
- 假设假设我们观测到的一组变量 $X = \{X_1, X_2, \dots, X_m\}$ 是由一组未知的潜在变量 $L = \{L_1, L_2, \dots, L_k\}$ 线性生成的, 且 $k < m$ 。这种结构通常被称为测量模型 (Measurement Model) 。
- **关键问题**: 如何仅通过 X 确认潜变量 L 的存在?



$$\begin{aligned} X_1 &= \lambda_1 L + \varepsilon_1 \\ X_2 &= \lambda_2 L + \varepsilon_2 \\ X_3 &= \lambda_3 L + \varepsilon_3 \\ X_4 &= \lambda_4 L + \varepsilon_4 \end{aligned}$$

2.1.1 Tetrad条件

考虑一个最简单的**单因子模型**情形，即如图情况。


此时我们可以计算任意两个观测变量 X_i 和 X_j ($i \neq j$) 之间的协方差 σ_{ij} ：

$$\sigma_{ij} = \text{Cov}(X_i, X_j) = \text{Cov}(\lambda_i L + \epsilon_i, \lambda_j L + \epsilon_j)$$

由于误差项之间相互独立且与 L 独立，展开后交叉项为零，我们得到：

$$\sigma_{ij} = \lambda_i \lambda_j \text{Var}(L)$$

令 $\sigma_L^2 = \text{Var}(L)$ ，则有 $\sigma_{ij} = \lambda_i \lambda_j \sigma_L^2$ 。



$$X_1 = \lambda_1 L + \epsilon_1$$

$$X_2 = \lambda_2 L + \epsilon_2$$

$$X_3 = \lambda_3 L + \epsilon_3$$

$$X_4 = \lambda_4 L + \epsilon_4$$

2.1.1 Tetrad条件


$$\sigma_{12}\sigma_{34} = (\lambda_1\lambda_2\sigma_L^2)(\lambda_3\lambda_4\sigma_L^2) = \lambda_1\lambda_2\lambda_3\lambda_4\sigma_L^4$$

$$\sigma_{13}\sigma_{24} = (\lambda_1\lambda_3\sigma_L^2)(\lambda_2\lambda_4\sigma_L^2) = \lambda_1\lambda_3\lambda_2\lambda_4\sigma_L^4$$

$$\sigma_{14}\sigma_{23} = (\lambda_1\lambda_4\sigma_L^2)(\lambda_2\lambda_3\sigma_L^2) = \lambda_1\lambda_4\lambda_2\lambda_3\sigma_L^4$$

显然，这三者相等。这就是著名的 Tetrad 等式约束：

$$\sigma_{12}\sigma_{34} = \sigma_{13}\sigma_{24} = \sigma_{14}\sigma_{23}$$



$$X_1 = \lambda_1 L + \varepsilon_1$$


$$X_2 = \lambda_2 L + \varepsilon_2$$

$$X_3 = \lambda_3 L + \varepsilon_3$$

$$X_4 = \lambda_4 L + \varepsilon_4$$

2.1.1 Tetrad条件


如果 $\sigma_{12}\sigma_{34} = \sigma_{13}\sigma_{24} = \sigma_{14}\sigma_{23}$, 那么四个变量 X_1, X_2, X_3, X_4 之间只有一个共同的潜在因果节点, 否则, 不止一个。



$$\rho_{12}\rho_{34} \neq \rho_{23}\rho_{14}$$

$$\rho_{13}\rho_{24} = \rho_{23}\rho_{14}$$

$$\rho_{12}\rho_{34} \neq \rho_{13}\rho_{24}$$



$$\rho_{12}\rho_{34} = \rho_{23}\rho_{14}$$

$$\rho_{13}\rho_{24} = \rho_{23}\rho_{14}$$

$$\rho_{12}\rho_{34} = \rho_{13}\rho_{24}$$


ρ_{ij} denotes the correlation coefficient between x_i and x_j

2.2 线性非高斯模型与广义独立噪声 (GIN) 条件

- 当数据生成机制是线性但噪声服从**非高斯分布 (Non-Gaussian)** 时，我们可以获得比高斯情况更强的可识别性。
- **LiNGAM** 算法，利用非高斯性来确定观测变量间的因果方向。
- 对于含有潜在变量的系统，**广义独立噪声 (Generalized Independent Noise, GIN) 条件**成为了核心工具。
- GIN 条件的核心思想是**寻找观测变量的特定线性组合，使得该组合后的残差独立于某些其他变量，从而消去潜在混淆因子的影响。**

2.2.1 广义独立噪声 (GIN) 条件

定义: (GIN 条件): 令 Y 和 Z 为两个观测变量向量。如果存在一个非零向量 w , 使得线性组合 $E = w^T Y$ 与 Z 统计独立, 即 $w^T Y \perp\!\!\!\perp Z$ 。则称 (Z, Y) 满足广义独立噪声 (GIN) 条件。



X_i : observed variables
 L_i : latent variables

2.2.1 广义独立噪声 (GIN) 条件

定义: (GIN 条件): 令 Y 和 Z 为两个观测变量向量。如果存在一个非零向量 w , 使得线性组合 $E = w^T Y$ 与 Z 统计独立, 即 $w^T Y \perp\!\!\!\perp Z$ 。则称 (Z, Y) 满足广义独立噪声 (GIN) 条件。

上述定义的直观推导如下:

考虑一个简单的因果结构: 潜在变量 L_1 导致了观测变量 X_1, X_2 , 同时 L_1 也是另一个潜在变量 L_2 的原因, 而 L_2 导致了观测变量 X_3, X_4 。

结构方程如下:

$$\begin{aligned}X_1 &= c_1 L_1 + \epsilon_1 \\X_2 &= c_2 L_1 + \epsilon_2 \\L_2 &= a L_1 + \epsilon_{L2} \\X_3 &= c_3 L_2 + \epsilon_3 = c_3 (a L_1 + \epsilon_{L2}) + \epsilon_3\end{aligned}$$

2.2.1 广义独立噪声 (GIN) 条件

结构方程如下：

$$X_1 = c_1 L_1 + \epsilon_1$$

$$X_2 = c_2 L_1 + \epsilon_2$$

$$L_2 = a L_1 + \epsilon_{L2}$$

$$X_3 = c_3 L_2 + \epsilon_3 = c_3(a L_1 + \epsilon_{L2}) + \epsilon_3$$


- 考虑 X_1 和 X_2 。由于它们都由 L_1 线性生成，我们可以找到一个线性组合来消去 L_1 。令：

$$R = c_2 X_1 - c_1 X_2 = c_2(c_1 L_1 + \epsilon_1) - c_1(c_2 L_1 + \epsilon_2) = c_2 \epsilon_1 - c_1 \epsilon_2$$

- 残差 R 仅由 X_1 和 X_2 的私有噪声组成，因此它独立于 L_1 ，也就独立于 L_1 的其他后代（如 X_3, X_4 ）。
- 结论：**如果我们发现存在一个线性组合 $w_1 X_1 + w_2 X_2$ 独立于 X_3 ，这暗示了 X_1, X_2 拥有一个共同的、未被 X_3 包含的因果源头。


2.3 非线性模型与结构稀疏性

- 当生成函数 g 是非线性的（例如多层神经网络）时，IID 数据的可识别性变得极具挑战性。**没有任何约束的非线性 ICA 是不可识别的**，因为存在无穷多保体积变换可以将潜在变量混合成任意分布（即存在无穷多解）。
- Zheng et al. (2022) 证明了，**如果生成过程满足结构稀疏性 (Structural Sparsity)，我们仍然可以实现可识别性。**
- 结构稀疏性假设：**对于每一个潜在变量 s_i ，存在一组观测变量，使得这些观测变量的“因果父节点交集”仅包含 s_i 。
- 不存在潜变量 s_i 和 s_j ，使得 s_i 和 s_j 的子节点相同(或者一方子节点完全被包含于另一方)



2.3 非线性模型与结构稀疏性


- **结构稀疏性假设：**对于每一个潜在变量 S_i ，存在一组观测变量，使得这些观测变量的“因果父节点交集”仅包含 S_i 。
- **如图所示：**
 - 潜在变量 S_1 影响观测变量集合 $\mathbf{X}_{S_1} = \{X_1, X_4\}$ 。
 - 潜在变量 S_5 影响观测变量集合 $\mathbf{X}_{S_5} = \{X_1, X_3, X_5\}$ 。
 - 虽然 X_1 同时受 S_1, S_5 影响（纠缠），但 X_3 和 X_5 可能主要受 S_5 影响。通过分析这种依赖关系的稀疏模式（哪些变量组之间存在强依赖，哪些是独立的），我们可以逆向解析出 S_1 和 S_5 。



多分布环境下的因果表征学习

3.1 多分布条件下的因果表征学习

- 当我们跳出单一分布的限制，利用数据的**异质性 (Heterogeneity)** 或**非平稳性 (Non-stationarity)** 时，因果表征的可识别性将得到显著增强。不同环境、不同领域或不同干预下的数据分布变化，往往蕴含了因果机制的关键信息。
- **核心思想**：数据分布的变化 (Distribution Shift) 蕴含因果信息。
- **核心方法**：引入辅助变量 u ，来代表领域索引、时间段、实验条件等。
- **直觉**：因果机制是不变的，但数据分布随环境变化




多分布与分布变化

$$X \longrightarrow Y$$


不变的因果机制
(Invariant Causal Mechanism)

3.1 塞麦尔维斯与产褥热：分布变化带来的启示

- 在19世纪中叶的维也纳总医院，一位医生塞麦尔维斯注意到两个产科诊所的**产妇死亡率**存在显著差异：
- **第一诊所（医生教学）**：死亡率极高（约10%）。
- **第二诊所（助产士教学）**：死亡率较低（约4%）。
- 这就构成了两个不同的“分布”（Domain 1 和 Domain 2）。塞麦尔维斯并没有停留在观察相关性上，他利用这种分布的变化（Distribution Shift）进行了推理。
- 他观察到，唯一的显著区别在于第一诊所的医生经常在解剖尸体后直接去接生。这实际上是一个“自然实验”或“干预”。
- 当他在第一诊所引入“氯水洗手”这一干预措施后，第一诊所的死亡率迅速下降，分布发生了剧烈变化，与第二诊所趋同。



Ignaz Semmelweis (1818–1865)




3.1 塞麦尔维斯与产褥热：分布变化带来的启示

这个故事揭示了因果表征学习在多分布环境下的核心逻辑：

(1) 独立因果机制 (ICM) 原则：世界是由多个相对独立的因果机制组成的（如解剖尸体操作、细菌传播、产褥热发病）。

(2) 稀疏变化 (Sparse/Minimal Changes) 原则：当环境从第一诊所切换到第二诊所（或引入洗手干预）时，并不是所有的物理规律都变了，只有少数几个机制（如“细菌传播概率”）发生了改变。




3.3 生成式AI与图像翻译：最小变化带来的可控性

- **问题：**传统的GAN（如CycleGAN）在进行图像翻译时，往往难以控制变化范围，经常错误的改变背景颜色（比如马 → 斑马）。
- Xie et al. (2023) 将Causal Representation Learning引入该领域，提出了基于稀疏变化的图像生成方法。
- **核心思想：**当我们把一张人脸图像从“年轻”域翻译到“年老”域时，理想情况下，只有与“年龄”相关的潜在因子（ Z_{age} ）应该发生变化，而“性别”、“种族”、“背景”等因子（ Z_{other} ）应保持不变。这对应于因果图中的软干预（Soft Intervention）。
- **实际实现：**引入正则化项 $||\Delta Z||_0$ ，最终优化目标变为： $\min \{\mathcal{L}_{recon} + \lambda ||\Delta Z||_0\}$ ，其中 $||\Delta Z||_0$ 鼓励变化的稀疏性。

3.3 生成式AI与图像翻译：最小变化带来的可控性

- **实验效果：**

- **季节迁移：** 将夏季风景照转换为冬季。传统方法可能会把天空颜色变得灰暗诡异。CRL方法仅将绿叶变为白雪，保留了天空的湛蓝和建筑的细节。
- **人脸编辑：** 在CelebA5数据集上，当要求模型“添加胡子”时，模型能够精确定位到控制胡须的潜在变量，而不改变性别特征。



3.4 文本到图像生成中的原子概念学习

- 在文本到图像 (Text-to-Image) 生成中, 文本提示词 (Text Prompts) 与图像特征之间的映射往往是多对多的纠缠关系。
- Xie, Kong, et al. (2024) 提出了学习原子概念 (Atomic Concepts) 的方法。
- 文本中的一个原子概念 (如 “红色”、 “圆桌”) 应该稀疏地影响图像中的潜在变量。
- **实际实现:** 惩罚文本概念嵌入 (Text Embeddings) 与图像潜在变量之间的稠密连接矩阵, 迫使模型学习到一一对应的因果映射。

3.4 文本到图像生成中的原子概念学习

- 实验效果: **ConceptAligner** 实现了比其他方法更强的可控性

A woman in a black and white striped shirt has her arm reaching out.

A woman in a **red and white** striped shirt has her arm reaching out.


FLUX-D



SANA



ConceptAligner



3.4 文本到图像生成中的原子概念学习

- 实验效果: **ConceptAligner** 实现了比其他方法更强的可控性

A cartoon panda eating bamboo.

A cartoon panda eating bamboo, **flowers around**, **butterflies around**.

SANA



ConceptAligner



3.4 文本到图像生成中的原子概念学习

- 实验效果: **ConceptAligner** 实现了比其他方法更强的可控性

SANA



SANA-Finetune

A dog is **jumping**.
A dog is **sleeping**.




ConceptAligner



时序数据下的因果表征学习

4 时序数据下的因果表征学习

- **因果性基本原则：因先于果 (Temporal Precedence)。**
- 时间是最自然的因果监督信号。在时序数据中，我们可以利用时间顺序和动力学演化来实现因果表征学习。
- **核心逻辑：**过去的状态解释现在的观测，利用时间结构打破旋转对称性。




4.1 经典概念：格兰杰因果 (Granger Causality)

- **定义**：如果在给定过去信息的情况下，变量 X 能改善对 Y 的预测，则称 X Granger cause Y 。即：若 $P(Y_{t+1} \in A \mid \Omega_t) \neq P(Y_{t+1} \in A \mid \Omega_t \setminus X_{\{past\}})$ ，则称 X Granger cause Y 。
- **Granger Causality 两原则**：
 1. 未来不能导致过去；
 2. 原因包含关于结果的唯一信息。
- 传统的 Granger 因果通常**直接作用于观测变量**。在 Causal Representation Learning 中，我们假设观测到的时间序列 x_t 是由潜在的因果过程 z_t 生成的，我们的目标是发现 z_t 及其动力学关系。

4.1 经典概念：格兰杰因果 (Granger Causality)

- **特别注意：Granger 因果名为“因果”，实为“预测”。**
- 本质上是时间上的先后相关性，而非物理上的作用机制。其最大的局限在于无法排除**共同原因 (Confounder)** 的干扰。
- 气压计读数下降通常发生在下雨之前。根据定义，气压计读数能提升对下雨的预测，因此气压计是下雨的“Granger Cause”。但显然，打碎气压计并不能阻止下雨。
- **真实原因：** 低压天气系统同时导致了气压计读数的下降和下雨



气压计例子中的格兰杰因果与真实因果的区别


4.2 时序解纠缠表征学习 (TDRL)

- 在处理平稳的时间序列数据时，我们面临的一个核心问题是：**如何利用时间信息来辅助因果发现？**
- 核心思想：**将“历史”作为隐式的“域”标签，利用这种时间上的依赖关系来约束表征学习的过程。
- 模型假设：**
 - (1) 潜在状态的演化 (Transition Dynamics)：潜在的因果变量 z_t 遵循某种物理规律或动力学方程，由上一时刻的状态 z_{t-1} 演变而来。数学上表示为：
$$z_t = f_{\text{trans}}(z_{t-1}) + \epsilon_t$$
其中 f_{trans} 是描述系统演化的非线性函数， ϵ_t 是噪声。
 - (2) 观测值的生成 (Observation Mixing)：我们实际看到的复杂数据 x_t （如视频像素），是这些潜在状态经过一个非线性混合函数 g 变换后的结果：

$$x_t = g(z_t)$$

4.2 时序解纠缠表征学习 (TDRL)


- 考虑一个物理仿真视频，其中有5个质点通过不可见的弹簧连接并在平面上运动。
- 观测数据**：质点的像素坐标视频流
- 潜在变量**：每个质点的位置 (p_x, p_y) 和动量 (v_x, v_y) 。
- 学习目标**：无监督地发现位置、动量等物理变量并恢复质点间的相互作用网络。
- TDRL能够从视频中无监督地学习到10个潜在变量（5个质点 $\times$ 2个坐标），并且准确恢复出它们之间的相互作用网络（即哪些质点之间有弹簧连接）。
- 这证明了 Causal Representation Learning 能够从视觉观测中“重新发现”物理定律。



因果抽象与多模态


5.1 因果抽象 (Causal Abstraction)

- 因果表征学习的一个深层哲学问题是：什么样的表征是“正确”的？



5.1.1 案例：姆佩巴效应 (Mpemba Effect)

- **姆佩巴效应**：在特定条件下，热水结冰的速度比冷水快。
- **错误的因果表征**：平均温度
 - **错误推断**：热水要先降温到冷水，再从冷水降温结冰，因此热水结冰的速度要比冷水慢。
- **正确的因果表征**：平均温度，对流速率
 - **正确推断**：热水内部存在温度梯度，引发强对流，加速冷却，最终导致热水结冰更快。





5.1.2 姆佩巴效应对因果表征学习的启示

- 这个案例对因果表征学习的启示有两点：
 - **表征 $\neq$ 压缩**：好的因果表征（Representation）不能只是数据的压缩，必须保留能决定系统未来演化的因果机制。
 - **警惕“过简化”**：在这个案例中，正确的宏观表征不应只有温度，而应该是温度，对流速率。
 - 现有的深度学习范畴下的因果表征学习较为依赖**稀疏性假设**，但是过度稀疏就永远无法学会正确的因果结构。

5.2 多模态因果学习与结构稀疏性

- 多模态数据的异质性能为因果识别提供极强的约束。
- 一个医疗数据集，包含眼底图像 (Modality 1)、睡眠监测数据 (Modality 2) 和人体测量学数据 (Modality 3)。
 - “糖尿病”**：同时影响眼底图像 (视网膜病变) 和生化指标，但对睡眠数据的直接影响较小。
 - “睡眠呼吸暂停”**：强烈影响睡眠数据，但对眼底图像影响较小。
- 通过联合建模多模态数据，可以利用一个模态的信息来消除另一个模态中的不确定性 (例如，利用生化指标作为“锚点”来解耦眼底图像中的病理特征)。



3.4 因果与推荐


推荐系统中的因果问题

推荐系统旨在根据用户的历史行为预测其偏好。

传统方法：假设数据独立同分布，仅拟合统计关联。

实际情况：数据生成过程存在因果机制，导致模型在面对偏差、数据缺失以及环境变化时表现不佳

核心目标：在观测分布偏离真实偏好时，依然能够做出正确预测。



数据偏见

数据偏见是指数据生成过程受到多种混杂因素的干扰，导致观测分布与真实的偏好分布存在显著差异。

形式化地，设 U 为用户集合， I 为物品集合。对于用户 u 和物品 i ， $Y_{(u,i)}$ 表示用户对物品的真实偏好，而 $O_{(u,i)}$ 为二值指示变量，表示该交互是否被观测到。

数据偏差一般分为选择偏差，一致性偏差和曝光偏差

选择偏差： 选择偏差源于用户可以自由选择评价哪些物品。用户倾向于对自己感兴趣的物品进行评分，而忽略不感兴趣的物品。这导致观测到的评分数据并非全体物品的随机样本，而是非随机缺失。可以用如下条件概率不等式表示：

$$P(O_{(u,i)} = 1 | Y_{(u,i)}) \neq P(O_{(u,i)} = 1)$$

数据偏见

一致性偏差：一致性偏差描述了用户的公开行为受到社会群体影响的现象。在社交网络或公开评分平台上，用户的观测评分 $Y_{u,i}^{obs}$ 往往不完全等同于其内心的真实偏好 $Y_{u,i}^{true}$ ，而是倾向于与群体平均观点保持一致。我们可以将观测评分建模为真实偏好与社会影响 S_i 的函数：

$$Y_{u,i}^{obs} = f(Y_{u,i}^{true}, S_i) + \varepsilon$$

这种偏差掩盖了用户的个性化需求，使得模型趋向于推荐符合大众口味但缺乏个性化的热门物品。

曝光偏差：在隐式反馈数据中，未交互具有二义性。它可能源于用户不喜欢该物品，也可能源于用户根本没有看到该物品。由于推荐系统的展示机制，只有极少部分的物品会曝光给用户。若令 $A_{u,i}$ 表示观测到的交互行为，我们可以将其分解为曝光变量 $E_{u,i}$ 和相关性变量 $R_{u,i}$ 的乘积：

$$A_{u,i} = E_{u,i} \cdot R_{u,i} \quad \text{我们无法确定是因为未曝光 (E=0) 还是不感兴趣 (R=0)}$$

数据缺失与噪声

1. 非随机缺失与数据稀疏性

推荐系统的数据矩阵通常具有极高的稀疏度，即绝大多数的用户-物品对未发生交互。这种缺失并非完全随机，而是非随机缺失。形式化地，缺失数据本身蕴含了丰富的信息。

2. 隐式反馈中的噪声

在推荐系统中，显式反馈稀缺，模型主要依赖点击、浏览等隐式反馈。然而，隐式反馈中存在显著的噪声，导致观测到的交互行为 $A_{u,i}$ 与用户的真实意图 $Y_{u,i}$ 之间存在语义鸿沟。


解决方案：

构建结构因果模型，将观测数据分解为“因果特征”和“环境噪声”。通过干预或反事实推断，模型可以尝试识别并剔除由环境噪声导致的虚假相关性，从而在嘈杂的观测数据中还原用户的真实意图。

因果推断与公平性

推荐系统中的不公平性通常根源于偏见和歧视，它们往往难以完全避免，因为现实世界的数据本身就是不完美的。在推荐系统中的不公平性一般是由于数据中存在偏见和推荐算法存在偏差所引起的。当用于训练推荐算法的数据集本身带有结构性缺陷时，就会产生数据偏见。算法本身的设计或工作方式可能加剧或放大数据中已有的偏见。

右图直观展示了推荐系统中普遍存在的选择偏差。右侧描绘了系统的物品选择过程，即推荐系统倾向于只向用户推荐预测评分较高的电影，从而过滤掉了低分电影；左侧则描绘了用户的自选择行为，即用户倾向于只对自己喜欢的电影进行打分，而忽略不喜欢的。



因果公平

研究因果推断与公平性就需要先定义因果实质公平。

定义：如果我们在“平行世界”改变敏感属性，推荐结果保持不变。

$$P(L_{z'} \mid X = x, z = z) = P(L_{z'} \mid X = x, z = z')$$

即在事实 $z = z$ 和反事实 $z = z'$ 世界下，推荐列表结果 L 的概率是相等的。此定义确保敏感属性不会对推荐列表产生直接或间接不公平的间接影响。

逆倾向评分

推荐系统中的偏见是造成不公平的主要原因。逆倾向评分方法利用因果方法在数学上对数据进行“重加权”，以消除这种偏见，使数据看起来像是来自一个公平、随机的实验。

逆倾向评分的目标是解决由非随机分配的处理引起的偏见。

1. 识别偏见：一个常见的问题是流行度偏差，这会导致商品端的不公平，即热门商品获得的曝光机会超过了其应得的水平。
2. 使用倾向性得分：倾向性得分是数据中观察到特定商品或用户交互的概率。而逆倾向就是倾向性得分的倒数。通过将逆倾向作为每个数据样本的权重，可以对稀有、意外的观察结果赋予高权重，使整体数据分布得以平衡，从而消除了偏见。

结构因果模型

结构因果模型包含因果图和结构方程。因果图捕捉变量之间的直接因果关系，而结构方程组则构建变量之间的定量关系。在获取结构方程基础上，就可以通过简单地将变量的原始值替换为想要检验的值来计算反事实的结果，从而对模型进行干预。

Kilbertus 等人在确定结构方程模型的情况下，可以通过干预、代换、约束与优化四个步骤消除歧视。

干预指的是需要在因果图中对涉及歧视的变量实施“干预”，即切断该变量的所有父节点连接并将其强制设定为特定值。

代换则是利用结构方程进行迭代代换，将预测器函数完全表示为干预后图中根节点的函数。

约束则是施加数学约束，要求预测器的分布在针对该变量的不同干预值下保持不变，即不管 p 为何值，对最终的结果都没有因果上的影响。

因果推断与推荐系统可解释性

打破“黑箱”证明可信决策的必要性

建立用户信任

透明的推荐逻辑能显著提升用户的购买意愿和满意度。

高风险领域合规

金融、医疗等领域需要合理解释以规避法律和安全风险。

因果归因

揭示驱动推荐结果的核心行为路径，而非单纯复述共现频率。

推荐系统本质上是一种辅助决策工具，其目标不仅是提供精准的结果，还在于建立用户信任并辅助用户进行理性判断。


反事实推理

为了打破“黑箱”壁垒，反事实推理被引入推荐系统领域，作为生成解释的一种核心方法。反事实推理旨在探讨“如果前提条件发生改变，结果会有何不同”。在机器学习解释中，这转化为寻找输入特征空间中的最小扰动，使得模型的预测结果发生特定改变。这些被改变的输入特征集合，即构成了对模型决策的直观解释。这种方法通过识别导致特定推荐结果的关键影响因子，向用户揭示了推荐背后的因果逻辑，从而有效地实现了推荐系统的可解释性。

Tan 等人提出了一个用于生成特征级解释的反事实解释框架。该框架引入了两个新概念：解释复杂度和解释强度。这两个概念用于构建反事实优化问题，以及一个用于评估所生成解释的评估指标。

因果发现

因果发现旨在直接从观测数据中自动推断变量间的因果结构。基于因果发现的方法则属于模型内生的解释范畴，即因果关系本身构成了模型的骨架，解释与预测是同源的。其核心在于学习一个因果图。因果图通常表示为一个有向无环图，其中的节点代表变量，有向边代表因果依赖关系。通过学习这种因果图，模型不仅能预测用户的偏好，还能同时生成基于图中路径的因果解释。这种解释直接反映了模型的决策逻辑，因此具有极高的忠实度。



解耦表示学习：长短期兴趣的分离

解耦表示学习通过将用户复杂的混合兴趣分解为独立的、具有明确语义的组成部分，从而让模型能够


“说清楚”推荐到底是基于用户的哪一种偏好。

长期兴趣：反映用户稳定的偏好基准。

短期兴趣：反映近期高频交互的动态偏好。

解释性：自适应融合权重直接反映推荐是基于“近期冲动”还是“长期习惯”。

图了解耦表示学习框架。A长短兴趣利益的表示和代理之间的相似性的对比任务；B长期利益编码器；C短期利益编码器；D长短兴趣利益的自适应融合，关注目标项目和历史相互作用




因果推断与推荐系统鲁棒性

鲁棒性是衡量推荐系统在面对非平稳环境或恶意干扰时，能否保持性能稳定的关键指标。

传统的监督学习模型通常基于独立同分布假设，即训练集和测试集的数据分布是一致的。

在开放动态的推荐场景中，这一假设往往并不成立。因果推断通过挖掘数据背后的不变机制，为构建鲁棒的推荐系统提供了理论支撑。



应对分布偏移：从相关性到不变性

推荐系统面临的主要挑战之一是分布外泛化问题。用户的兴趣偏好、物品的流行趋势以及系统的曝光策略都会随时间发生动态变化，导致训练数据的分布与测试数据的分布存在显著差异。

从因果推断的视角来看，这种分布偏移通常源于环境特征的变化，而因果特征与目标变量之间的关系应当是跨环境稳定的。形式化地，设 E 为所有可能环境的集合。对于任意环境 $e \in E$ ，数据的生成过程可以分解为因果部分 C 和非因果部分 S 。一个鲁棒的预测模型 $f(\cdot)$ 应当致力于学习不变的条件概率分布：


$$P(Y|f(X_c), e) = P(Y|f(X_c)), \forall e \in E$$

上式表明，如果我们能够通过因果发现或不变风险最小化等方法，识别出独立于环境变化 e 的因果结构 X_c ，就能构建出在未知分布下依然可靠的预测模型。

3.5 因果与安全

因果与安全

- 3.5.1 机器学习安全
- 3.5.2 因果对抗鲁棒性
- 3.5.3 因果公平性与算法偏见消除
- 3.5.4 因果可解释性与模型透明度
- 3.5.5 因果隐私保护
- 3.5.6 小结




机器学习安全

背景

- 机器学习系统正嵌入医疗、金融、交通等关键复杂系统，面临“可信与可控”的严峻挑战

安全研究的四大核心维度：

- 对抗鲁棒性：抵御刻意扰动与分布偏移
- 公平性：避免算法系统性歧视
- 可解释性：说明模型决策逻辑
- 隐私保护：防止敏感信息泄露



<http://arxiv.org/abs/2502.21123>

因果对抗鲁棒性：核心概念

- “原因、相关、环境”三个核心概念：
 - 原因：改变它，结果随之改变的本质因素
 - 相关：经常一起出现，但未必产生实质影响的伴随现象
 - 环境：非因果相关性随环境变化，而因果关系跨环境稳定
- 核心逻辑：
 - 非因果相关性：随环境变化而不稳定
 - 因果关系：跨环境稳定存在
 - 模型失效根源：过度依赖非因果线索（噪声、提示词、微小标记）
- 目标：
 - 聚焦 “因果父变量”，削弱或切断非因果路径影响


结构建模与路径识别

- 核心工具

- 结构因果模型 (SCM)：将假设显式化的建模工具
- 有向无环图 (DAG)：明确变量间 "谁影响谁" 的因果关系


- 案例：图像分类任务

- 因果链：形状、结构、部件组合→标签 (强化)
- 非因果捷径：背景、拍摄风格→标签 (弱化)




跨环境训练与反事实增强

- 提升模型鲁棒性的两种策略：
 - 跨环境训练：联合多来源数据，施加正则化与不变性约束，利用 "环境变化" 筛选稳定因果特征，剔除虚假相关
 - 反事实增强：同一样本中分离原因与非原因




优化目标与混杂处理

- 优化目标：将 "减少非因果路径依赖" 写入目标函数



(a) 优化目标：减少非因果依赖

- 混杂因素处理：同时影响输入与标签的 "第三方因素" (制造虚假相关)




(b) 混杂处理：剥离第三方因素

方法融合与展望

• 方法融合逻辑

- 因果方法 + 传统对抗训练：解决结构性依赖 + 让模型 "见识" 攻击样本
- 因果方法 + 异常检测：减少可操纵线索依赖 + 前端拦截异常输入
- 协同效果：提升经验稳健性 + 强化结构安全性



因果公平性与算法偏见消除

- 背景与意义

- 应用场景：信贷审批、医疗诊断、刑事司法等高风险领域
- 传统公平性研究局限：基于统计相关性，易陷入 "辛普森悖论"
- 核心问题：指标公平 $\neq$ 实质公平，难以触及不平等本质根源

- 因果推理的价值

- 提供基于机制的全新视角，从根源破解算法偏见
- 核心思路：区分敏感属性的直接因果效应与虚假关联

算法公平性的视角转换（传统 vs 因果）




因果推理
(Causal Inference)



路径特定公平性与偏见解耦

- 路径分类逻辑

- 歧视性路径：需切断（如 "性别→录取" 直接歧视）
- 合理路径：可保留（如 "性别→体力→录取"，体力为职业正当要求）



- 核心方法

- 因果中介分析：分解总因果效应为自然直接效应（NDE）与自然间接效应（NIE）
- 工具：因果图（DAG）显式指定允许 / 禁止路径

消除偏见的因果方法

1. 预处理阶段

- 方法：因果数据增强、重加权
- 前沿技术：生成反事实样本（如文本中翻转性别词，保持语义不变）
- 目标：迫使模型学习与敏感属性无关的因果机制

2. 模型训练阶段

- 因果正则化：损失函数中加入敏感属性独立性约束
- 对抗学习：训练特征提取器，平衡敏感属性独立性与任务预测能力
- 因果解耦 VAE：分离敏感因子与任务因果因子，仅用后者预测

3. 后处理与审计

- 因果干预检测：扰动敏感特征，观察输出变化
- 案例：COMPAS 系统中，识别 "居住地警力部署密度" 对 "种族 - 高风险评分" 的混淆影响
- 价值：校正系统性偏差导致的算法不公

因果可解释性与模型透明度

- 背景与问题

- 大模型痛点：参数量指数级增长，决策机制成 "黑箱"
- 传统解释方法局限：基于统计相关性（SHAP、LIME），解释不稳定、易误导

- 因果可解释性目标

- 超越相关性，揭示因果机制
- 核心问题："为什么这么决策？" "如果不这样会怎样？"
- 价值：增强信任、支持调试、明确责任归属

反事实解释：提供行动指南

- 定义与逻辑


- 核心：寻找输入的最小扰动，使预测结果翻转
- 本质：因果图约束下的优化问题（距离最近 + 结果翻转）

- 优势与要求

- 优势：提供可追索性（Recourse），明确改变现状的具体行动
- 要求：数学可行 + 因果逻辑合理（如不建议“减少年龄”）

- 案例对比

- 传统解释：贷款拒绝 → “信用评分贡献度 - 0.3”（无指导意义）
- 反事实解释：贷款拒绝 → “年收入 + 5000 元或还清信用卡欠款即可批准”



核心理念：寻找最小扰动以翻转预测结果，为用户指明改变现状的具体行动路径（Recourse）。


结构因果模型与特征归因

- 核心功能

- 建模输入输出的因果关系，量化直接 + 间接因果效应
- 区别于线性归因：明确因果路径与效应传递方式

- 典型应用

- 医疗诊断模型：区分 "药物直接改善康复率" 与 "通过免疫指标间接改善"
- 价值：决策流可视化，推理过程透明可验证




通过 SCM 分解特征对结果的直接和间接因果路径，使决策流透明可验证。

机械可解释性与大模型

- 演进方向
 - 目标：将神经网络逆向工程为可理解的 "电路"
 - 核心技术：因果抽象 + 因果追踪
- 关键方法
 - 因果干预分析：干预神经元 / 注意力头 / 层级输出，观察功能变化
 - 因果电路定位：通过因果激活修补，定位任务相关稀疏子图


机械可解释性与大模型

深入神经元层面验证因果逻辑，超越表层文本（如思维链 CoT）判断




因果隐私保护

- 传统隐私保护的痛点
 - 泛化式干预：差分隐私（注入噪声）、联邦学习（限制传输）
 - 核心困境：隐私 - 精度 - 公平三重权衡
 - 应对乏力：难以抵御梯度泄露、模型反演等新型攻击
- 因果隐私保护的核心逻辑
 - 工具：结构因果模型（SCM）+ 因果图（DAG）
 - 思路：区分 "隐私泄露因果链路" 与 "任务必需因果链路"
 - 目标：定向干预泄露路径，保留任务因果机制，实现协同优化



隐私泄露的因果建模与路径定位

金融信贷模型实例，建模步骤与因果对抗鲁棒性的“结构建模”逻辑一致：



因果驱动的隐私防护技术路径

1. 因果路径阻断

- 因果特征解耦：分离隐私 - 任务特征子空间（如屏蔽医疗影像面部轮廓）
- 路径特定干预：仅对泄露路径加噪声（如联邦学习中敏感属性→梯度路径）
- 因果约束训练：损失函数中添加泄露路径惩罚项

2. 因果生成式隐私数据

- 流程：SCM 学习任务因果逻辑→剥离敏感属性→生成合成数据
- 要求：保因果、去敏感，通过因果一致性检验
- 案例：医疗领域生成无患者身份信息的合成病历

3. 因果隐私审计

- 反事实验证：替换敏感属性，观察输出变化
- 因果 SHAP 量化：评估敏感属性对输出的贡献度
- "被遗忘权" 验证：模拟移除敏感数据场景

本章小结

本章围绕“因果与安全”展开，针对机器学习安全的四大核心维度——对抗鲁棒性、公平性、可解释性、隐私保护，系统阐述了因果推理如何从机制层面破解传统方法的局限，形成统一且高效的安全优化框架。

