




浙江大學
ZHEJIANG UNIVERSITY

因果人工智能


因果与因果推断 (Causality and Causal Inference)

- 亚里士多德《物理学》的一个英译本的Book II 3的开篇写道：“Knowledge is the object of four inquiry, and men do not think they know a thing till they have grasped the 'why' of it (which is to grasp its primary cause)”【我们探索的目标是知识，只有掌握了“为什么”，才算真正理解一个事物，即，掌握该事物的根本原因。】
- 探求事物的原因，是人类永恒的精神活动之一。从古希腊的哲学到中国先秦的诗歌，都充满了对原因的追问和对因果关系的思考。如屈原在《天问》开篇，就追问日月星辰运行的原因。
- 因果推断 (Causal Inference) 始于寻找结果的原因：Look for Causes of given Effect



因果与因果推断 (Causality and Causal Inference)

- 哲学家穆勒的归纳五法（寻找原因的方法）：差异法、求同法、求同差异并用法、共变法、剩余法。
- 哲学上亚里士多德的四因：质料因、动力因、形式因、目的因，强调的是事务的原因，而不是原因的结果。
- 统计学家，Rubin的潜在结果：定义原因的结果 (Effects of Causes)
- 图灵奖获得者，Pearl的因果网络：多因素因果关系与外部干预
- 图灵奖获得者，Pearl提出因果关系的三个层级：相关、干预、反事实
- 在最近的一篇文章《What are the most important statistical ideas of the past 50 years?》中，Andrew Gelman（曾获得年轻统计学家的最高奖COPSS 奖章）和Aki Vehtari评选了过去五十年中，统计学最重要的八个想法，排名第一的就是因果推断。




因果关系的三个层级



Judea Pearl

2011年图灵奖获得者
提出因果关系的
三个层级



公鸡打鸣是太阳升起的原因吗？
张三没打疫苗得病了；
假如当初打疫苗，是否还会得病？

如果不让公鸡打鸣，太阳还会升起吗？
如果打疫苗，疫情会减轻吗？

公鸡打鸣与太阳升起
打疫苗越多的地方或时期，疫情越重

当今人工智能处于最低层级：关联
无论数据多大或神经网络多深，无法回答“干预”和反事实问题

人工智能起源

人工智能（artificial intelligence）单词首次登上人类历史舞台

让机器能像人那样认知、思考和学习，即用计算机模拟人的智能。

- 麦卡锡(John McCarthy)、明斯基 (Marvin Lee Minsky)、香农 (Claude Shannon) 和罗切斯特 (Nathaniel Rochester) 四位学者向美国洛克菲勒基金会递交了一份题为“关于举办达特茅斯人工智能夏季研讨会的提议 (a proposal for the Dartmouth summer research project on artificial intelligence)”的建议书，希望洛克菲勒基金会资助拟于1956年夏天在达特茅斯学院举办的人工智能研讨会。
- 评审意见：研究内容难以让人彻悟 (difficult to grasp very clearly)，但是鉴于这一研究所具有长期挑战性特点，基金会愿意资助其申请经费的一半。希望你们不会觉得我们过于谨慎 (overcautious)，对思维的数学模型研究从长远来看非常具有挑战性，是一场适度的赌博，因此在现阶段冒任何大风险会令人犹豫重重。

A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence


August 31, 1955

John McCarthy, Marvin L. Minsky,
Nathaniel Rochester,
and Claude E. Shannon

■ The 1956 Dartmouth summer research project on artificial intelligence was initiated by the August 31, 1955 proposal, submitted by John McCarthy, Marvin Minsky, Nathaniel Rochester, and Claude Shannon. The original response consisted of 17 pages plus a six-page appendix. Copies of this proposal are found in the archives at Dartmouth College and Stanford University. This file is your view of the original, and the more recent pages are summaries and annotations of the how who prepared the study. In the interest of brevity, this study reports directly the proposed work along with the brief autobiographical statements of the proposers.

groups, from abstractions and concepts, solve kinds of problems now reserved for humans, and improve themselves. We think that a significant advance can be made in one or more of these problems if a carefully selected group of scientists work on it together for a summer. The following are some aspects of the artificial intelligence problems.

1. Automatic Computers
If a machine can do a job, then an automatic calculator can be programmed to simulate the machine. The speed and memory capacities of present computers may be insufficient to simulate many of the higher functions of the human brain, but the major obstacle is our lack



达特茅斯人工智能暑期研讨会申请书及评审意见

Research Project on Artificial Intelligence , August 31, 1955, Dartmouth

人工智能诞生之初所提研究问题

号角：从达特茅斯启航

人工智能（Artificial Intelligence）是以机器为载体所展示的人类智能



达特茅斯会议合影
(1956年6月18日至8月17日)


8周时间

30位专家


七个议题

问题	描述
自动计算机	让计算机完成特定人类工作
使用语言对计算机进行编程	通过语言对计算机编程
神经网络	通过神经网络让计算机形成抽象概念
计算复杂度	计算任务所耗费的时间和空间
智能算法的自我改进	算法能够苟日新、日日新
智能算法的抽象能力	大数据读薄、然后厚积薄发（归纳和演绎）
智能算法的随机性和创造力	智能算法具备学会学习能力

人工智能算法在我们生活中无处不在



人工智能：第一次隆冬来临



Lighthill Report, 1973

- 1973年提交了一份名为《人工智能：一份全面报告》（Artificial Intelligence: A General Survey）被称为“莱特希尔（Lighthill）报告”的评估结果。
- 该报告对人工智能进展和成效给出了较为悲观的结论，报告主要观点如下：
该领域迄今为止的发现尚未产生当时承诺的重大影响（In no part of the field have the discoveries made so far produced the major impact that was then promised）。人工智能研究集中在自动机、机器人和神经系统，自动机和神经系统的研究有价值，但进展令人失望。机器人的研究没有价值，进展非常令人失望，建议取消机器人的研究。
- 莱特希尔特别强调了“组合爆炸（combinatorial explosion）”这一问题用现阶段人工智能技术难以解决，这样将导致人工智能方法只能需求解决“玩具类问题（toy problem）”，而非真实世界中任务。这一报告导致英国政府几乎终止了对英国高校进行人工智能研究的资助。

人工智能：第一次隆冬来临---未能解决真实世界问题

机器翻译的笑话：英语翻译为俄语

一、

- 英语谚语：心有余而力不足 (the spirit is willing but the flesh is weak)
- 输出的俄语：伏特加不错，但肉已经腐烂 (the vodka is good but the meat is rotten)

二、

- 英语谚语：眼不见，心不烦 (Out of sight, out of mind)
- 输出俄语：眼瞎脑残 (invisible, insane)

后来研究者把这个尴尬结局归为人工智能欠缺“常识知识 (commonsense knowledge)”。

人工智能：第一次隆冬来临

- 第一次低谷：1973年英国发表James Lighthill 报告
 - 该报告主要评判AI基础研究中A自动机、B机器人和C中央神经系统。
 - 报告得出结论：A和C的研究有价值，但进展令人失望。B的研究没有价值，进展非常令人失望。建议取消B的研究。
 - 批评后，AI开始了严冬（AI Winter）

(Sir James Lighthill, *Artificial Intelligence: A General Survey*, Science Research Council, 1973)

教训： AI尚属婴儿期，难以对其未来测算准确

人工智能核心要素：数据、算法、算力


人工智能：第二次隆冬来临



800亿神经元之间如何工作的？
(记忆、意识、直觉等能力)

- **刺激与学习：巴甫洛夫条件反射定律**

除食物本身之外，在食物出现之前的其他刺激(如送食人员或其脚步声以及铃声等)，也会引起狗分泌唾液。巴甫洛夫根据谢切诺夫 (Sechenov, Ivan Mikhailovich) 《脑的反射》著作中所提出“大脑的一切心理活动都是反射，包含有意识和无意识”理论，提出了著名的“巴甫洛夫条件反射定律”。



- **赫布理论 (Hebbian theory)**

神经元之间持续重复经验刺激可导致突触传递效能增加 (Neurons that fire together, wire together)、神经元之间突触的强弱变化是学习与记忆的生理学基础

人工智能：第二次隆冬来临

- 1943年，神经科学家沃伦（Warren McCulloch）和逻辑学家沃尔特·皮兹（Walter Pitts）合作提出了以他们名字命名的“MCP神经元”模型。兴奋的麦卡洛克于1954年在《英国科学哲学期刊》发表的一篇题为《走出形而上学的洞穴(Through the Den of the Metaphysician)》文章中激动写道，“在科学史上第一次，我们知道了我们是怎么知道的”。
- 弗兰克·罗森布拉特（Frank Rosenblatt）在20世纪50年代提出了“感知机（perceptron）”模型，人们对神经网络寄予了莫大期望。
- 1969年，明斯基（Marvin Minsky）和帕普特（Seymour A. Papert）出版了《感知机：计算几何学》一书，证明了由输入层和输出层构成的感知机能力极其有限，甚至无法完成异或（XOR）这一基本逻辑计算问题。这一书籍的出版使得神经网络被打入冷宫。
- 国际电气和电子工程师协会(IEEE)为了纪念罗森布拉特，于2004年设立了IEEE Frank Rosenblatt奖。今天深度学习正在推动人工智能形成第三次发展浪潮，提出“误差后向传播”这一概念来训练神经网络参数的保罗（Paul Werbos）以及命名“深度学习”新名词的辛顿(Geoffrey Hinton)分别于2022年和2014年获得IEEE Frank Rosenblatt奖。

THROUGH THE DEN OF THE METAPHYSICIAN *

WARREN S. MCCULLOCH

We are again in one of those prodigious periods of scientific progress—in its own way like the pre-Socratic period to which we are still indebted for the crisp formulation of our physical problems and, consequently, for our epistemological quandary. Anyone who has had the good fortune to listen to Wiener and von Neumann and Rosenbluth and Pitts wrestling with the problems of modern computing machines that know and want, has a strange sense that he is listening to a colloquy of the ancients. But they would be the first to tell you that they themselves are drunk with an American wine of an older vintage; they quote liberally from Charles Peirce and from Josiah Willard Gibbs. These men have altered our metaphysics by altering our physics. It is epistemology that is most affected, for it is the physics of communication which is today receiving an adequate theoretical treatment. For the first time in the history of science we know how we know and hence are able to state it clearly.

Physiologists, working on the central nervous system, have long had such a goal in mind. Rudolph Magnus, inspired by Immanuel Kant, made his last great lecture one on 'the physiology of the *a priori*' by which he meant how those mechanisms work that determine for us the three-dimensional nature of our world, its axes and its angles, and that give to us our sense of velocity and acceleration, from which he held our notion of time to be in large measure derived. Perhaps the most notable attempt of this sort was by Sir Charles Sherrington, entitled *Man on his Nature*, for, near the end of a life spent on studying the ways of the brain, he was forced to the conclusion that 'in this world, Mind goes more ghostly than a ghost'. The reason for his failure was simply that his physics was not adequate to the problem that he had undertaken. That has so regularly been the shortcoming of scientists who would have approached this problem, that even Clerk Maxwell, who wanted nothing more than to know the relation between thoughts and the molecular motions of the brain, cut short his query with the memorable phrase, 'but does not the way to

* Paper read to the Philosophy of Science Group on 30th June 1952. It appeared in French in *Thalès*, published by the Presses Universitaires de France, Paris, 1951, 7, and is printed here by permission of the editor and publishers of that Journal.

18

ALCHEMY AND ARTIFICIAL INTELLIGENCE

Hubert L. Dreyfus

December 1965

1965年12月，先后在MIT和伯克利任教的休伯特·德雷福斯（Hubert Lederer Dreyfus）教授以兰德公司顾问的身份，发表了《炼金术与人工智能》（Alchemy and Artificial Intelligence）的研究报告。

人工智能：第二次隆冬来临

- ❑ 第二次低谷：日本智能（第五代）计算机研制失败
 - 1982年开始，日本通产省主持第五代计算机。
 - 动机：计算机从计算与存储数据向能直接推理与知识处理的新型结构过渡。
 - 目标：构成一个具有1000个处理单元的并行推理机，推理速度比常规高1000倍。连接10亿信息组的数据库和知识库，具备听说能力。
 - 1992年因失败而告终（开支US \$850 million）

教训：驱动AI的发展不仅是硬件，要靠软件、数据和知识

人工智能核心要素：数据、算法、算力、知识


人工智能：第三次隆冬来临

- 第三次低谷：知识词典日趋势微、网络百科兴起
 - 斯坦福1984年通过专家来建设知识百科全书Cyc。截止2015年11月（其建设也时断时续），包括23万多个概念、实体和200多万个三元组，如：
 - place: ~19,000 organization: ~26,000 business related thing: ~28,000
 - Cyc在90年代后期衰败，因搜索引擎崛起，显示互联网威力。
 - Cyc也开始链接外部知识库：Dbpedia, UMBEL, CIA World Factbook等等。

教训： 知识不能靠专家表达，要自动学习

数据驱动+知识引导

人工智能：两落三起



新一代人工智能的原因

浙江大学潘云鹤院士提出驱动新一代人工智能发展的内因和外因论：回顾人工智能发展历程中的主要挫折，我们不难发现，当它与信息环境的变化趋势不符时，往往就会导致失败。促使人工智能变化的动力既有来自人工智能研究的内部驱动力，也有来自信息环境与社会目标的外部驱动力，两者都很重要，但相比之下，往往后者的动力更加强大。

信息 新环境 巨变

互联网、物联网和超级计算等

互联共融

社会 新需求 爆发

AI+X应用需求（医疗、教育和交通、
基础科学等）

层出不穷

AI 技术的新目标巨变


从“造人”到“赋能”

凡贵通者，贵其能用

恩格斯：社会一旦有技术上的需要，这种需要就会比十所大学更能把科学推向前进
（社会历史发展的动力来自实践需求）

人工智能学习特点

- 深度学习等人工智能学习特点：数据驱动的**关联学习**



为什么图像会被识别为“狗”？为什么会用“草地”预测狗？为什么不同测试结果差异大？

模型存在不可解释，不可泛化等问题——关联并未反映客观自然科学规律？


关联的三种来源

因果




可解释
稳定/鲁棒
可决策

混淆偏差






虚假关联: 当忽略 X 时,
T 和 Y 相关

选择偏差



虚假关联: 当给定 S
时, T 和 Y 相关



大语言模型的学习特点也是数据驱动，关联学习

对齐（Alignment）

与数据空间对齐
与人类指令对齐
与人类反馈对齐

predict the next token

完形填空形式下文字接龙 (自监督学习)

- 原话：一辆 列车 缓慢 行驶 在 崎岖 的山路上
- 移除单词：一辆 列车 行驶 在 崎岖 的山路上
- 预测填空：一辆 列车 缓慢 行驶 在 崎岖 的山路上

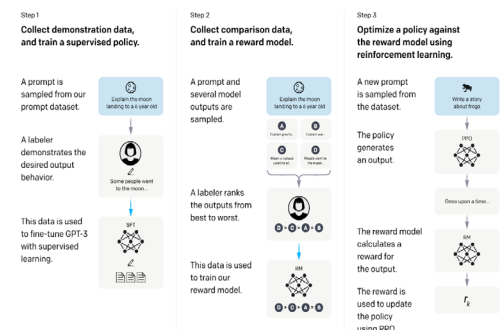
supervised fine-tuning

提示学习与指令微调 (人教机学)

第一轮: {"instruction": "本院查明,被告人酒后...
请分析案情。
"output": "根据上述内容, 可以认定本案的核心
要素包括醉酒驾驶、致人受伤、酒后逃逸..."},
第二轮: {"instruction": "根据上述分析, 请预测
罪名。
"output": "本案预测的罪名是危险驾驶罪"},
第三轮: {"instruction": "请给出处罚意见。
"output": "结合嫌疑人逃逸的情节, 建议考虑拘
役三个月, 并罚款6000元"}
...

Reinforcement Learning
from Human Feedback

人类反馈下强化学习 (尝试与探索)



自然语言合成的核心神经网络是Transformer 模型

GPT的训练三板斧之一：完形填空形式下文字接龙（自监督学习）

在训练时，人工智能模型会不断地在句子中‘挖去’一个单词，根据剩下单词的上下文来填空，即预测最合适的‘填空词’出现的概率，这一过程为‘自监督学习’。

原话：一辆 列车 缓慢 行驶 在 崎岖 的 山路上

移除单词：一辆 列车 ____ 行驶 在 崎岖 的 山路上

预测填空：一辆 列车 缓慢 行驶 在 崎岖 的 山路上


GPT的训练三板斧之二：提示学习与指令微调（人教机学）

- 让人工智能模型说人话、做人事。
- 手工设计提示和指令微调被誉为人工智能私语者（AI whisperer）
- 经师易得、人师难求

- **情感预测任务。**输入：“I missed the bus today. I felt so ____.” 其中 “I felt so” 就是提示词（prompt），然后使用 大模型 用一个表示情感的词填空。
- **翻译任务。**输入：“English:I missed the bus today. French:____.” 其中 “English:” 和 “French:” 就是提示词，然后使用大模型 应该再空位填入相应的法语句。

提示学习

“提示” 是一种提供给预训练语言模型的线索，让预训练语言模型能更好的理解人类的问题。



第一轮: {"instruction": "本院查明,被告人酒后...
请分析案情。

"output": "根据上述内容, 可以认定本案的核心要素包括醉酒驾驶、致人受伤、酒后逃逸..."};

第二轮: {"instruction": "根据上述分析, 请预测罪名。

"output": "本案预测的罪名是危险驾驶罪}

第三轮: {"instruction": "请给出处罚意见。

"output": "结合嫌疑人逃逸的情节, 建议考虑拘役三个月, 并罚款6000元}

指令微调

指令微调，是指在已经训练好的语言模型的基础上，通过使用有标注的特定任务数据进行进一步的微调，从而使得模型具备遵循指令的能力。

GPT的训练三板斧之三：人类反馈下强化学习（尝试与探索）

谋定而后动，知止而有得

Step 1

Collect demonstration data, and train a supervised policy.

A prompt is sampled from our prompt dataset.

Explain the moon landing to a 6 year old

A labeler demonstrates the desired output behavior.

Some people went to the moon...

This data is used to fine-tune GPT-3 with supervised learning.

SFT

Step 2

Collect comparison data, and train a reward model.

A prompt and several model outputs are sampled.

Explain the moon landing to a 6 year old

A B C D
Explain gravity... Explain war...
Moon is natural satellite of... People went to the moon...

A labeler ranks the outputs from best to worst.

D > C > A = B

This data is used to train our reward model.

RM
D > C > A = B

Step 3

Optimize a policy against the reward model using reinforcement learning.

A new prompt is sampled from the dataset.

Write a story about frogs

The policy generates an output.

PPO


Once upon a time...

The reward model calculates a reward for the output.


RM

The reward is used to update the policy using PPO.

r_k




大语言模型的学习特点也是数据驱动，关联学习



The Transformer - model architecture
Google (2017): Attention is all you need
(八位作者共同一作)


截至2026年2月，该文引用量次数232321



项庄 舞剑 意在 沛公

学习单词和单词之间关联关系 (in-context meaning)

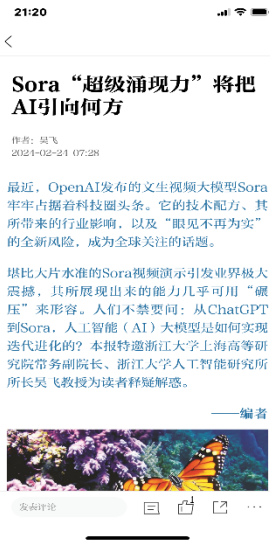
大语言模型的学习特点也是数据驱动，关联学习



- 提示词：东京赏樱
- Sora可以认为是背诵、默写与组合出来“现实世界”

Sora “超级涌现力” 将把AI引向何方 （文汇报：2024年2月24日）

从Chat到Sora: 对合成内容中最小单元进行有意义的**关联组合**，犹如昨日重现



I am four years old.

There are five people in my family.


I am young, short and thin.

My dad is forty years old.

单词有意义的线性组合



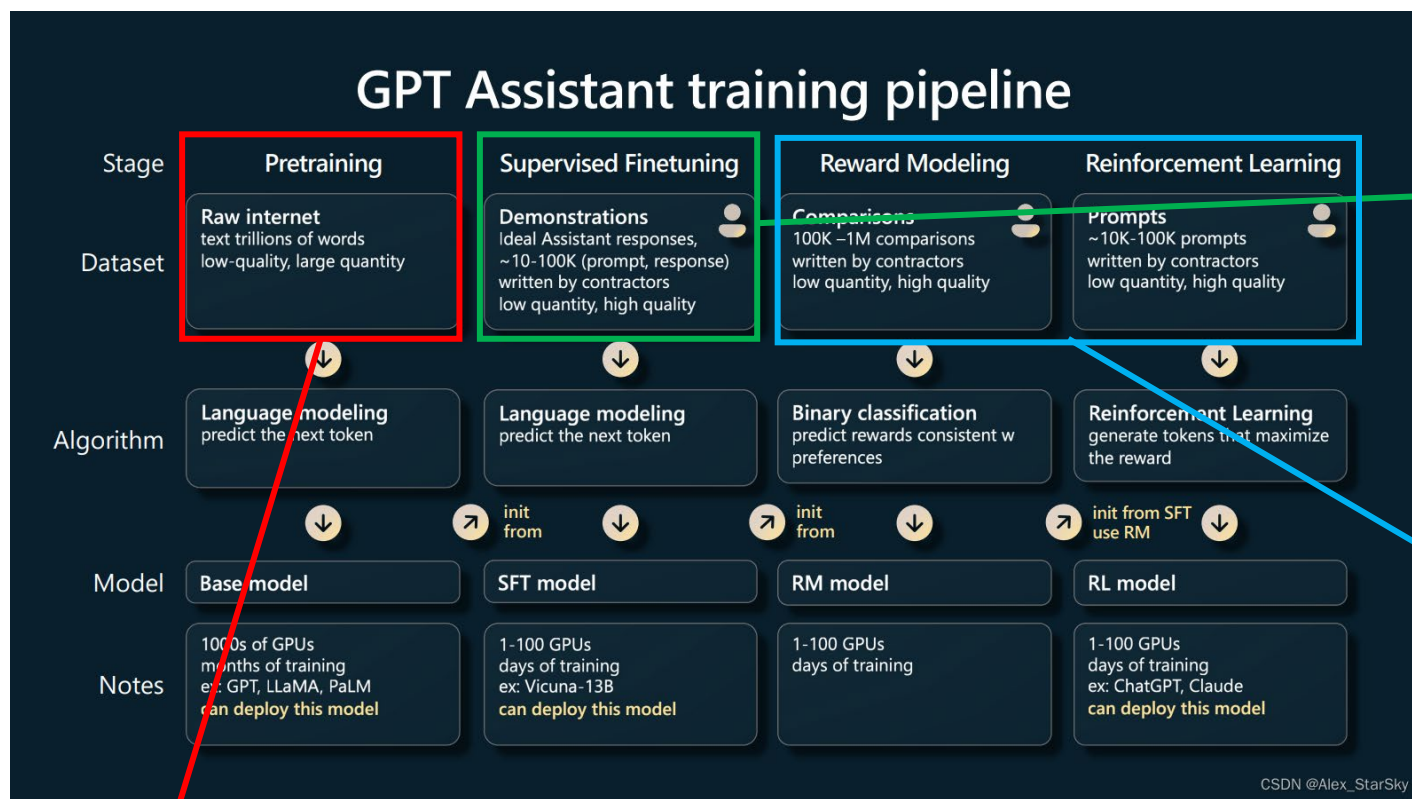
像素点有意义的空间组合



时空子块有意义的时序组合

在保持连贯的上下文语境中，对若干个单词进行有意义线性组合，从而连缀成一个会意句子；在保持合理的空间布局下，对众多图像小块进行有意义结构组合，拼合为一幅精彩图像；在保持一致的连续时空内，对一系列时空子块进行有意义时空组合，从而拼接成一段动感视频。

因果如何赋能大语言模型



因果去除数据偏置

- 虚假相关问题
- 灾难遗忘问题

因果支撑决策

- 用户偏好对齐
- 因果强化学习

因果赋能Transformer

- 由关联自回归到因果回归机制
- 因果Transformer架构
- 基于因果知识增强的Transformer架构

Survey: Causality for LLMs

Causality for Large Language Models

Anpeng Wu, Kun Kuang, Minqin Zhu, Yingrong Wang, Yujia Zheng, Kairong Han, Baohong Li, Guangyi Chen, Fei Wu, Kun Zhang


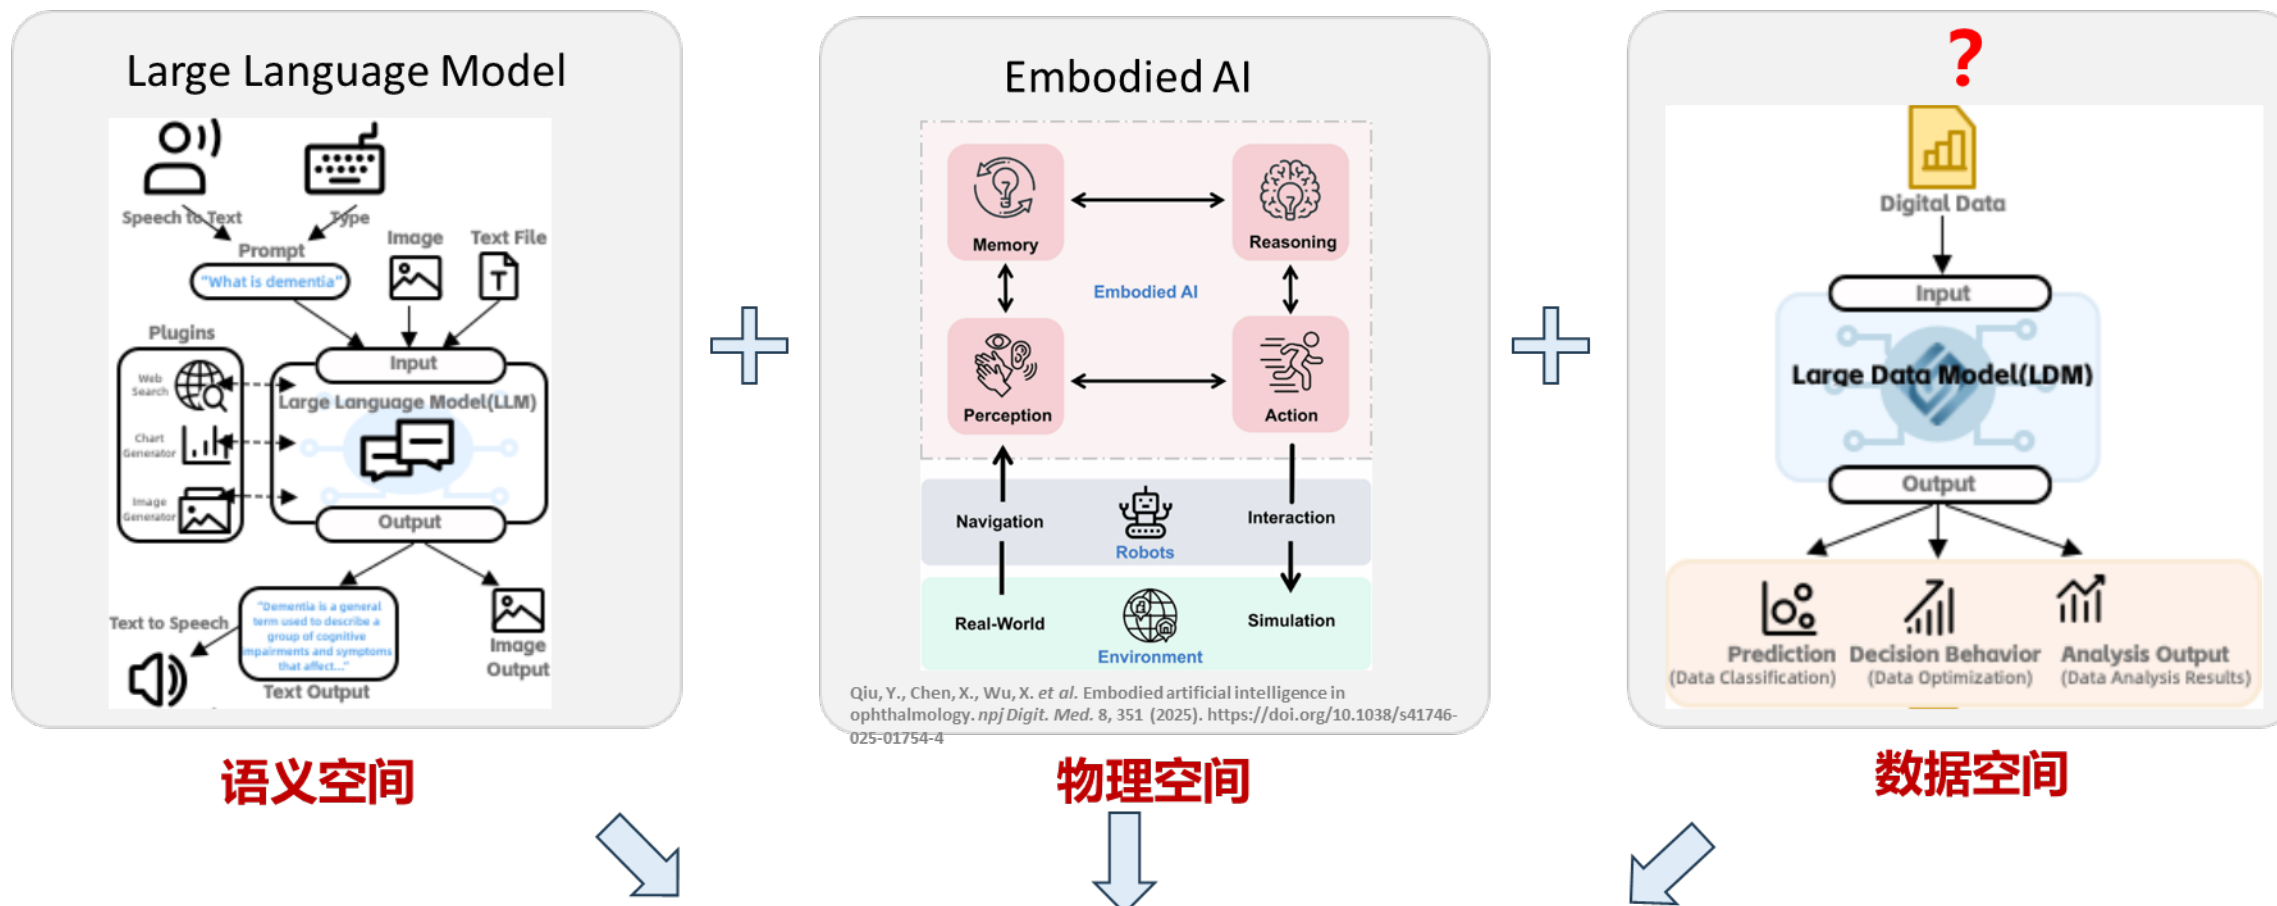


Figure 1: The Role of Causality in Enhancing LLMs: A Comprehensive Framework Across Development Stages

AGI需要三个通用世界模型



Artificial general intelligence (AGI)—sometimes called **human-level intelligence AI**—is a type of artificial intelligence that would match or surpass human capabilities across virtually all cognitive tasks. <Wikipedia>

世界模型中因果的必要性

因果模型是必须的，还是可有可无的？

DeepMind 的 Jonathan Richens 和 Tom Everitt 在 ICLR2024 工作中提出：

“Any agent capable of satisfying a regret bound for a large set of distributional shifts must have learned an approximate causal model.”

(任何能够满足大量分布变化的遗憾界限的智能体都必须学会近似的因果模型)

世界模型中因果的必要性


任何能够满足大量分布变化的遗憾界限的智能体
都必须学会近似的因果模型

- 结论1：在**理想情况**下（最优策略），智能体的策略足以还原出环境中的因果图（Causal Bayesian Network）。
- 结论2：即使策略**不是最优**（有一定遗憾），也能学到一个近似的因果模型，误差随遗憾值线性增长。
- 结论3：有了因果模型，就能找到**遗憾有界**的策略（**双向等价**）。


因果世界模型驱动的Agent

将智能体与因果世界模型结合


把“因果世界模型”嵌入Agent，让Agent能基于干预/因果变量进行想象与规划，在环境变化与任务切换下保持鲁棒泛化



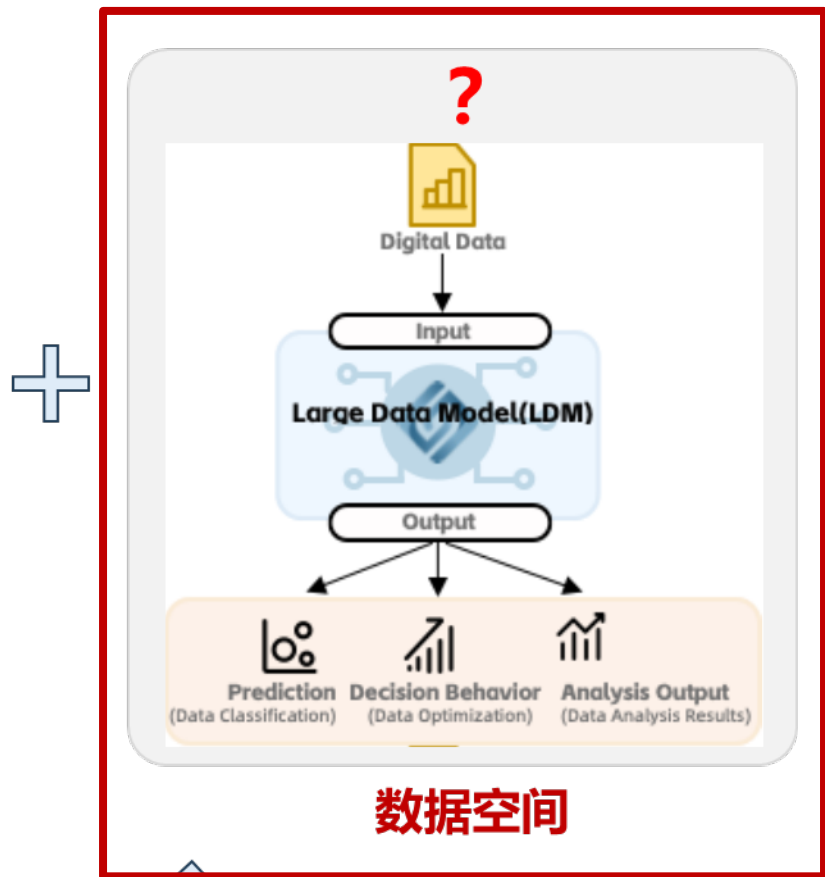
AGI需要三个通用世界模型



语义空间



物理空间



数据空间

Artificial general intelligence (AGI)—sometimes called **human-level intelligence AI**—is a type of artificial intelligence that would match or surpass human capabilities across virtually all cognitive tasks. <Wikipedia>

数据空间的核心：结构化数据

Structured Data refers to the data that possesses a clear organizational format and is typically represented, stored, managed, and queried according to predefined schemas or models. Typical forms of structured data include **tabular data**, **time-series data**, and **graph data**, each of which organizes numerical information in distinct yet structured ways.

Tabular Data

年份		品牌名称		品牌数量		品牌平均	
品牌	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2011-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2012-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2013-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2014-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2015-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2016-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2017-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2018-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2019-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2020-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2021-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2022-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2023-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2024-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2025-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2026-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2027-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2028-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2029-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均
2030-12	品牌名称	品牌数量	品牌平均	品牌数量	品牌平均	品牌数量	品牌平均



Bank



Medical




Government



Retail

Time-series Data





Electric Power



Meteorological Phenomena




Stock



Manufacture

Graph Data





Social Media



Network Security



Smart City



Chemicals

LLM处理结构化数据的局限性

◆ **数据层：文本数据为主，图片、视频数据为辅，结构化数据<1%**

根据 OpenAI公布的数据分析，GPT-4 预训练数据集包括约 13 万亿 token 的文本数据，占比约 85%；及2万亿token 的图片等视觉数据，占比约 15%。

◆ **技术层：tokenization无法有效处理数值**

文本序列: “我喜欢吃水果，尤其是香蕉”

↓


切分token: 我 喜 欢 吃 水 果 ， 尤 其 是 香 蕉

文本序列: 9.11<9.9

↓

切分token: 9 . 11 < 9 . 9

◆ **应用层：难以解决数据维度的基本应用，如分类、计算、预测等**




LLM无法触及工业领域核心业务场景

结构化数据通用大模型

Large Data Model

(LDM)

LDM模型框架




LDM通用性验证

动脉瘤稳定情况预测

输入特征：每位患者的**31项**临床指标，包括BMI、动脉瘤是否规则、动脉瘤大小、RRT、是否血脂异常等；

输出目标：动脉瘤是否保持稳定2年

样本数量：共1171例样本，其中106例为测试




*LDM预训练未使用上述数据集

设备故障预测


输入特征：设备运行时的振动幅度、温度、电压、电流等实时监测数据，以及设备的累计工作时长、维护历史等共**26项**信息；

输出目标：预测设备是否会发生故障

样本数量：1417个




公开数据集



CMCC Datasets

*移动通信运营、用户管理、账务结算、网络优化等领域



Kaggle Datasets

*包括社科、商业、生物、交通、信息等多领域

LDM的第一性原理

LLM：压缩即智能

大语言模型LLM的成功证明了基于Transformer 架构及大量参数，在海量文本数据上通过大规模训练，能够具备强大的语言理解、生成及推理能力，并且能够遵循Scaling Law持续增强



LDM：因果即规律

我们发现，在海量**真实数据集**及**结构因果合成数据集**上，同样基于Transformer架构及大量参数进行大规模训练，能够得到具备强大的**数据理解、数据预测及泛化能力**的**通用数据大模型（LDM）**，并且也能够遵循Scaling Law持续增强



数据预测 数据恢复 特征选择 数据分类 ...

Missing Value Prediction




巨大参数空间
学习数据分布规律



LDM学习的基础
是规律性学习
(因果结构)




生物组学



工业时序



因果数据




...

绪论

- 因果与关联
- 潜在结果框架
- 结构因果模型

1.1 因果与关联

人工智能算法在我们生活中无处不在



人工智能算法在我们生活中无处不在

- 以人为中心的风险敏感领域




Human



模型优化应从**性能第一**转到**风险控制**

为什么需要从数据关联到因果推理



关联的局限性1：不可解释



tylervigen.com



为什么需要从数据关联到因果推理

关联的局限性1：不可解释




为什么需要从数据关联到因果推理

关联的局限性2：不可用于支撑决策



为什么需要从数据关联到因果推理

关联的局限性2：不可用于支撑决策



- 小孩子的阅读能力与鞋尺寸有强的正相关。
- 根据小孩鞋尺寸能预测他的阅读能力！
- 但是人为地改变鞋的尺寸，并不会提高他们的阅读能力。

为什么需要从数据关联到因果推理

关联的局限性2：不可用于支撑决策

- 预测模型能否指导我们决策？
- 举例：推荐算法A和B，推荐打折链接给用户
- 假设推荐系统需要更换算法，是否要将原来算法A调整到新算法B
- 是否新算法B的效果会更好一些？



算法A



算法B

为什么需要从数据关联到因果推理

关联的局限性2：不可用于支撑决策

- 测量两个算法的成功率



算法A	算法B
50/1000 (5%)	54/1000 (5.4%)

新算法B提升了推荐成功率，那么算法B就一定比算法A要好么？


	算法A	算法B
低收入用户	10/400 (2.5%)	4/200 (2%)
高收入用户	40/600 (6.6%)	50/800 (6.2%)
整体	50/1000 (5%)	54/1000 (5.4%)

到底哪个算法更好？

为什么需要从数据关联到因果推理

关联的局限性3：不稳定，会随着时间、数据、环境等变化而变化

绝大多数机器学习方法需要独立同分布假设




为什么需要从数据关联到因果推理

关联的局限性3：不稳定，会随着时间、数据、环境等变化而变化



绝大多数机器学习方法需要独立同分布假设



数据驱动
关联学习




重要特征




为什么需要从数据关联到因果推理

关联的局限性4：数据关联可能会带来不公平性问题



自然语言翻译



Micro AUC提升，表面收益增加，但可能Macro AUC下降，用户平均满意度下降（模型牺牲低活用户体验，换取更多收益）。

推荐和预测




The New York Times

Many Facial-Recognition Systems Are Biased, Says U.S. Study

Algorithms falsely identified African-American and Asian faces 10 to 100 times more than Caucasian faces, researchers for the National Institute of Standards and Technology found.

人脸识别



计算机视觉和检索

为什么需要从数据关联到因果推理

关联的局限性4：数据关联可能会带来不公平性问题

偏序偏差
流行度偏差
...





算法

用户

样本选择偏差
遗漏变量偏差
...

用户行为偏差
内容生产偏差
...

数据



Micro AUC提升，表面收益增加，但可能Macro AUC下降，用户平均满意度下降（模型牺牲低活用户体验，换取更多收益）。


为什么需要从数据关联到因果推理

关联的局限性4：数据关联可能会带来不公平性问题

关联分析框架



因果推理框架



T: 肤色
X: 收入
Y: 犯罪率

收入—犯罪率: 强相关

肤色—犯罪率: 强相关



收入—犯罪率: 强因果

肤色—犯罪率: 弱因果


关联学习导致人工智能的不能

因果




可解释
稳定/鲁棒
可决策

混淆偏差



虚假关联: 当忽略 X 时,
T 和 Y 相关


选择偏差



虚假关联: 当给定 S
时, T 和 Y 相关



关联分析框架



因果推理框架

- 关联不可解释, 因果提升模型可解释性
- 关联不可决策, 因果助力模型决策能力
- 虚假关联不稳定, 因果关联具有不变性
- 虚假关联不公平, 因果关联确保公平性

因果让不能
变成可能,
实现因果可
信人工智能


问题的主要根源：因果机制尚未融入机器学习

- 问题主要根源：因果机制尚未融入机器学习



Judea Pearl

2011年图灵奖获得者
提出因果关系的
三个层级



公鸡打鸣是太阳升起的原因吗？
张三没打疫苗得病了；
假如当初打疫苗，是否还会得病？

如果不让公鸡打鸣，太阳还会升起吗？
如果打疫苗，疫情会减轻吗？

公鸡打鸣与太阳升起
打疫苗越多的地方或时期，疫情越重

当今人工智能处于最低层级：关联


无论数据多大或神经网络多深，无法回答“干预”和反事实问题

将因果引入机器学习，提升模型稳定性、可解释性和决策能力

由关联到因果跨越

- 由关联学习到因果启发

人工智能需要从关联分析跨越到因果推理
“知其然，并知其所以然”



关联的定义

定义： 两个或多个变量之间存在的一种统计依赖关系，当其中一个变量的取值发生变化时，另一个变量的取值也倾向于随之发生规律性变化

两个关键条件： 描述了一种共变模式、不蕴含方向性

真实案例：

- 下课铃响起时，学生们同时走出教室
- 下雨天中，行人撑起伞时，地面同时变湿

日常生活中的关联



- 下课铃声响起，同学们走出教室
- 下课铃响起与走出教室之间存在关联
- 下课铃响起与走出教室之间是否存在因果关系？

日常生活中的关联



- 下雨时，行人撑伞，地面变湿
- 行人撑伞与地面变湿之间存在关联
- 行人撑伞和地面变湿之间是否存在因果关系？

什么是因果？

- 哲学上把现象和现象之间那种“引起和被引起”的关系，叫做因果关系，其中引起某种现象产生的现象叫做**原因**，被某种现象引起的现象叫做**结果**。

- 学科中因和果的问题：


- 医学：新药的因果效应（疫苗是否能控制疫情）
- 社会科学：政策的因果效应（禁烟的效应）
- 广告学：营销策略的因果效应（投放广告的效果）
- ...



- 什么是因果？

什么是因果?

- A big scholarly debate, from Aristotle to Russell



因果的定义

定义：在控制相关变量不变的前提下，当一个变量（因）的取值发生变化时，另一个变量（果）的取值也会发生相应的改变

两个关键条件：保持其他相关变量不变的前提下改变因变量，具有方向性


真实案例：

- 在控制其他因素不变的条件下，下课铃声响起后，学生们就会走出教室

日常生活中的因果关联




- 下课铃响起是学生们走出教室的**原因**，学生们走出教室是下课铃响起的结果
- 二者之间**存在**因果关系
- 二者的关联属于**因果关联**



日常生活中的非因果关联



- 下雨是行人撑伞的**原因**，同时也是地面变湿的**原因**
- 撑伞不会导致地面变湿，地面湿也不会使行人撑伞
- 二者**不存在**因果关系
- 二者的关联属于**非因果关联**




关联与因果的区别

- (1) **是描述现象还是解释机制**：关联止步于对变量间自然发生的**共变现象**进行描述；因果则致力于阐明变量间共变现象内在的**驱动机制**
- (2) **是双向相关还是单向作用**：关联仅表明变量间存在统计相依性，**不预设方向**；因果则严格遵循**从因到果的单向路径**，且原因必须先于结果发生
- (3) **是观察测量还是控制验证**：关联的成立仅依赖于在**自然状态**下对数据的**观察与测量**；而因果关系的确立，则必须**依靠实验或统计方法主动控制相关变量**，以进行严格的验证

关联与因果的联系

因果本质上也是一种关联，其在现实世界中引发的可观察现象仍然是变量间的共变模式



因果必然是关联，但关联远不止于因果

关联的三种来源


非因果关联

因果




可解释
稳定/鲁棒
可决策

混淆偏差






虚假关联: 当忽略 X 时,
T 和 Y 相关

选择偏差



虚假关联: 当给定 S
时, T 和 Y 相关




混淆偏差的定义

定义：两个变量T和Y之间由于一个**共同的原因变量X**产生的非因果关联

混淆变量：共同的原因变量X


真实的因果效应：当**控制混淆变量不变时**，**改变变量T**引起的变量Y的变化



混淆偏差的案例




- 下雨是行人撑伞与地面变湿的**共同原因**，即**混淆变量**
- 当控制天气这一条件不变时，行人撑伞与否**不会影响**地面的干湿状态，反之亦然



混淆偏差的案例：读书是否有用？

The association between education and income

There is a clear correlation between years of education and income. But does this mean there is also causation?




The figure uses data from Angrist and Krueger (1991). People with 12 years of education have incomes that are 12 per cent higher than those of people with 11 years of education. People with 16 years of education have 65 per cent higher incomes than people with 11 years of education.

高中毕业

大学毕业

©Johan Jarnestad/The Royal Swedish Academy of Sciences

- 高中毕业 v.s. 高中肄业：12%
- 大学毕业 v.s. 高中毕业：53%
- 高出来的收入是否是“因为”多读了几年书？




选择偏差的定义


定义：两个变量T和Y之间由于**非随机样本选择**而**控制了一个共同的结果变量S**产生的非因果关联

非随机样本选择：收集样本过程中**受到某些变量的影响**，导致收集到的样本并非从总体随机采样的代表性样本

真实的因果效应：当**未控制共同结果变量**时，**改变变量T**引起的变量Y的变化




选择偏差的案例



Credit: Cameron Moll


“二战”期间，为了加强对战机的防护，英美军方调查了作战后幸存飞机上弹痕的分布，决定哪里弹痕多就加强哪里。然而统计学家沃德力排众议，指出更应该注意弹痕少的部位，因为**这些部位受到重创的战机，很难有机会返航**，而这部分数据被忽略了。事实证明，沃德是正确的。

选择偏差的案例




Credit: Cameron Moll

- 样本中只包含了“幸存者”，而幸存与否与中弹位置和受损程度都有关，是**非随机样本选择**
- 是否幸存是中弹位置与受损程度的**共同结果**




选择偏差的案例



Credit: Cameron Moll


- 在控制了“幸存者”这一条件后，返航的大部分飞机，机翼受损严重
- 不控制“幸存者”条件，机尾引擎部位中弹的飞机受损更严重，甚至无法返航



读书是否有用？

The association between education and income

There is a clear correlation between years of education and income. But does this mean there is also causation?



The figure uses data from Angrist and Krueger (1991). People with 12 years of education have incomes that are 12 per cent higher than those of people with 11 years of education. People with 16 years of education have 65 per cent higher incomes than people with 11 years of education.


高中毕业

大学毕业

©Johan Jarnestad/The Royal Swedish Academy of Sciences


- 高中毕业 v.s. 高中肄业：12%
- 大学毕业 v.s. 高中毕业：53%

- 高出来的收入是否是“因为”多读了几年书？



直接做随机对照实验

评估教育对收入的影响




- 分析读书与收入之间的因果效应
 - 随机对照实验：做实验、发问卷
 - 干预变量 $T=1/0$ ：是否高中毕业
 - 结果变量 Y ：收入
- 实际应用中，RCT也可能存在选择偏差
 - 如高中毕业但收入低的受访者，不愿意回答
 - 而高中未毕业但收入高的，非常愿意回答
 - 选择变量 S ，由 T 和 Y （甚至 X ）同时影响
 - $S=1$ ： X, T, Y
 - $S=0$ ： X, T

常见误区：非随机样本选择 = 选择偏差？

非随机样本选择：收集样本过程中受到某些变量的影响，导致收集到的样本并非从总体随机采样的代表性样本

并非所有的非随机样本选择都会导致选择偏差


当且仅当非随机样本选择与关心的原因变量和结果变量相关时，才会引起两者之间的选择偏差



不引发选择偏差的非随机样本选择案例



- 研究时只收集了浙江大学一所学校的样本，导致由学校引发的非随机样本选择
- 学校本身与下课铃声是否响起和学生们是否走出教室无关，该非随机样本选择不会影响二者之间的分析结论



小结

- 人工智能的学习特点：数据驱动、**关联学习**、概率输出
- 关联有三种来源：**因果关系**、混淆偏差和选择偏差，后两者产生的关联称之为**虚假关联**
- 人工智能方法在关联学习过程中未能区分因果关联和虚假关联，会导致不可解释、不可决策、不稳定等不能


**甄别因果关联，由关联到因果的跨越，
实现“知其然，并知其所以然”的人工智能**

1.2 潜在结果框架

潜在结果框架



Donald B Rubin
哈佛大学
统计学院教授
美国国家科学院院士



- 潜在结果框架又被称为Rubin因果模型
- 用数学符号形式化地定义了因果相关概念
- 是现代因果推断的基石

如何形式化地表示因果关系？

因果的定义：在控制相关变量不变的前提下，当一个变量（因）的取值发生变化时，另一个变量（果）的取值也会发生相应的改变

关键问题：

- 如何表示“控制相关变量不变”？
- 如何表示在“控制相关变量不变”的条件下“原因变量的改变”？
- 如何表示在“控制相关变量不变的条件下对原因变量的改变”这一干预行为导致的“结果变量的改变”？

因果效应估计

- 干预变量: $T = 1$ 或 $T = 0$
- 潜在结果变量: $Y(T = 1)$ 和 $Y(T = 0)$
- 个体因果效应 (Individual Treatment Effect, ITE) :

$$ITE(i) = Y_i(T_i = 1) - Y_i(T_i = 0)$$

- 平均因果效应 (Average Treatment Effect, ATE) :

$$ATE = E[Y(T = 1) - Y(T = 0)]$$

- 反事实问题: $Y(T = 1)$ 或 $Y(T = 0)$



两个关键条件: 保持其他所有变量不变, 改变T

理想方案：存在平行世界

假设存在平行世界（真实世界和平行世界）

- 在真实世界和平行世界上，除原因变量以外所有的变量都是一样的——“控制相关变量不变”




理想方案：存在平行世界

假设存在平行世界（真实世界和平行世界）

- 在真实世界和平行世界上，不对其他变量做任何变动的前提下，分别对原因变量施加不同的值，观察结果变量的变化——“控制相关变量不变”的条件下“原因变量的改变”



$T = 1$



$T = 0$


理想方案：存在平行世界

假设存在平行世界（真实世界和平行世界）

- 在真实世界和平行世界上，不对其他变量做任何变动的前提下，分别对原因变量施加不同的值，观察结果变量的变化——“**控制相关变量不变的条件下对原因变量的改变**”这一干预行为导致的“**结果变量的改变**”




$Y(T = 1)$



$Y(T = 0)$

金标准---随机实验



- 随机实验的缺点：
 - 耗钱，耗时，耗力
 - 很多时候可能存在伦理问题

个体因果效应

- **个体因果效应**：在潜在结果框架下，个体 i 在干预 t 相对于干预 t' 下的个体因果效应，记作 τ_i ，由其潜在结果的差值衡量： $\tau_i(t, t') = y_i(t) - y_i(t')$ 。此处， t' 代表基准或对照干预。
- **真实案例**：
 - 研究某降压药物（T）对患者血压（Y）的因果效应
 - 在某一时刻，某患者 i 在不服用降压药（ $t_i = 0$ ）时的血压为140mmHg，即其未接受药物治疗的潜在结果 $y_i(0) = 140$
 - 在平行宇宙中，同一时刻同一患者服用了降压药（ $t_i = 1$ ），血压变为130mmHg，即其接受药物治疗的潜在结果 $y_i(1) = 130$
 - 个体处理效应 $\tau_i(1,0) = y_i(1) - y_i(0) = -10$
- **反事实问题**：只能观测到一种干预下的潜在结果， $y_i(t)$ 或 $y_i(t')$
- 个体因果效应在真实观测世界中**不可识别**！

平均因果效应

- **平均因果效应**：在潜在结果框架下，目标人群的平均因果效应（Average Treatment Effect, 简称ATE）为潜在结果在目标人群中的期望之差： $\tau = E_i[y_i(1) - y_i(0)] = E[Y(1)] - E[Y(0)]$ 。
- 衡量了原因变量对总体平均的因果效应，**仅用观测结果即可计算**，无需依赖反事实结果
- 总体层面的平均因果效应是否能够准确反映个体的因果效应？

平均因果效应

	T	Y(1)	Y(0)
患者1	1	130 (观测)	140 (未知)
患者2	1	132 (观测)	145 (未知)
患者3	1	128 (观测)	138 (未知)
患者4	1	135 (观测)	142 (未知)
患者5	1	125 (观测)	135 (未知)
患者6	0	132 (未知)	140 (观测)
患者7	0	133 (未知)	145 (观测)
患者8	0	127 (未知)	138 (观测)
患者9	0	133 (未知)	142 (观测)
患者10	0	125 (未知)	135 (观测)

- T: 是否服用降压药物
- Y: 血压 (mmHg)
- 处理组平均血压:
 $(130+132+128+135+125)/5=130$
- 对照组平均血压:
 $(140+145+138+142+135)/5=140$
- 平均因果效应 $\tau = E[Y(1)] - E[Y(0)] = 130 - 140 = -10$

平均因果效应

	T	Y(1)	Y(0)	Y(1)-Y(0)
患者1	1	130（观测）	140（未知）	-10
患者2	1	132（观测）	145（未知）	-13
患者3	1	128（观测）	138（未知）	-10
患者4	1	135（观测）	142（未知）	-7
患者5	1	125（观测）	135（未知）	-10
患者6	0	132（未知）	140（观测）	-8
患者7	0	133（未知）	145（观测）	-12
患者8	0	127（未知）	138（观测）	-11
患者9	0	133（未知）	142（观测）	-9
患者10	0	125（未知）	135（观测）	-10

- ATE为-10
- 仅患者1、3、5、10的ITE等于ATE
- 对患者2、7、8而言，用ATE指导用药会导致血压偏低
- 对患者4、6、9而言，用ATE指导用药会导致血压偏高
- ATE无法充分揭示处理效果在个体层面的多样性与复杂性

条件平均因果效应

- **条件平均因果效应**：在潜在结果框架下，条件平均因果效应（Conditional Average Treatment Effect, 简称CATE）定义为在给定一组协变量 $X = x$ 条件下，个体处理效应的期望值，其数学表达如下：
$$\tau(x) = E_i[y_i(1) - y_i(0)|x_i = x] = E[Y(1)|X = x] - E[Y(0)|X = x]。$$
- 衡量了原因变量在具有特定协变量取值的子群体中的因果效应，**仅用观测结果即可计算**，无需依赖反事实结果
- 条件平均因果效应是否能够准确反映个体的因果效应？

条件平均因果效应

	T	Y(1)	Y(0)	X
患者1	1	130（观测）	140（未知）	<60
患者2	1	132（观测）	145（未知）	≥60
患者3	1	128（观测）	138（未知）	≥60
患者4	1	135（观测）	142（未知）	<60
患者5	1	125（观测）	135（未知）	≥60
患者6	0	132（未知）	140（观测）	<60
患者7	0	133（未知）	145（观测）	≥60
患者8	0	127（未知）	138（观测）	≥60
患者9	0	133（未知）	142（观测）	<60
患者10	0	125（未知）	135（观测）	<60

- X：年龄分组
- <60岁群体
 - 处理组平均血压
 $(128+135)/2=132.5$
 - 对照组平均血压
 $(140+142+135)/3=139$
 - CATE=132.5-139=-6.5
- ≥60岁群体
 - 处理组平均血压
 $(132+128+125)/3=128.33$
 - 对照组平均血压
 $(145+138)/2=141.5$
 - CATE=128.33-141.5=-13.17

条件平均因果效应

	T	Y(1)	Y(0)	ITE	X
患者1	1	130（观测）	140（未知）	-10	<60
患者2	1	132（观测）	145（未知）	-13	≥60
患者3	1	128（观测）	138（未知）	-10	≥60
患者4	1	135（观测）	142（未知）	-7	<60
患者5	1	125（观测）	135（未知）	-10	≥60
患者6	0	132（未知）	140（观测）	-8	<60
患者7	0	133（未知）	145（观测）	-12	≥60
患者8	0	127（未知）	138（观测）	-11	≥60
患者9	0	133（未知）	142（观测）	-9	<60
患者10	0	125（未知）	135（观测）	-10	<60

- ATE为-10
- <60岁群体
 - CATE为-6.5
 - 对于患者4、6而言，CATE比ATE更逼近ITE
- ≥60岁群体
 - CATE为-13.17
 - 对于患者2、7而言，CATE比ATE更逼近ITE
- CATE能够得到“该降压药对于年长者效果更好”这一额外信息

各种因果效应的对比

- 个体因果效应：最精细、支撑个体层面分析，但不可识别
- 平均因果效应：最粗糙、支撑总体层面分析，可识别，但当总体中个体之间异质性较大时不能准确反映个体因果效应
- 条件平均因果效应：粒度适中、支撑子群体层面分析，可识别，若子群体划分得当，能够更准确地反映总体中少数特殊个体的因果效应，但当子群体内个体之间异质性较大时也无法准确反映个体因果效应
 - 当条件集合（子群体划分粒度）趋于无穷大，且样本量充足时，条件平均因果效应无限逼近于个体因果效应

潜在结果框架下的可识别假设



平均因果效应和条件平均因果效应尽管可识别，但也需要观测数据满足一定的假设

- **稳定单元处理值假设** (Stable Unit Treatment Value Assumption, 简称SUTVA)：一个个体的原因变量不会影响另一个个体的结果；同一处理对所有个体的作用都相同，即不存在不同的处理版本
- **条件可忽略性/无混淆假设** (ignorability/unconfoundedness)：在给定一组充分的协变量 X 后原因变量与潜在结果独立，即 $(Y(1), Y(0)) \perp T | X$
- **正值性/重叠假设** (positivity/overlap)：对于任何协变量组合的个体，都有既可能接受处理也可能不接受处理的正概率，也有既可能被选入样本也可能未被选入样本的正概率，即 $0 < P(T = 1 | X = x) < 1$ 且 $0 < P(S = 1 | X = x) < 1$ ，其中 S 是样本选择机制， $s_i = 1$ 表示个体 i 被选入样本， $s_i = 0$ 表示个体 i 未被选入样本

Causal Inference – 因果推理

The official journal of the [Chinese Academy of Engineering](http://www.engineering.org.cn/)

Survey Paper: Causal Inference (因果推理)




Kuang, K., Li, L., Geng, Z., Xu, L., Zhang, K., Liao, B., Huang, H., Ding, P., Miao, W., Jiang, Z. (2020).
Causal Inference. *Engineering*. <http://www.engineering.org.cn/ch/10.1016/j.eng.2019.08.016>

Causal Inference – 因果推理

• Engineering 综述论文


- 况琨：平均因果效应评估-简要回顾与展望
- 李廉：反事实推理的归因问题
- 耿直：辛普森悖论和替代指标悖论
- 徐雷：因果发现CPT（因果势理论）方法
- 张坤：从观测数据中发现因果关系
- 廖备水，黄华新：形式论辩在因果推理和解释中的作用
- 丁鹏：复杂实验中的因果推断
- 苗旺：观察性研究中的工具变量和阴性对照方法
- 蒋智超：有干扰下的因果推断



基础理论——复杂环境下因果推断

• 复杂环境下因果推断的三大挑战


- 关键信息缺失、数据偏差多样、干预变量复杂



复杂偏差下因果推断


2021诺贝尔经济学奖：
基于工具变量的因果推断

2000诺贝尔经济学奖：
面向选择偏差的因果推断




可解释
稳定/鲁棒
可决策

混淆偏差



虚假关联: T is
correlated with Y
ignoring X

选择偏差



虚假相关: T is
correlated with Y
given S

同时存在混淆偏差和选择偏差，（条件）工具变量

Continuous/Complex treatment effect estimation






Fig. 1. An example of complex treatments.



Yingrong Wang, Haoxuan Li, Minqin Zhu, Anpeng Wu, Ruoxuan Xiong, Fei Wu, Kun Kuang*. Causal Inference with Complex Treatments: A Survey, ACM Computing Surveys, 2026.


Some working papers

- Causal Inference with Delayed Response




Some working papers


- Short-term and Long-term Treatment Effects



(a) Surrogate setting.





(b) Common setting.



(c) A medical case in the short-term and in the long-term.

Some working papers

- Precise causal effect == accurate decision?




1.3 结构因果模型

结构因果模型



Judea Pearl
加州大学洛杉矶分校
计算机科学教授
美国国家科学院院士，图灵奖得主



- 结构因果模型，
Structural Causal
Model，简称SCM
- 从图论的角度定义
因果，更加直观
- 是现代因果发现的
基石


如何形式化地表示因果关系？

因果的定义：在控制相关变量不变的前提下，当一个变量（因）的取值发生变化时，另一个变量（果）的取值也会发生相应的改变

- 用因果图来形式化地描述变量间的因果关系——谁是谁的因，谁是谁的果
- 用结构方程来量化变量间的因果效应——每个因变量对于该变量的因果效应
- 用do算子来刻画“控制相关变量不变，改变因变量取值”这一干预过程

因果图和结构方程

- **因果图**： Judea Pearl 1995年提出。一般而言，因果图是一个由节点和带箭头的边（有向边）组成的**有向无环图(directed acyclic graphs, DAG)**。其中，节点表示我们研究中的变量（如A、B、C），有向边表示因果关系，从原因指向结果（如 $A \rightarrow B$ 表示A是B的一个原因）。**因果图能表示变量间因果关系的原因在于表示变量间的条件独立性**
- **结构方程**：结构方程描述了因果图中变量之间的确定性**生成机制**，由**变量**（如A、B、C）、**生成函数**（如 f_B 、 f_C ）和**随机误差**（如 ϵ_B 、 ϵ_C ）构成。例如，因果图 $A \rightarrow B \rightarrow C$ 对应的结构方程为 $B = f_B(A, \epsilon_B)$ ， $C = f_C(B, \epsilon_C)$




因果中的原因

- **因果图中的原因**：在因果图中，若变量 Y 是另一个变量 X 的孩子，则 X 是 Y 的直接原因；若 Y 是 X 的后代，则 X 是 Y 的潜在原因。
- **结构方程中的原因**：如果变量 X 出现在给变量 Y 赋值的函数中，如 $Y = f(X) + \varepsilon$ ，则 X 是 Y 的直接原因(direct cause)。如果 X 是 Y 的直接原因或者其他原因，均称 X 是 Y 的原因。

每个结构方程 M 都与一个因果图 G 相对应。因果图中的节点是结构因果模型中所包括的变量，节点之间的边表示函数 f 。在 M 中，若变量 X 的函数 f_z 包含了变量 Y （ X 的取值依赖于 Y ），则在 G 中有一条从 Y 到 Z 的有向边。

我们主要讨论**因果图为有向无环图的结构因果模型**。

$$Z = f(X, Y) = 2X + 5Y$$



商品销量 Z ，与其他商品的价格差 X 和广告费 Y 的因果图

因果图中联合概率分布

对于任意的有向无环图模型，模型中 d 个变量的联合概率分布由每个节点与其父节点之间条件概率 $P(child|parents)$ 的乘积给出：

$$P(x_1, x_2, \dots, x_d) = \prod_{j=1}^d P(x_j | x_{pa(j)})$$


其中， $x_{pa(j)}$ 表示节点 x_j 的父节点集合（所有指向 x_j 的节点）。

为什么可以这样给出拆解联合概率分布？变量之间某种普遍成立的独立性假设。

对于一个简单的链式图 $X \rightarrow Y \rightarrow Z$ ，其联合概率分布可直接写成：

$$P(X = x, Y = y, Z = z) = P(X = x)P(Y = y|X = x)P(Z = z|Y = y)$$


因果图中联合概率分布



$$\begin{aligned} &P(X_1, X_2, X_3, X_4, X_5, X_6, X_i, X_j) \\ &= P(X_2) \times P(X_3) \times P(X_1 | X_2, X_3, X_i) \times P(X_4 | X_2) \times P(X_5 | X_3) \\ &\quad \times P(X_6 | X_i) \times P(X_i | X_4) \times P(X_j | X_1, X_5, X_6) \end{aligned}$$

因果图基本结构：链结构

链(chain): 链是因果图的一种基本结构。它包含三个节点两条边，其中一条边由第一个节点指向第二个节点，另一条边由第二个节点指向第三个节点。



链式因果图

链中的条件独立性: 对于变量 X 和 Y ，若 X 和 Y 之间只有一条单向的路径，变量 Z 是截断(intercept)该路径的集合中的任一变量，则在给定 Z 时， X 和 Y 条件独立。


$$P(X, Y|Z) = P(X|Z)P(Y|Z)$$

即在链式图 $X \rightarrow Z \rightarrow Y$ 中， X 和 Y 在给定 Z 时条件独立。

其中，上式的第一步使用了条件概率的定义，第二步使用了乘积分解规则，最后一步使用了贝叶斯公式 $P(X)P(Z|X) = P(Z)P(X|Z) = P(X, Z)$ 。

因果图基本结构：链结构

链式图 $X \rightarrow Z \rightarrow Y$ 中， X 和 Y 在给定 Z 时条件独立也可以这样理解：在给定 Z 时，若 X 的取值发生变化，则为了维持 Z 的取值不变， U_2 的取值会发生变化；而由于 Y 的取值只依赖于 Z 和 U_3 ，但 Z 是给定的，因此 Y 的取值不会发生变化。也就是说，给定 Z 时， X 的取值不会影响 Y 的取值，因此给定 Z 时， Y 和 X 是条件独立的。




链式因果图

因果图基本结构：分连结构

分连(fork): 分连也是因果图的一种基本结构。它包含三个节点两条边，两条边分别由第一个节点指向第二个节点和第三个节点。

分连中的条件独立性: 若变量 Z 是变量 X 和 Y 的共同原因，且 X 到 Y 只有一条路径，则在给定 Z 时， X 和 Y 条件独立。



分连因果图

$$P(X, Y|Z) = P(X|Z)P(Y|Z)$$


在分连结构中，给定 Z 时， X 和 Y 的联合概率：

$$P(X, Y|Z) = \frac{P(X, Y, Z)}{P(Z)} = \frac{P(Z)P(X|Z)P(Y|Z)}{P(Z)} = P(X|Z)P(Y|Z)$$

即在分连图 $X \leftarrow Z \rightarrow Y$ 中， X 和 Y 在给定 Z 时条件独立。上式的第一步使用了条件概率的定义，第二步使用了乘积分解规则。

因果图基本结构：分连结构

在分连图 $X \leftarrow Z \rightarrow Y$ 中， X 和 Y 在给定 Z 时条件独立可以这样理解：若给定 Z ， Y 和 X 的取值不会变化，它们的值只会分别随 U_3 和 U_2 变化，因此给定 Z 时， Y 和 X 是条件独立的。




分连因果图

因果图基本结构：汇连结构

汇连(collider): 汇连(又叫碰撞)也是因果图的一种基本结构。它包含三个节点两条边，两条边分别由第一个节点和第二个节点指向第三个节点。

汇连中的条件独立性: 若变量 Z 是变量 X 和 Y 的汇连节点，且 X 到 Y 只有一条路径，则 X 和 Y 相互独立，但在给定 Z 时， X 和 Y 是相关的。



汇连因果图

在汇连结构中，给定 Z 时， X 和 Y 的联合概率：


$$P(X, Y|Z) = \frac{P(X, Y, Z)}{P(Z)} = \frac{P(X)P(Y)P(Z|X, Y)}{P(Z)} \neq P(X|Z)P(Y|Z)$$

即在汇连图 $X \rightarrow Z \leftarrow Y$ 中， X 和 Y 在给定 Z 时条件相关。上式的第一步使用了条件概率的定义，第二步使用了乘积分解规则。

因果图基本结构：汇连结构

在汇连图 $X \rightarrow Z \leftarrow Y$ 中， X 和 Y 在给定 Z 时条件相关可以这样理解：给定 Z ，当 X 的取值发生变化时，为了保证 Z 的取值不变， Y 的取值也一定会发生变化，因而给定 Z 时， Y 和 X 是相关的。

例如假定 $Z = 10$ ， $U_3 = 1$ ，当 X 取值为3时， Y 的取值为6；当 X 的取值为4时， Y 的取值为5；当 X 取值为8时， Y 的取值为1。也就是说，给定 Z 时， Y 的取值会随 X 的取值变化而变化，因此，给定 Z 时， Y 和 X 是相关的。




汇连因果图

因果图基本结构：汇连结构


汇连中的条件独立性：若变量 Z 是变量 X 和 Y 的汇连节点，且 X 到 Y 只有一条路径，则 X 和 Y 相互独立，但在给定 Z 或 Z 的后代时， X 和 Y 是相关的。

对于上述定理中，给定 Z 的后代， X 和 Y 是相关的，可以这样理解：不妨设 Z 的某个后代为 W ，给定 W 时，则 W 的祖先也给定， W 的祖先给定时，则 W 的祖先的祖先也给定.....因为 Z 是 W 的祖先，因此 Z 也会给定，此时， X 和 Y 是相关的。




汇连因果图


因果图基本结构




链式因果图



分连因果图



汇连因果图



因果图主要由{链式, 分连, 汇连}构成

d-分离与条件独立性

D-分离(directional separation, d -separation), 可用于判断任意两个节点的相关性和独立性。若存在一条路径将这两个节点 (**直接**) 连通, 则称这两个节点是有向连接(d -connected)的, 即这两个节点是相关的; 若不存在这样的路径将这两个节点连通, 则这两个节点不是有向连接的, 则称这两个节点是有向分离的(d -separated), 即这两个节点相互独立。

D-分离: 路径 p 被限定集 Z 阻塞(block)当且仅当:

- (1) 路径 p 含有链结构 $A \rightarrow B \rightarrow C$ 或分连结构 $A \leftarrow B \rightarrow C$ 且中间节点 B 在 Z 中, **或**
- (2) 路径 p 含有汇连结构 $A \rightarrow B \leftarrow C$ 且汇连节点 B 及其后代都不在 Z 中。

若 Z 阻塞了节点 X 和节点 Y 之间的每一条路径, 则称给定 Z 时, X 和 Y 是 D -分离, 即给定 Z 时, X 和 Y 条件独立。

d-分离与条件独立性

例 分析如下因果图中节点的关系


不妨考虑 X 和 T 的关系：

(1)若限定集为 $\emptyset$ 时， X 和 T 相互独立。因为 X 和 T 之间含有一个汇连结构 $X \rightarrow Z \leftarrow Y$ ，且 Z 及其后代都不在限定集 $\emptyset$ 中，此时 X 和 T 是有向分离，即 X 和 T 相互独立；

(2)若限定集为 $\{W, Y\}$ 时， X 和 T 条件独立。因为 X 和 T 之间只有一条路径，且这条路径含有一个分连结构 $Z \leftarrow Y \rightarrow S$ ，且 Y 在限定集 $\{W, Y\}$ 中，因此 Y 阻塞了 X 和 T 之间的唯一路径， X 和 T 是有向分离，即限定集为 $\{W, Y\}$ 时， X 和 T 条件独立。


(3)若限定集为 $\{W\}$ 时， X 和 T 的关系是？

若限定集为 $\{W\}$ 时， X 和 T 是相关的。因为 X 和 T 之间含有一个链式结构 $Y \rightarrow S \rightarrow T$ (S 不在限定集中)，一个分连结构 $Z \leftarrow Y \rightarrow S$ (Y 不在限定集 $\{W\}$ 中)，一个汇连结构 $X \rightarrow Z \leftarrow Y$ (Z 的后代 W 在限定集 $\{W\}$ 中)，根据 D -分离的定义，这些结构都无法阻塞 X 和 T 之间的路径，因此 X 和 T 是有向连接的，即 X 和 T 是相关的；




包含链、分连和
汇连结构的因果图

结构因果模型下的偏差



(a) 混淆偏差



(b) 选择偏差

混淆偏差：

- 存在因未控制混淆变量 X 导致未阻塞的混淆路径 $T \leftarrow X \rightarrow Y$

选择偏差：

- 存在因控制了对撞变量 S 导致未阻塞的对撞路径 $T \rightarrow S \leftarrow Y$


do-算子

观测数据分布 $P(Y|T)$ ：在自然状态下，在观察到原因变量 T 自然取值为 t 时结果变量 Y 的概率分布

- 没有控制混淆变量，混淆路径未被阻塞，包含了混淆偏差

do-算子： $do(T=t)$ 表示通过外部干预，强制将总体中每一个个体的原因变量 T 的值都设定为 t

- T 的取值就不再受其他变量影响，在因果图上相当于删除所有指向 T 的边



do-算子

经过do-算子的干预之后，得到干预分布 $P(Y|do(T = t))$ ：
通过外部干预，强制将总体中每一个个体的原因变量T的值都设定为t时，结果变量Y的概率分布

- 因删除前序路径而去除了所有混淆路径，没有偏差

真实案例：某降压药（T）对患者血压（Y）的研究

- 观察分布 $P(Y|T=1)$ 回答的问题是：“在自然状态下，我们观察到的那些服了药的患者，他们的血压分布是怎样的？”

(混杂了患者自选择的偏差)


- 干预分布 $P(Y|do(T=1))$ 回答的问题是：“如果我们通过随机化试验，强制让全体患者都服药，他们的血压分布会是怎样的？”

do-算子：因果效应差

X 表示用药情况(1表示用药, 0表示不用药), Y 表示病人的恢复情况(1表示恢复, 0表示未恢复), Z 表示性别(1表示男性, 0表示女性)。为了比较病人用药与否的恢复情况, 可以对用药情况分别进行干预, 即将病人都分别固定成用药病人和不用药病人。不妨设 $do(X = 1)$ 和 $do(X = 0)$ 分别表示这两种干预, 并估计其中的差别:

$$P(Y = 1|do(X = 1)) - P(Y = 1|do(X = 0))$$


这被称为“因果效应差” (causal effect difference)或“平均因果效应” (average causal effect, ACE)。



因果图

do-算子：因果效应差

对用药情况 X 进行干预并固定其值为 x 时，可将所有指向 X 的边均移除，则因果效应 $P(Y = y|do(X = x))$ 等价于图所示的引入干预的操纵图模型(manipulated model)中的条件概率 $P_m(Y = y|X = x)$ 。



引入干预的操纵图模型

$$P(Y = y|do(X = x)) = P_m(Y = y|X = x)$$


do-算子的效果可以通过修改图结构后在新图上计算普通条件概率来实现

do-算子：因果效应差


计算因果效应的关键在于计算操纵概率(manipulated probability) P_m 。 P_m 与正常(无干预)条件下的概率 P 有两个相同的重要性质：(1) 边缘概率 $P(Z = z)$ 不随干预而变化，因为 Z 的取值不会因为去掉从 Z 到 X 的箭头而变化；(2) 条件概率 $P(Y = y|X = x, Z = z)$ 不变，因为 Y 关于 X 和 Z 的函数 $f_Y = (X, Z, U_2)$ 并未改变。因此，有如下等式：

$$P_m(Y = y|X = x, Z = z) = P(Y = y|X = x, Z = z),$$

$$P_m(Z = z) = P(Z = z)$$



因果图



引入干预的操纵图模型


do-算子：因果效应差

目标：将 $P(Y = y|do(X = x))$ 用观测概率 P 表达。


第一步：do算子的含义

$do(X = x)$ 表示在操纵图（mutilated graph）中将 X 强制设为 x ，此时的概率分布记为 P_m 。
根据定义：

$$P(Y = y|do(X = x)) = P_m(Y = y|X = x)$$



因果图



引入干预的操纵图模型

do-算子：因果效应差

第二步：用条件版全概率公式对 Z 展开

在操纵图的概率分布 P_m 下，对 Z 应用条件版全概率公式：

$$P_m(Y = y|X = x) = \sum_z P_m(Y = y, Z = z|X = x)$$

对右边的联合条件概率用乘法法则拆开：

$$P_m(Y = y, Z = z|X = x) = P_m(Y = y|X = x, Z = z) \cdot P_m(Z = z|X = x)$$

代入得：

$$P_m(Y = y|X = x) = \sum_z P_m(Y = y|X = x, Z = z) \cdot P_m(Z = z|X = x) \quad \dots(1)$$

do-算子：因果效应差

$$P_m(Y = y|X = x) = \sum_z P_m(Y = y|X = x, Z = z) \cdot P_m(Z = z|X = x) \quad \dots(1)$$


第三步：利用操纵图中的 d-分离性质

在操纵图中，指向 X 的所有边被切断，因此 X 和 Z 是 d-分离的。d-分离意味着条件独立：

$$X \perp Z \text{ in } G_m \implies P_m(Z = z|X = x) = P_m(Z = z)$$

代入式(1)：

$$P_m(Y = y|X = x) = \sum_z P_m(Y = y|X = x, Z = z) \cdot P_m(Z = z) \quad \dots(2)$$



引入干预的操纵图模型

do-算子：因果效应差

$$P_m(Y = y|X = x) = \sum_z P_m(Y = y|X = x, Z = z) \cdot P_m(Z = z) \quad \dots(2)$$

第四步：将操纵图概率替换为观测概率

需要用到两个等式：

等式 A: $P_m(Y = y|X = x, Z = z) = P(Y = y|X = x, Z = z)$

这是因为在给定 X 和 Z 后， Y 的生成机制（即 $X \rightarrow Y$ 和 $Z \rightarrow Y$ 的因果机制）在操纵前后没有被改变，被切断的只是指向 X 的边，不影响 Y 的条件分布。


等式 B: $P_m(Z = z) = P(Z = z)$

这是因为操纵只切断了指向 X 的边， Z 的生成机制（由 U_3 等变量决定）完全没有被触动，所以 Z 的边际分布不变。


将等式 A 和 B 代入式(2)：

$$P(Y = y|do(X = x)) = \sum_z P(Y = y|X = x, Z = z) \cdot P(Z = z)$$

这就是调整公式（adjustment formula）。



因果图



引入干预的操纵图模型

do-算子：因果效应差


$$\begin{aligned} P(Y=y|do(X=x)) &\xrightarrow{\text{do的定义}} P_m(Y=y|X=x) \xrightarrow{\text{全概率展开}} \sum_z P_m(Y=y|X=x, Z=z) \cdot P_m(Z=z|X=x) \\ &\xrightarrow{\text{d-分离}} \sum_z P_m(Y=y|X=x, Z=z) \cdot P_m(Z=z) \xrightarrow{\text{机制不变性}} \sum_z P(Y=y|X=x, Z=z) \cdot P(Z=z) \end{aligned}$$

do-算子：因果效应差


得到如下正常(无干预)条件下的概率表示的因果效应：

$$P(Y = y | do(X = x)) = \sum_z P(Y = y | X = x, Z = z) P(Z = z)$$

这被称为调整公式(adjustment formula)，对于 Z 的每一个取值 z ，计算 X 和 Y 的条件概率并取均值。**这个过程称之为“ Z 调整” (adjusting for Z)或“ Z 控制” (controlling for Z)**。式2.4的右端只包含正常(无干预)条件下的概率 P ，即可用正常(无干预)条件下的条件概率来计算干预后的条件概率。



因果图



引入干预的操纵图模型

例子：do-算子计算因果效应差

	不用药	用药
恢复人数	289	273
总人数	350	350
恢复率(%)	83	78

表1 某组病人在是否尝试新药以后的恢复情况

	不用药		用药	
	男性	女性	男性	女性
恢复人数	234	55	81	192
总人数	270	80	87	263
恢复率(%)	87	69	93	73

表2 以性别分组后的某组病人在是否尝试新药以后的恢复情况
用药男性和用药女性的恢复率均高于相应性别。

辛普森悖论：汇总数据与分组数据给出了相反的结论，根源在于性别既影响用药倾向又影响恢复率，是一个混淆变量。

例子：用调整公式来计算真正的因果效应

其中 $X = 1$ 表示用药， $Y = 1$ 表示病人恢复， $Z = 1$ 表示男性， $Z = 0$ 表示女性，则有：

$$P(Y = 1|do(X = 1))$$

$$= P(Y = 1|X = 1, Z = 1)P(Z = 1) + P(Y = 1|X = 1, Z = 0)P(Z = 0)$$

代入表2的数据，则将病人干预为用药病人的因果效应为：

$$P(Y = 1|do(X = 1)) = 0.93 \times \frac{(87 + 270)}{(350 + 350)} + 0.73 \times \frac{(263 + 80)}{(350 + 350)} = 0.832$$

类似地，将病人干预为不用药病人的因果效应为：

$$P(Y = 1|do(X = 0)) = 0.87 \times \frac{(87 + 270)}{(350 + 350)} + 0.69 \times \frac{(263 + 80)}{(350 + 350)} = 0.7818$$

在分别计算完用药病人和不用药病人的干预因果效应后，再计算其因果效应差：

$$ACE = P(Y = 1|do(X = 1)) - P(Y = 1|do(X = 0)) = 0.832 - 0.7818 = 0.0502$$

说明用药病人的恢复率高于不用药病人的恢复率，即该新药能帮助治愈病人。

注意：先前有 $P(Y = 1|X = 1) = 0.78$ 和 $P(Y = 1|X = 0) = 0.83$ 。因此可见如果不加干预仅从原始数据归纳所得条件概率无法得到正确结论（存在辛普森悖论）。

结构因果模型下的因果效应

个体因果效应: $\tau_i = y_i|do(T = 1) - y_i|do(T = 0)$

平均因果效应: $\tau = E[Y|do(T = 1)] - E[Y|do(T = 0)]$

条件平均因果效应: $\tau(x) = E[Y|do(T = 1), X = x] - E[Y|do(T = 0)|X = x]$

- 个体因果效应衡量的是单个个体在两种干预下结果的差异
- 平均因果效应是对整个总体取期望
- 条件平均因果效应则是在给定某些协变量取值下的因果效应



与潜在结果框架的区别:

- 采用do-算子而非潜在结果来定义因果效应, 无需潜在结果框架下的可识别性假设
- 观测数据分布难以满足do-算子干预分布, 需要对观测数据进行调整来模拟do-算子干预操作

因果发现

- Conditional independence between each variable pair
 - *Spirtes, Glymour, and Scheines. Causation, Prediction, and Search. 1993.*
 - Illustration: the PC algorithm

X1	X2	X3	X4	X5
-1.1	1	1.3	0.2	-0.7
2.1	2	3.1	-1.3	-1.6
3.1	4.2	-2.6	0.6	2.1
2.3	-0.6	-3.5	0.8	2.3
1.3	-1.7	0.9	2.4	-1.4
-1.8	0.9	-1.3	0.9	0.7
...	...	...	...	...




因果发现

- Conditional independence between each variable pair
 - *Spirtes, Glymour, and Scheines. Causation, Prediction, and Search. 1993.*
 - Illustration: the PC algorithm

X1	X2	X3	X4	X5
-1.1	1	1.3	0.2	-0.7
2.1	2	3.1	-1.3	-1.6
3.1	4.2	-2.6	0.6	2.1
2.3	-0.6	-3.5	0.8	2.3
1.3	-1.7	0.9	2.4	-1.4
-1.8	0.9	-1.3	0.9	0.7
...	...	...	...	...

$X_1 \perp\!\!\!\perp X_5 \mid X_3$
 $X_2 \perp\!\!\!\perp X_4 \mid X_1$
 $X_2 \perp\!\!\!\perp X_5 \mid X_3$
 $X_4 \perp\!\!\!\perp X_5 \mid X_3$
 $X_1 \perp\!\!\!\perp X_3 \mid \{X_2, X_4\}$



小结

- 人工智能的学习特点：数据驱动、关联学习、概率输出
- 关联有三种来源：因果关系、混淆偏差和选择偏差，后两者产生的关联称之为非因果关联
- 因果的理论框架：潜在结果框架与结构因果模型

**甄别因果关联，由关联到因果的跨越，
实现“知其然，并知其所以然”的人工智能**