



浙江大學
ZHEJIANG UNIVERSITY

大模型赋能因果推断与发现

大语言模型 (LLM)

对齐 (Alignment)

与数据空间对齐
与人类指令对齐
与人类反馈对齐

predict the next token

完形填空形式下文字接龙 (自监督学习)

- 原话：一辆 列车 缓慢 行驶 在 崎岖 的山路上
- 移除单词：一辆 列车 行驶 在 崎岖 的山路上
- 预测填空：一辆 列车 缓慢 行驶 在 崎岖 的山路上


supervised fine-tuning

提示学习与指令微调 (人教机学)

第一轮: {"instruction": "本院查明,被告人酒后...
请分析案情。
"output": "根据上述内容, 可以认定本案的核心
要素包括醉酒驾驶、致人受伤、酒后逃逸..."},
第二轮: {"instruction": "根据上述分析, 请预测
罪名。
"output": "本案预测的罪名是危险驾驶罪"},
第三轮: {"instruction": "请给出处罚意见。
"output": "结合嫌疑人逃逸的情节, 建议考虑拘
役三个月, 并罚款6000元}

Reinforcement Learning
from Human Feedback


人类反馈下强化学习 (尝试与探索)



自然语言合成的核心神经网络是Transformer 模型

LLM agent with causal analysis ability

- 基于大语言模型技术，提出了**因果智能体**，协同因果发现和因果推断方法，实现复杂环境下因果发现与因果推断



输入：数据（tabular data），问题描述

输出：问题结论

组成模块：

LLM：问题理解，工具调用，得出结论

Tools：因果分析python库


Memory：临时生成的因果图

行为：面向因果问题的四个方面


1. 数据级别：进行条件独立性检验等
2. 因果边级别：推断边之间的关系
3. 因果图级别：生成完全或部分因果图
4. 因果效应级别：计算ATE和CATE

大数据模型 (LDM)

a TabPFN is trained on synthetic data to take entire datasets as inputs and predict in a forward pass



TabPFN can now be applied to arbitrary
unseen real-world datasets




b Input dataset

	x_1	x_2	y
Test Training rows	1.2	6.1	3.0
	8.9	9.1	3.1
	1.0	2.9	6.7
	33.3	2.2	?



We predict this entry

2D TabPFN layer (12x)



- Each node represents one entry in the table

Predictions: $\hat{y}_{\text{test}}$




LDM for Causal Inference

LDM for Causal Discovery

值得探索的一个方向

LLM+LDM

打通语义空间和数据空间



5.1 大模型赋能因果推断

传统因果推断的三大瓶颈

• 传统因果推断的三大挑战

1. **数据类型局限**：高度依赖结构化表格数据，难以有效处理文本、图像等非结构化数据，导致大量潜在因果信息流失。
2. **领域知识依赖**：构建因果模型需要专家手动设定变量间的初始关系，在复杂领域（如基因组学）中成本极高且易受知识盲区限制。
3. **语义理解薄弱**：无法捕捉自然语言中的隐含因果关系和常识知识，难以理解体现因果强度和传递性的语义表述（如“长期”、“进而”）。

大模型赋能因果推断

大模型赋能的核心逻辑与技术本质

- 大模型赋能：数据与知识双驱动的通用能力
- 大语言模型（LLMs）：深度语义理解、海量知识内化和灵活语言生成的特质。
- 效果：能够自动化处理非结构化数据（如文本、图像），降低对专家知识的依赖，并以自然语言解释推理结果，从而更高效、更广泛地应用于解决复杂现实问题。

大模型赋能因果推断

- **语义理解**：LLMs 可直接解析非结构化文本（如法律文书、社交媒体评论），端到端地提取其中的因果信息和隐含线索，省去了繁琐的人工特征工程，极大扩展了因果推断的数据源范围。
- **知识内化**：LLMs 通过预训练内化海量常识与专业知识，能自主构建和动态更新多步因果链（如医学、金融领域），大幅降低对专家手动输入知识的依赖，显著减少应用成本和专家工时。
- **自然语言交互**：LLMs 能将复杂的因果分析结果（如 ATE、CATE 数值）转化为通俗、可追溯的自然语言解释，说明“为什么有效”和“在什么条件下有效”，提升了结果的可解释性和人机交互性，帮助非专业人士做出更精准的决策。

大模型赋能因果推断

数据处理层扩展：将非结构化文本（如病历、文献）转化为机器可理解的结构化表示，为因果模型提供更丰富的输入数据。

知识注入层强化：自动提取和补充领域内的因果知识，降低了对专家手动构建模型和注入知识的依赖。

推理输出层优化：以自然语言形式清晰呈现因果推理的过程和最终结果，极大提升了因果推断的可解释性和人机交互性。

大模型赋能因果推断的关键技术

- LLMs 应用于因果推断的关键技术可根据“是否修改模型参数”和“是否融合外部方法 / 知识”分为提示工程、微调、融合传统因果方法和知识增强四大类。

1. 提示工程的灵活入门方案
2. 微调的高性能定制方案
3. 融合传统因果方法
4. 知识增强的特定领域适配

1 提示工程的灵活入门方案

1. 基础提示：通过直接的语言指令，让模型完成简单的因果任务。

指令 “提取 ‘吸烟导致肺癌’ 的因果关系”，模型输出 “吸烟→肺癌”。

2. 上下文学习（ICL）：在提示中提供少量示例，引导模型模仿示例的推理方式来解决新问题。

根据示例 “下雨→地湿”，提出问题 “浇水→？”，模型输出 “地湿”。

3. 思维链（CoT）：通过提示引导模型将复杂的因果推理过程分解为多个简单步骤，并逐一回答，从而得出最终结论。

提示 “分步分析 ‘没带伞会淋湿吗？’ （看天气→有无遮蔽→结论）”，模型按步骤推理。

CausalCoT: 因果理论驱动的分步推理

CausalCoT 的核心设计思路是在思维链（CoT）的每一步推理中加入因果理论约束，例如强制模型依次判断变量间是“关联还是因果”、识别“是否存在混杂变量”、并最终确定“因果方向”。

去混杂：针对文本“夏季高温导致冰淇淋销量上升和溺水人数增加”，CausalCoT 会引导模型分步分析，最终准确识别出“夏季高温”是混杂变量，从而避免将“冰淇淋销量→溺水人数”这一关联关系误判为直接因果关系。

CausalCoT: 因果理论驱动的分步推理

Question: Imagine a self-contained, hypothetical world with only the following conditions, and without any unmentioned factors or causal relationships:

Physical vulnerability has a direct effect on the likelihood of **fatality** and **vaccination decision**. **Vaccination** has a direct effect on the **fatality rate**.

In the entire population, 50% of the people are vulnerable to a certain disease.

For vulnerable and vaccinated people, the fatality rate is 4%. For vulnerable and unvaccinated people, the fatality rate is 7%.

For strong and vaccinated people, the fatality rate is 1%. For strong and unvaccinated people, the fatality rate is 5.8%.

Overall, the fatality rate for vaccinated people is 5%, while the fatality rate for unvaccinated people is 4.5%.

Does getting vaccinated increase the likelihood of death?


Ground-Truth Answer: No

CLadder

Correct steps to lead to the ground-truth answer:

1) Parse the **causal graph**: Confounding

Subskill: Causal Relation Extraction



2) Classify the **query type**: Average Treatment Effect

Subskill: Causal Question Classification

3) Formulate the query to its **symbolic form**:

$$E[Y | \text{do}(X=1)] - E[Y | \text{do}(X=0)]$$

Subskill: Formalization

4) Collect the **available data**:

$$P(Z=1)=0.5$$

Subskill: Semantic Parsing

$$P(Y=1|Z=1,X=1)=0.04, P(Y=1|Z=1,X=0)=0.07$$

$$P(Y=1|Z=0,X=1)=0.01, P(Y=1|Z=0,X=0)=0.058$$

$$P(Y=1|X=1)=0.05, P(Y=1|X=0)=0.045$$

5) **Derive the estimand** using **causal inference**:

$$E[Y | \text{do}(X=1)] - E[Y | \text{do}(X=0)]$$

Subskill: Formal Causal Inference

$$= \sum_{Z=v} P(Z=z) [P(Y=1|Z=z, X=1) - P(Y=1|Z=z, X=0)] \quad \# \text{ remove "do" using do-calculus}$$

$$= P(Z=0) [P(Y=1|Z=0, X=1) - P(Y=1|Z=0, X=0)]$$

$$+ P(Z=1) [P(Y=1|Z=1, X=1) - P(Y=1|Z=1, X=0)] \quad \# \text{ turn the expression into terms in the available data}$$

6) **Solve for** the estimand by plugging in the relevant data in Step 4:

$$= 0.5 \cdot (0.01 - 0.058) + 0.5 \cdot (0.04 - 0.07) \quad \# \text{ plug in the numbers in the available data}$$

$$= -0.039$$

Subskill: Arithmetics

< 0 # the effect size is negative, so the final answer is "No"

Example of CausalCoT

2 微调的高性能定制方案

微调是指用**因果推断标注数据**更新 LLMs 参数，使其形成“因果专用模型”。与提示工程相比，其在特定任务上性能更优，但需大量数据和计算资源，且易过拟合。

微调的主要优势在于：

1. **性能优势**：在特定的因果推断任务上，微调能显著提升模型的推理性能和准确性。
2. **适配性优势**：通过参数级别的调整，微调使模型能更深入地适配特定任务，形成更专业的因果推理能力。

3 融合传统因果方法

- 融合方法的核心是“取长补短”，将 LLMs 的语言理解能力与传统因果方法的数学严谨性深度协作，形成“语义理解 + 数值推理”的双引擎模式，常见于**特征提取**等关键环节
- “LLMs + 倾向得分匹配 (PSM)” 是应用广泛的融合模式。

LLMs+PSM：文本混杂变量的处理方案

LLMs + 倾向得分匹配 (PSM) 融合方法，利用 LLMs 处理传统 PSM 无法应对的文本类混杂变量（如病历、评论），将其编码为向量后，再由 PSM 进行样本匹配和因果效应估计，从而更全面地消除混杂变量的影响。

某三甲医院在评估降压药物疗效时发现，仅使用结构化数据的传统 PSM 方法，其 ATE 估计值与临床实际存在偏差；而融合了病历文本编码的“LLMs+PSM”方法，因捕捉到了吸烟史、并发症等关键文本信息，ATE 估计值更精准，准确率比传统方法提升了 28%。

本质：用文本上下文知识帮助PSM估计，实现更准确的因果推断

LLMs+IV：选择偏差的解决路径

“LLMs + 工具变量法（IV）”融合模式适用于存在“选择偏差”的场景，利用 LLMs 的文本分析能力辅助寻找合适的工具变量（需与干预相关、与结果无直接关联），再通过 IV 方法间接估计因果效应，解决了传统 IV 方法工具变量选择难的问题。

在评估“广告投放对销售额的影响”时，LLMs 通过分析广告投放地区的“媒体覆盖率文本报道”，将“媒体覆盖率”确定为合适的工具变量，有效解决了选择偏差问题，使某电商平台的广告效应估计误差降低了 35%。

4 知识增强的特定领域适配

知识增强方法的核心是通过“外部知识注入”（如因果图谱、领域词典），弥补 LLMs 在专业领域知识上的不足，提升因果推理的准确性和可靠性，主要实现方式包括上下文知识注入和知识图谱融合。

适用场景：

在金融、航空、能源等对专业性要求极高的领域，知识增强方法具有突出贡献。在这些领域，LLMs 的通用知识不足以支撑精准的因果推理（如不了解专业的影响机制或因果链），通过注入领域专用的因果知识，可显著提升模型在专业场景下推理的专业性和可靠性。

上下文知识注入：轻量级知识补充

上下文知识注入是在**提示**中直接加入领域因果知识的轻量级增强方式，无需修改模型参数，操作灵活，适用于知识更新快或知识量少的领域。

具体例子：

在航空安全领域分析“航班发动机故障”事件时，通过在提示中预设“叶片疲劳→叶片断裂→发动机喘振→故障”等航空发动机故障的常见因果链，模型能准确分析出“某航班发动机喘振是因叶片疲劳裂纹导致”的因果关系。

知识图谱融合：深度知识整合


知识图谱融合是将结构化的领域因果知识图谱与 LLMs 结合的深度整合方式，模型通过“构建知识图谱→检索因果链→整合推理”的流程，利用图谱中的专业因果关系提升推理的深度和准确性。

在金融领域，先从行业报告中提取因果关系构建金融知识图谱；当分析“降准对房地产行业的影响”时，模型从图谱中检索到“降准→房企融资成本降低→拿地意愿增强→投资增长”的因果链，并结合“当前房企负债率高”的文本信息，最终推理出“降准对房地产行业的提振效果可能有限”的结论。

大模型赋能因果推断总结

大模型通过**语义理解**、**知识内化**和**自然语言交互**三大能力赋能因果推断

1. 提示工程的灵活入门方案
2. 微调的高性能定制方案
3. 融合传统因果方法
4. 知识增强的特定领域适配



5.2大模型赋能因果发现

动机：传统因果发现的搜索困境

- 离散搜索困境
- 连续搜索困境

离散搜索困境

- 因果发现，往往假设因果图有向无环(directed acyclic)，但即便如此，随着变量增加，可能的因果图随超指数增长
- 例子
 - $N=1$, # of DAG = 1
 - $N=2$, # of DAG = 3
 - $N=4$, # of DAG = 543
 - 对于 n 个变量，可能的因果有向无环图数量超过 $2^{\frac{n(n-1)}{2}}$ 个
- 因此在实际情况中，想要完整探索整个DAG空间是几乎不可能

基于连续搜索的因果发现

- 连续搜索指的是将传统的 DAG 学习任务转化成一个连续优化的任务
- 最早由NOTEARS提出，其核心思路是把DAG这一限制用基于邻接矩阵的连续可导函数表示。
 - 定理: $d \times d$ 邻接矩阵 W 对应到一个有向无环图当且仅当 $h(W) = \text{tr}(e^{W \circ W} - d) = 0$
 - 根据上述定理，DAG Learning可被表示成下述优化问题
 - 其中 $F(\cdot)$ 常用似然函数

$$\begin{aligned} & \min_{W \in \mathbb{R}^{d \times d}} F(W) \\ & \text{subject to } h(W) = 0. \end{aligned}$$

连续搜索困境

- 连续 DAG 学习往往**非凸**，高维收敛不稳定且困难
- **依赖很强的假设**。例如之前提到 $F(\cdot)$ 往往是似然函数，所以模型假设需要非常具体（最常见假设是线性高斯模型，且变量本身都是连续而非离散的），即 $X = WX + \epsilon, \epsilon \sim N(0, \sigma^2 I)$
- 因此目前为止，对于因果有向无环图的学习还面临许多限制。那么在实际应用过程中，有什么办法能提高学习效率呢？

一个自然的思路是：若能从外界获取部分“正确的因果边及方向”，便可以大幅减少需要探索的因果图

大模型即领域专家

- 传统上，这一步往往依赖领域专家提供相关领域知识，再交由统计法完成细化与验证。但专家介入具有昂贵、耗时、且不可避免带有主观偏差等问题
- 大模型为外部知识介入因果发现提供了替代路径
- 我们分三部分介绍LLM赋能因果发现
 - **直接推断**：从自然语言与模型元数据直接产出因果边/图
 - **先验注入**：将 LLM 提取的领域知识以先验的形式融入传统统计算法中
 - **后验修正**：对传统统计方法得到的结构进行语义校验与方向纠偏

1 直接推断 (Direct Inference)


- 大模型进行**直接推断**的本质是上下文工程驱动的因果抽取：通过精心构造的角色与证据化提示，把自然语言元数据转译为可计算的因果边与方向。
- 其基本设定如下
 - 向 LLM 提供变量 $X = \{x_1, x_2, \dots, x_n\}$ 的元数据，例如对应的描述文本 $T = \{t_1, t_2, \dots, t_n\}$ 。
 - LLM 通过理解这些描述并调用其已学习的知识，识别出因果边集合 $S = \{(x_i, x_j)\}$ ，其中 (x_i, x_j) 表示“ x_i 导致 x_j ”。

直接推断：典型提示词模板

任务类型	提示词模板
成对发现 (Pairwise Discovery)	"Which is more likely to be true: (A) lung cancer causes cigarette smoking, or (B) cigarette smoking causes lung cancer?"
条件独立性集合检验 (Conditional Independence Set Test)	As an expert in a specific field, you're asked to assess the statistical independence between two variables, potentially conditioned on another variable set. Your response, based on theoretical knowledge, should be a binary guess (YES or NO) and the probability of its correctness, formatted as: [ANSWER (PROBABILITY%)]. For example, [YES (70%)] or [NO (30%)].
因果验证 (Causal Validation)	Given a statistical correlation between variables A and B, and their relationship with other variables in the system, determine if we can validly conclude that A causes B. Please provide your reasoning step by step and conclude with either 'Valid' or 'Invalid' for this causal inference.
全因果图发现 (Full Graph Discovery)	As a domain expert, analyze cause-and-effect relationships among variables with given abbreviations and values. Interpret each variable and present the causal relationships as a directed graph, using edges to denote direct causality, e.g., $x_{i1} \rightarrow x_{j1}, \dots, x_{im} \rightarrow x_{jm}$.


直接推断的高效方案

- 通常使用大模型进行直接推断的计算开销往往是 $O(n^2)$ ，但Jiralerspong携Yoshua Bengio等人 受到根因分析 (Root Cause Analysis)的启发，提出了以下大模型因果发现流程 [1]
 - 阶段一-**确定根因**: 让 LLM 在给定全部变量元数据下识别“不被任何其他变量因果影响”的**根/外生变量**，并把它们作为 **BFS** 的起始节点
 - 阶段二-**扩展**: 每次从队列取出当前节点，给 LLM 当前已发现的部分因果关系作为上下文，让它预测“**当前节点会导致哪些变量变化**”（即该节点的潜在后继/子节点集合）
 - 阶段三-**插入**: 把 LLM 新提出的相连变量加入 BFS 队列，并对拟加入的边做**成环检查**，确保不违反 DAG 约束后再把这些边插入到因果图中




直接推断高维情形下的解决方案

- 在高维情形下，Sokolov等人发现一旦变量太多，基于大模型的全图因果发现便会发生崩溃 [2]。因此，他们提出了一种可扩展的方案：先基于语义相似度进行分层聚类，先在簇内分析连接关系，再判定簇间因果，从而高效地发现因果关系。



直接推断做为CI测试的替代

- 除了直接当作因果关系的先验，大模型的元数据还可以被应用于条件独立性检验 (Conditional Independence Test)，这一 Constrained-based 的因果发现算法的基石。chatPC 方法 [3] 便是这一思路的实例：它将条件独立性检验（如“在给定 Z 时， X 与 Y 独立吗？”）转化为自然语言提示，随后以 LLM 的回答来引导 PC 算法的删边过程



2 先验知识(Prior Knowledge)

- 在传统因果发现中，将专家先验知识纳入算法一般分为两种：
 - **硬约束方法(Hard Constraint)**: 硬约束方法通过删除贝叶斯网络中与因果发现算法所给约束相冲突的边，来严格执行先验知识。例如，
 - Edge Constraint: 强制/禁止 “ $X \rightarrow Y$ ”(required/forbidden edges)
 - Causal Ordering: X 必须作为 Y 的ancestor (不能存在 $Y \rightarrow Z \rightarrow X$)
 - **软约束方法(Soft Constraint)**: 软约束的核心思想是先验不是绝对的，因此其通过惩罚或是奖励的方式影响DAG的学习过程。例如
 - 通过正则的方式惩罚禁止的边: $\min_G L_{data} + \lambda |A_{ij}|$

讨论

- 什么情况下适合使用硬约束？什么情况下使用软约束？对于融合大模型的算法而言，应当选取硬约束还是软约束？
 1. 由软约束常用formulation可见， $\min_G L_{data} + \lambda |A_{ij}|$ ，其天然适合score-based因果发现算法，例如将正则向与BDeu和BIC评分函数结合
 2. 对于置信度极高的先验知识，硬约束更合适
 3. 因此对于大模型而言，软约束是更加合理的先验注入方法

先验知识具体算法

- Ban等人为通过大模型得到先验知识，选择单次问询，得到一系列最有可能的因果关系[4]，以此尽可能避免大模型得到自相矛盾，或是非有向无环的结果
- Kampani等人提出的LLM-DCD专门针对离散数据[5]，利用大模型进行邻接矩阵的估计，并将其作为基于连续优化的因果发现的起始点。而后使用常用的传统方法完成因果发现。
 - （注意，我们之前提到过基于连续搜索的因果发现常常假设变量都是连续的。若所有变量都为binary variables，我们常常假设每个variable都遵循伯努利分布，那么连续方法也不是不能使用。然而categorical变量若想使用基于极大似然的连续方法是较为困难的，因为统计方法常用K个binary dummy variables来替换K-level categorical variable，而这直接让dimension大大增加，Kampani在使用大模型获得先验知识的同时，也针对离散数据设计了别出心裁的优化函数）

3 后验修正(Posterior Correction)

- 最后，在**后验纠正**中，LLM 充当了“专家裁判”的角色，即在上下文推理或额外数据的辅助下，对传统统计因果发现得到的因果结构进行纠错与细化。
- 目前许多算法大模型同时作为先验知识和后验专家
 - 例如，Takayama 等人将不含先验知识、由某种传统因果发现算法得到的原始邻接矩阵 G_0 输入给 LLM[6]；随后，针对每一条潜在边，用成对提示多次向 LLM 提问，并将每次回答记录“是/否”。接着，将多次回答聚合为概率矩阵 P ，并依据预设阈值将其离散化为确定性的先验矩阵 $\hat{G}$ 。最后，把 $\hat{G}$ 回注到原始的 CD 方法中，推断最终因果图。

后验修正优化MEC

- 回忆PC算法，算法本质是得到一系列不同变量之间的条件概率关系，这就导致了马尔可夫 (Markove Equivalent Class, MEC)等价类的出现
 - 例如， $X \rightarrow Y \rightarrow Z$ 和 $Z \rightarrow Y \rightarrow X$ 是马尔可夫等价的（为什么？）
 - 因为他们同时满足以下的条件概率关系集合： $X \perp Z | Y$,同时 X, Y, Z 互不独立
- Long 等人 [7] 将 LLM 视为 “不完美专家”，在控制边方向误判风险的前提下逐步缩小 MEC 中可行结构的数量。

大模型赋能因果发现面临的挑战

- **大模型核验SCM假设** 目前的研究几乎都是将大模型运用与因果边的识别，却未被应用到验证我们对于 Structural Causal Model (SCM)的假设是否正确这一问题上，其中包括因果关系是否线性，噪声分布假设是否合理等等。
- 此类核验尤为重要，因为传统方法依赖特定假设——例如LiNGAM 要求噪声分布为非高斯分布；类似地，若变量之间存在非线性效应时，BIC 打分的可靠性会下降。LLM 可以利用其语言理解能力去解释关于预期关系特征领域的知识，从而帮助选择合适的算法并校验假设，在多样场景中提升可靠性。

大模型赋能因果发现面临的挑战

增强CD的可解释性 大语言模型（LLM）是否具备真正的因果推理能力仍是一个开放问题。例如，Feng等人在2024年指出[8]，LLM可能更多地只是在模仿而非真实地在推理，即复述其内嵌的知识，而非理解真正的因果机制 [9]；Jin等人在2023年提到它们更像没有深层理解的‘因果鹦鹉’ [10]。当问题需要理解混杂变量时，LLM 往往依赖相关性的启发式，显示出统计关联与因果理解之间的鸿沟。

未来研究应侧重于：

1. 开发可解释性方法，以分析 LLM 如何处理因果关系；
2. 探究预训练数据与因果能力之间的关系；
3. 构建能够区分真正推理与记忆化模式的评估框架。

References


- [1] T. Jiralerspong, X. Chen, Y. More, V. Shah, and Y. Bengio, “Efficient Causal Graph Discovery Using Large Language Models.” 2024.
- [2] A. Sokolov, F. Sabelli, B. faraz, W. Li, and L. Seco, “Towards Automating Causal Discovery in Financial Markets and Beyond,” *SSRN Electron. J.*, Jan. 2024, doi: 10.2139/ssrn.4679414.
- [3] K.-H. Cohrs, E. Diaz, V. Sitokonstantinou, G. Varando, and G. Camps-Valls, “Large Language Models for Constrained-Based Causal Discovery,” in *AAAI 2024 Workshop on “Are Large Language Models Simply Causal Parrots?”*, 2023. [Online]. Available: <https://openreview.net/forum?id=NEAoZRWHPN>
- [4] Taiyu Ban, Lyuzhou Chen, Derui Lyu, Xiangyu Wang, and Huanhuan Chen. Causal structure learning supervised by large language model, 2023.
- [5] S. Kampani, D. Hidary, C. van der Poel, M. Ganahl, and B. Miao, “LLM-initialized Differentiable Causal Discovery.” 2024. [Online]. Available: <https://arxiv.org/abs/2410.21141>
- [6] M. Takayama *et al.*, “Integrating Large Language Models in Causal Discovery: A Statistical Causal Approach.” 2024.
- [7] S. Long, A. Piché, V. Zantedeschi, T. Schuster, and A. Drouin, “Causal Discovery with Language Models as Imperfect Experts,” in *ICML 2023 Workshop on Structured Probabilistic Inference & Generative Modeling*, 2023. [Online]. Available: <https://openreview.net/forum?id=RXlvYZAE49>
- [8] Taiyu Ban, Lyvzhou Chen, Xiangyu Wang, and Huanhuan Chen. From query tools to causal architects: Harnessing large language models for advanced causal discovery from data, 2023.

References


- [8] C. Shen, Z. Chen, D. Luo, D. Xu, H. Chen, and J. Ni, “Exploring Multi-Modal Integration with Tool-Augmented LLM Agents for Precise Causal Discovery.” 2024. [Online]. Available: <https://arxiv.org/abs/2412.13667>
- [9] T. Feng, L. Qu, N. Tandon, Z. Li, X. Kang, and G. Haffari, “From Pre-training Corpora to Large Language Models: What Factors Influence LLM Performance in Causal Discovery Tasks?” 2024. [Online]. Available: <https://arxiv.org/abs/2407.19638>
- [10] Z. Jin *et al.*, “CLadder: Assessing Causal Reasoning in Language Models,” in *NeurIPS*, 2023. [Online]. Available: <https://openreview.net/forum?id=e2wtjx0Yqu>
- [11] Guangya Wan et al. “Large Language Models for Causal Discovery: Current Landscape and Future Directions”. In: Proceedings of the Thirty-Fourth International Joint Conference on Artificial Intelligence, IJCAI-25. Ed. by James Kwok. Survey Track. International Joint Conferences on Artificial Intelligence Organization, Aug. 2025, pp. 10687–10695. doi: 10.24963/ijcai.2025/1186. url: <https://doi.org/10.24963/ijcai.2025/1186>.

大数据模型 (LDM)

a TabPFN is trained on synthetic data to take entire datasets as inputs and predict in a forward pass



TabPFN can now be applied to arbitrary
unseen real-world datasets




b Input dataset

	x_1	x_2	y
Test Training rows	1.2	6.1	3.0
	8.9	9.1	3.1
	1.0	2.9	6.7
	33.3	2.2	?



We predict this entry

2D TabPFN layer (12x)



- Each node represents one entry in the table

Predictions: $\hat{y}_{\text{test}}$



LDM for Causal Inference

LDM for Causal Discovery

值得探索的一个方向

LLM+LDM

打通语义空间和数据空间

